# Hybrid-INoT: гибридная агентная архитектура с внутренней ролевой сегрегацией для инженерных задач в условиях длинного общего контекста

Даниил Привезенцев[1*]

[1*]Национальный исследовательский университет «Высшая школа экономики», Москва, Россия.

Corresponding author(s). E-mail(s): daprivezentsev@edu.hse.ru;

**Аннотация**

Внешняя мультиагентная оркестрация (Classical-MAS) на базе больших языковых моделей многократно передаёт общий контекст независимым ролям и порождает постоянные издержки координации, что в задачах с длинным разделяемым контекстом ведёт к сверхлинейному росту токенного бюджета. В работе рассматривается **Hybrid-INoT** — гибридная архитектура, в которой ролевой цикл *planner–worker–critic–self-check* развёрнут внутри одного вызова модели, тогда как вовне вынесены только инструментальные действия, верификация и компрессия контекста. Архитектура описывается через операциональную модель, функцию маршрутизации RouteMode и условие останова внутреннего ролевого цикла. Показано, что при $|\mathcal{C}_0| > \tau^\star$ и $|\mathcal{A}| \geq 3$ ожидаемый токенный расход Hybrid-INoT оказывается ниже, чем у Classical-MAS; кроме того, получена верхняя оценка расхода токенов в худшем случае и выведено условие экономической эффективности малой модели самопроверки. Предлагается также система метрик токенной эффективности, денежной стоимости и поддерживаемости кода, а также программа эмпирической проверки, включающая пилотное сравнение на HumanEval, абляционный анализ, исследование масштабирования по длине контекста, оценку процедуры самопроверки и расчёт TCO на реальных измерениях.

**Keywords:** Большие языковые модели, агентные системы, интроспекция ролей, Introspection of Thought, Self-Refine, Reflexion, токенная эффективность, экономика инференса, надёжность кода, экспериментальный протокол

# 1 Введение

## 1.1 Научная проблема и её измеримая цена

В агентных системах на основе больших языковых моделей типичной конфигурацией является внешняя мультиагентная оркестрация (Classical-MAS): отдельные процессы или вызовы реализуют ролей планировщика, исполнителя, критика, тестировщика [12–14]. В задачах программной инженерии, где несколько ролей читают одни и те же длинные фрагменты кода, логов и документации, такая схема обладает структурным дефектом: *каждая роль получает копию общего контекста $\mathcal{C}_0$ заново*, а между ролями дополнительно курсируют сообщения координации. В терминах токенного бюджета это даёт слагаемое

$$D_{\text{ctx}} + H_{\text{coord}} \quad \in \quad \Theta(|\mathcal{A}| \cdot |\mathcal{C}_0|) + \Theta(|\mathcal{A}|^2 \cdot \bar{h}),$$

где $|\mathcal{A}|$ — число ролей, $\bar{h}$ — средняя длина координационного сообщения. Это не умозрительное наблюдение: эмпирические замеры показывают, что при $|\mathcal{A}| \geq 4$ и $|\mathcal{C}_0| \geq 4000$ токенов доля контекста в общем расходе превышает 60% [14, 15]. При стандартных ценах API \$3/M input-токенов (на уровне Claude Sonnet 3.5 / GPT-4o в 2025 г.) цена этого структурного дефекта составляет единицы тысяч долларов в месяц на скромном объёме в 10 000 задач.

Таким образом, издержки рассматриваемой архитектурной схемы допускают количественное выражение: при масштабе $10^4$–$10^6$ инженерных задач Classical-MAS расходует на многократную ретрансмиссию контекста на порядок больше ресурсов, чем на собственно генерацию решения. Именно это обстоятельство определяет рассматриваемый научный пробел.

## 1.2 Научный пробел

Открытая литература содержит три родственных линии: (i) внутриконтекстная самокритика одной модели — Self-Refine [7], Reflexion [8]; (ii) чередование рассуждения и действия внутри одного агента — ReAct [6], SWE-agent [17]; (iii) внешняя ролевая декомпозиция на отдельные вызовы — MetaGPT [12], ChatDev [13]. Ни одна из этих работ не задаёт *операционально отличимую* промежуточную конфигурацию, в которой (а) внутри одного вызова удерживается разделяемый контекст без дублирования, (б) ролевая сегрегация достаточна для критического разбора, (в) внешними остаются только операции с проверяемыми сигналами (тесты, статический анализ, вызовы инструментов). Отсутствует также формальное условие, при котором такой гибрид доминирует над чисто внешней MAS по ожидаемому токенному расходу.

## 1.3 Основные результаты и вклад статьи

В статье получены следующие результаты:

**C1.** Операциональное определение Hybrid-INoT с явной сигнатурой состояний, функцией маршрутизации RouteMode и условием сходимости внутреннего ролевого цикла (§4).

**C2.** Утверждение 2 о строгом преимуществе Hybrid-INoT над Classical-MAS по ожидаемому числу токенов при $|\mathcal{C}_0| > \tau^\star$, $|\mathcal{A}| \geq 3$, доказанное через явный подсчёт токенов при явно выписанных предположениях (§5).

**C3.** Неравенство (2), задающее условие экономической эффективности малой модели самопроверки (§5).

**C4.** Система метрик токенной эффективности, стоимости и поддерживаемости кода с обоснованной формой агрегации (§6).

**C5.** Программа эмпирической валидации, включающая пять исследований E1–E5 с фиксированными базовыми конфигурациями, абляционным анализом и исследованием режимов отказа (§7).

Эмпирическая проверка преимуществ Hybrid-INoT при длинном контексте обсуждается в §10.

# 2 Связанные работы и формальное разграничение

## 2.1 От chain-of-thought к внутреннему ролевому дебату

Chain-of-Thought [5] показал, что явное порождение промежуточных шагов повышает качество. Self-Refine [7] формализует цикл «генератор–обратная связь–исправление» внутри одной модели. Reflexion [8] дополняет эту схему рефлексивной памятью, а ReAct [6] сочетает рассуждение с действием. Работа Sun и Zeng [1] описывает Introspection of Thought (INoT) как структурированный внутренний дебат нескольких ролей. В то же время Turpin et al. [9] показывают, что промежуточный текст цепочки не следует интерпретировать как достоверное описание скрытого вычислительного процесса. Поэтому в настоящей работе интроспекция рассматривается прежде всего как вычислительный механизм отбора кандидатов, критики и селективного перезапуска.

## 2.2 Мультиагентные системы для программной инженерии

Weiss [10] и Wooldridge [11] задают теоретическую рамку MAS. MetaGPT [12] и ChatDev [13] переносят её в контекст больших языковых моделей: роли реализуются как отдельные вызовы, каждая получает собственную копию контекста. Обзорные работы указывают на два ключевых ограничения Classical-MAS: распространение ошибки по цепочке и рост стоимости координации [14, 15]. SWE-bench и SWE-agent [16, 17] показывают, что практическая автоматизация задач программной инженерии требует длинного контекста и итеративного редактирования, что ещё сильнее обостряет проблему ретрансмиссии $D_{\mathrm{ctx}}$.

## 2.3 Компрессия контекста и внешняя верификация

LongLLMLingua и LLMLingua-2 [20, 21] демонстрируют, что компрессия промпта сохраняет или улучшает качество на длинном контексте при снижении стоимости. Jia et al. [22] применяют этот подход к коду. Для самопроверки кода недостаточно языковой рефлексии: необходимы внешние наблюдаемые сигналы — тесты, статический анализ и сообщения компилятора [23–25].

## 2.4 Формальное разграничение Hybrid-INoT от предшественников

**Таблица 1** Операциональные отличия Hybrid-INoT от ближайших работ. Разграничение строится по пяти осям: (i) хранилище контекста, (ii) число внешних вызовов модели на итерацию, (iii) наличие внешней верификации, (iv) условие маршрутизации, (v) условие останова.

| Ось | Ближайшие работы | Hybrid-INoT (наш вклад) |
|---|---|---|
| Контекст | Self-Refine, Reflexion: один контекст, без сегрегации ролей. MetaGPT, ChatDev: $\lvert\mathcal{A}\rvert$ независимых копий. | Один контекст с явно выделенными ролевыми префиксами $\mathcal{R} = \{r_p, r_w, r_c, r_v\}$; ретрансмиссия $D_{\text{ctx}}$ устранена. |
| Вызовы на итерацию | Self-Refine, Reflexion: 1. ReAct: 1 с tool use. MetaGPT/ChatDev: $\lvert\mathcal{A}\rvert$. | $1+\mathbb{I}$[external check]. |
| Верификация | Self-Refine, Reflexion: языковая. MetaGPT/ChatDev: ролевая (ещё одна языковая). SWE-agent: тесты. | Обязательная внешняя с наблюдаемыми сигналами (tests, static analysis); языковой self-critique используется лишь как фильтр. |
| Маршрутизация | Фиксирована архитектурно. | Явная функция $\textsc{RouteMode}: \mathcal{X} \times \hat{\mathcal{C}} \to \{\texttt{internal}, \texttt{external}\}$ (Опр. 2). |
| Останов | Self-Refine: фиксированное $I$. Reflexion: эпизодический. MetaGPT: до consensus. | До первого $v_i = \texttt{pass}$ или до исчерпания $I$; условие сходимости — Утв. 1. |

Таблица 1 показывает, что отдельные компоненты предлагаемой схемы встречаются в предшествующих работах. Новизна Hybrid-INoT состоит в их объединении в архитектуру с формально заданной маршрутизацией, внутренним ролевым циклом и внешней верификацией, а также в выводе условий токенного преимущества такой композиции (§5).

# 3 Формальная постановка задачи

## 3.1 Задача

**Определение 1** (Агентная инженерная задача)**.** *Задача — кортеж* $(x, \mathcal{C}_0, \mathcal{Z}, \mathcal{V})$, *где* $x \in \mathcal{X}$ *— описание задания,* $\mathcal{C}_0$ *— исходный контекст (код, документация, логи),* $\mathcal{Z}$ *— множество разрешённых внешних инструментов,* $\mathcal{V} : \mathcal{Y} \to \{0, 1\}$ *— внешняя проверяемая функция успеха (например, набор тестов).*

Агент обязан вернуть $y \in \mathcal{Y}$, максимизируя ожидаемое $\mathcal{V}(y)$ при ограничении $T \le B$, $C_{\text{inf}} \le B_{\$}$, $\ell \le B_\ell$, где $T$, $C_{\text{inf}}$, $\ell$ — суммарный токенный расход, денежная стоимость и задержка.

## 3.2 Гипотезы исследования

***H1*** *(преимущество при длинном контексте).* Существует порог $\tau^\star$ такой, что для задач с $\lvert\mathcal{C}_0\rvert > \tau^\star$ Hybrid-INoT обеспечивает рост показателя $U_{\text{tok}}$ не менее чем на $\delta_{H1} = 15\%$ относительно Classical-MAS при неухудшении качества в пределах 2 п.п.

*Проверка:* эксперимент E1 (§7.2) с парным критерием Вилкоксона, 95% bootstrap CI, поправкой Холма–Бонферрони; значение $\tau^\star$ оценивается в E3 (§7.4).

***H2*** *(экономическая оправданность малой модели самопроверки).* Существует режим, в котором малая модель self-check снижает вероятность дорогого перезапуска $\rho$ так, что выполняется условие (2): $C^S_{\text{check}} < (\rho_0 - \rho_1)C^L_{\text{rerun}}$.

*Проверка:* E4 (§7.5) с прямыми измерениями $\rho_0, \rho_1, C^S_{\text{check}}, C^L_{\text{rerun}}$ на 100 задачах HumanEval и 50 задачах SWE-bench Lite.

***H3*** *(граница применимости).* При задачах с истинной независимостью подзадач и высокой степенью параллелизма инструментов преимущество Hybrid-INoT по времени ответа исчезает или становится отрицательным.

*Проверка:* исследование режима отказа E2c (§7.3) на подмножестве задач с явно параллельной структурой из Synthetic Tool-Use Suite.

Гипотеза H3 задаёт границу применимости архитектуры: при высокой независимости подзадач и выраженном параллелизме инструментальных вызовов выигрыш внутреннего ролевого цикла по задержке может исчезать. Порог $\delta_{H1} = 15\%$ для H1 выбран как минимально практически значимое улучшение с учётом типичной вариативности токенного бюджета при изменении seed ($\approx 5{-}8\%$ std в [7]) и инженерных издержек развёртывания гибридной схемы при масштабе $10^4$ задач в месяц. Устойчивость выводов к выбору этого порога оценивается в E1 на сетке $\delta \in \{5\%, 10\%, 15\%, 20\%\}$.

# 4 Метод: Hybrid-INoT

## 4.1 Состояния и сигнатуры ролей

Определим состояние системы $\sigma = (x, \hat{\mathcal{C}}, \mathcal{H}, i, b)$, где $\hat{\mathcal{C}}$ — сжатый контекст, $\mathcal{H}$ — история итераций, $i \in \{0, \dots, I\}$ — счётчик итераций, $b \in \mathbb{N}$ — остаток токенного бюджета.

Каждая роль задаётся сигнатурой $r : \mathcal{S}_r^{\text{in}} \to \mathcal{S}_r^{\text{out}}$:

$$
\begin{aligned}
r_{\text{plan}} &: (x, \hat{\mathcal{C}}, b) \mapsto \pi \in \Pi, \\
r_{\text{work}} &: (\pi, \hat{\mathcal{C}}, K) \mapsto \{y_1, \dots, y_K\} \subset \mathcal{Y}, \\
r_{\text{crit}} &: (\{y_k\}, \hat{\mathcal{C}}) \mapsto (s_1, \dots, s_K) \in [0,1]^K, \\
r_{\text{self}} &: y \mapsto (v, M) \in \{0,1\} \times [0,1].
\end{aligned}
$$

Роли $r_{\text{plan}}, r_{\text{work}}, r_{\text{crit}}$ реализуются как ролевые префиксы внутри *одного* вызова крупной модели над общим $\hat{\mathcal{C}}$; роль $r_{\text{self}}$ — внешний процесс запуска тестов и статического анализа.

## 4.2 Функция маршрутизации

**Определение 2** (RouteMode)**.** *Пусть $\phi_{tool}(x) \in \{0,1\}$ указывает на обязательность внешнего инструмента, $\phi_{par}(x) \in \{0,1\}$ — на доминирующий*

*параллелизм подзадач, $|\hat{\mathcal{C}}|$ — длина сжатого контекста. Тогда*

$$\textsc{RouteMode}(x, \hat{\mathcal{C}}) = \begin{cases} \texttt{external}, & \phi_{tool}(x) = 1 \ \vee \ \phi_{par}(x) = 1 \ \vee \ |\hat{\mathcal{C}}| < \tau^{\star}_{route}, \\ \texttt{internal}, & \text{иначе.} \end{cases}$$

*Параметры $\phi_{tool}, \phi_{par}$ определяются отдельным классификатором над $x$ (в базовой реализации — лёгким классификатором на основе инструкции к модели, в дальнейшем — обученным бинарным классификатором); порог $\tau^{\star}_{route} = 1024$ токена используется как исходная конфигурация и уточняется в E3.*

## 4.3 Внутренний цикл и условие сходимости

**Algorithm 1** Hybrid-INoT: внутренний интроспективный цикл

**Require:** задача $x$, контекст $\mathcal{C}_0$, бюджет $B$, максимум итераций $I$, число кандидатов $K$

**Ensure:** решение $y^{\star}$, флаг $v^{\star}$, оценка $M^{\star}$

```
C ← PolicySanitize(x, C_0)
Ĉ ← CompressIfNeeded(C)                                   ▷ Алг. 2
m ← RouteMode(x, Ĉ)                                       ▷ Опр. 2
if m = external then return ExternalAgentWorkflow(x, Ĉ)
end if
s^best ← −∞; y^best ← ⊥
for i = 1 to I do
    π_i ← r_plan(x, Ĉ, B − spent)
    {y_{i,k}} ← r_work(π_i, Ĉ, K)
    (s_{i,1}, ..., s_{i,K}) ← r_crit({y_{i,k}}, Ĉ)
    k* ← arg max_k s_{i,k}; y_i ← y_{i,k*}
    if s_{i,k*} > s^best then s^best ← s_{i,k*}; y^best ← y_i
    end if
    (v_i, M_i) ← r_self(y_i)                  ▷ внешние тесты и статический анализ
    if v_i = 1 then return (y_i, 1, M_i)
    end if
    Ĉ ← UpdateContextWithFailures(Ĉ, v_i)
    if stagnation(s_{i,k*} − s_{i−1,k*}) < ε then break   ▷ см. Утв. 1
    end if
end for
return (y^best, 0, M(y^best))
```

**Утверждение 1** (Останов внутреннего цикла)**.** *Пусть $s_i := \max_k s_{i,k}$ — максимальная оценка критика на итерации $i$. Если (a) критик $r_{crit}$ детерминирован при фиксированном контексте и (b) каждая неудача добавляет в $\hat{\mathcal{C}}$ непустой сигнал об ошибке, то алгоритм 1 завершится не позднее итерации $I$, при этом*

*либо вернёт $v = 1$, либо $s_i$ образует ограниченную сверху последовательность с хотя бы одной точкой стагнации, обнаруживаемой правилом $|s_i - s_{i-1}| < \epsilon$.*

*Набросок* Верхний цикл явно ограничен $I$. Монотонное накопление сигналов об ошибке в $\hat{\mathcal{C}}$ гарантирует, что состояние контекста не повторяется на последовательных итерациях, поэтому пара $(\hat{\mathcal{C}}_i, s_i)$ не зацикливается. Ограниченность $s_i \in [0, 1]$ влечёт существование предела у некоторой подпоследовательности; правило стагнации выявляет выход на плато и останавливает цикл. □ □

***Замечание.***

Утверждение 1 не гарантирует монотонного роста $s_i$ и не исключает ситуаций, в которых критик систематически подтверждает неверные решения. Этот сценарий рассматривается отдельно в E2b (§7.3) как одна из угроз валидности.

### 4.4 Компрессия контекста

**Algorithm 2** Компрессия длинного контекста

**Require:** $\mathcal{C}_0$, порог длины $\tau_{\text{len}}$
**Ensure:** $\hat{\mathcal{C}}$

```
if |C_0| ≤ τ_len then return C_0
end if
разбить C_0 на смысловые блоки {b_j}
оценить rel(b_j) с помощью классификатора по типу LLMLingua-2 [21]
удалить дубликаты, низкоинформативные логи, вторичную документацию
сохранить API-сигнатуры, трассы с ошибками, изменяемые файлы и ограничения задачи
return Ĉ с |Ĉ| ≤ τ_len
```

### 4.5 Селективный перезапуск

## 5 Аналитическая модель токенных и стоимостных затрат

### 5.1 Структура аналитических соотношений

Анализ в данном разделе включает два типа соотношений. К первому относятся прямые балансовые равенства и неравенства, задающие структуру токенных и денежных затрат. Ко второму относятся утверждения о сравнении архитектур при фиксированных предположениях относительно длины контекста, стоимости координации и внутренней критики. Такое разделение позволяет отличить общие расчётные соотношения от результатов, требующих дополнительных условий.

**Algorithm 3** Селективный перезапуск по подтверждённым сигналам

**Require:** кандидаты $\{y_1, \ldots, y_K\}$, оценки $\{s_k\}$, бюджет повторов $R$
**Ensure:** $y^\star$

```
отсортировать {y_k} по убыванию s_k; оставить верхние M ≤ K
for каждый y_m do
    q_m ← ExternalVerify(y_m)
    if q_m = 1 then return y_m
    end if
end for
if R > 0 then промпт формируется только по подтверждённым сигналам ошибки; return SelectiveRerun(R − 1)
end if
return arg max_k s_k
```

## 5.2 Токенные бюджеты Classical-MAS и Hybrid-INoT

**Предположение 1.** *Среди ролей $\mathcal{A}$ в Classical-MAS не менее $\alpha|\mathcal{A}|$ ролей, $\alpha \in (0, 1]$, читают общий контекст $\mathcal{C}_0$ целиком.*

**Предположение 2.** *Длина координационных сообщений ограничена $\bar{h}$, число итераций обеих схем равно $I$, стоимость компрессии $T_{cmp} \leq \gamma|\mathcal{C}_0|$ с $\gamma < \alpha|\mathcal{A}|$, стоимость внутренней критики $T^{add}_{core} \leq \beta|\hat{\mathcal{C}}|$, $\beta < \alpha|\mathcal{A}| - \gamma$.*

**Утверждение 2** (Токенное преимущество при длинном контексте)**.** *При Предположениях 1–2 и $|\mathcal{A}| \geq 3$ существует $\tau^\star > 0$ такой, что при $|\mathcal{C}_0| > \tau^\star$ выполняется*

$$\mathbb{E}[T_{MAS}] - \mathbb{E}[T_{INoT}] \;\geq\; (\alpha|\mathcal{A}| - \gamma - \beta) \cdot |\mathcal{C}_0| + \Theta(|\mathcal{A}|^2\bar{h}) - T_{check} - \mathbb{E}[T_{rerun}] \;>\; 0.$$

*Набросок* $\mathbb{E}[T_{\mathrm{MAS}}] \geq I \cdot \alpha|\mathcal{A}| \cdot |\mathcal{C}_0| + I \cdot |\mathcal{A}|^2\bar{h} + T_{\mathrm{gen}}$. $\mathbb{E}[T_{\mathrm{INoT}}] \leq I \cdot |\hat{\mathcal{C}}| + T_{\mathrm{cmp}} + T_{\mathrm{check}} + \mathbb{E}[T_{\mathrm{rerun}}] + T_{\mathrm{gen}}$, где $|\hat{\mathcal{C}}| \leq |\mathcal{C}_0|$. Подставляя оценки компрессии и беря разность, получаем линейное по $|\mathcal{C}_0|$ преимущество с положительным коэффициентом $(\alpha|\mathcal{A}| - \gamma - \beta)$ при достаточно большом $|\mathcal{C}_0|$. Порог $\tau^\star$ — наименьшее значение $|\mathcal{C}_0|$, при котором линейный член компенсирует постоянные слагаемые. □ □

***Область применимости утверждения.***

Утверждение 2 задаёт нижнюю оценку разности ожидаемых токенных бюджетов при Предположениях 1–2. При $|\mathcal{A}| = 2$ (например, plan+exec без выделенного критика) знак этой разности может изменяться. Аналогично, при $|\mathcal{C}_0| < \tau^\star$ преимущество Hybrid-INoT не гарантируется. Значение $\tau^\star$ зависит от $\alpha, \beta, \gamma, |\mathcal{A}|, I$ и должно уточняться эмпирически.

### 5.3 Верхняя граница токенного расхода

**Утверждение 3** (Верхняя граница расхода токенов Hybrid-INoT)**.** *В худшем случае, когда все $I$ итераций заканчиваются $v_i = 0$,*

$$T_{INoT}^{worst} \leq T_{cmp} + I \cdot K \cdot (p^L + r^L) + I \cdot T_{check} + I \cdot T_{rerun}^{unit}.$$

Полученная оценка задаёт верхнюю границу дополнительных токенных затрат и используется как ограничение при бюджете $B$: при $T \to B$ алгоритм 1 возвращает лучшего из доступных кандидатов.

### 5.4 Условие экономической эффективности малой модели самопроверки

Денежная стоимость инференса:

$$C_{\text{inf}} = c_L^{in} \sum_i p_i^L + c_L^{out} \sum_i r_i^L + c_S^{in} \sum_i p_i^S + c_S^{out} \sum_i r_i^S. \tag{1}$$

Малая модель самопроверки экономически эффективна тогда и только тогда, когда

$$\underbrace{C_{\text{check}}^S}_{\text{стоимость проверки}} < \underbrace{(\rho_0 - \rho_1) \cdot C_{\text{rerun}}^L}_{\text{ожидаемая экономия}}. \tag{2}$$

Неравенство (2) задаёт критерий выбора между дешёвой предварительной проверкой и повторным запуском крупной модели. Его практическая применимость определяется величинами $\rho_0, \rho_1, C_{\text{check}}^S$ и $C_{\text{rerun}}^L$, которые подлежат оценке в E4.

## 6 Система метрик

### 6.1 Основные метрики и обоснование формы агрегации

$$U_{\text{tok}} = \frac{Q}{T}, \qquad Q_{\$} = \frac{Q}{C_{\text{inf}}}, \qquad VCR = \frac{1}{N} \sum_i \mathbb{I}[\text{tests}_i = 1 \wedge \text{static}_i = 1 \wedge \text{sec}_i = 1]. \tag{3}$$

Для неоднородного качества используется взвешенная сумма по классам задач $Q = \sum_b w_b Q_b$ с весами, заданными в таблице 2.

### 6.2 Агрегированная метрика успешности и её форма

Для агрегированной оценки успешности используется форма

$$MAS_i = \min(Success_i, Verified_i) \cdot M_i^{\lambda}, \qquad \lambda \in [0, 1], \quad \lambda = 0.5. \tag{4}$$

Обоснование этой конструкции состоит в следующем. Во-первых, величины *Success* и *Verified* являются необходимыми условиями засчитывания решения:

patch, не прошедший внешнюю проверку, не должен получать высокий итоговый балл. Во-вторых, множитель $M_i^\lambda$ моделирует влияние поддерживаемости на итоговую оценку; параметр $\lambda$ регулирует силу этого влияния. В базовой конфигурации используется $\lambda = 0.5$, а устойчивость выводов к выбору $\lambda$ оценивается в E2d.

### 6.3 Веса поддерживаемости и их обоснование

$$M_i = w_{cc}(1 - \widetilde{CC_i}) + w_{dup}(1 - \widetilde{Dup_i}) + w_{warn}(1 - \widetilde{Warn_i}) + w_{doc}\widetilde{Doc_i}. \quad (5)$$

**Таблица 2** Веса поддерживаемости и их связь с подкатегориями ISO/IEC 25010:2023 [26]

| Параметр | Значение | Обоснование |
|---|---|---|
| $w_{cc}$ | 0.35 | ISO 25010 Modifiability; цикломатическая сложность [27] — наиболее прямой прокси стоимости сопровождения. |
| $w_{dup}$ | 0.25 | ISO 25010 Reusability; дублирование — ключевой сигнал технического долга. |
| $w_{warn}$ | 0.20 | ISO 25010 Analysability; warnings — поверхностный, но надёжный сигнал. |
| $w_{doc}$ | 0.20 | ISO 25010 Modifiability; покрытие документацией как прокси понятности. |

***Анализ чувствительности.***

В E2d проверяется устойчивость ранжирования конфигураций B0–B3 при вариации $(w_{cc}, w_{dup}, w_{warn}, w_{doc})$ в $\pm 20\%$ и при $\lambda \in \{0, 0.25, 0.5, 0.75, 1\}$ в (4). Инверсия ранжирования при таких вариациях рассматривается как признак чувствительности метрики к выбранной параметризации.

### 6.4 Метрики надёжности

$$SCR = \frac{\#\{\text{ошибочные кандидаты, выявленные процедурой самопроверки}\}}{\#\{\text{все ошибочные кандидаты}\}}, \quad (6)$$

$$RFR = \frac{\#\{\text{патчи без отката}\}}{\#\{\text{применённые патчи}\}}. \quad (7)$$

## 7 Программа эмпирической валидации

### 7.1 Общие правила

Во всех экспериментах фиксируются идентификаторы задач, значения seed, версии моделей с идентификаторами снимков и цены токенов с датой измерения. Для закрытых API без фиксированного идентификатора версии данные выносятся в отдельное приложение с описанием наблюдаемых характеристик. Статистическая обработка включает парный критерий Вилкоксона для непрерывных метрик, критерий Мак-Немара для бинарных исходов, 95% bootstrap CI ($10^4$ ресэмплирований) и поправку Холма–Бонферрони.

## 7.2 E1 — Пилот на HumanEval

**Цель:** проверить H1 на ограниченной выборке. **Данные:** HumanEval (164 задачи) [18]; для каждой задачи рассматриваются четыре версии с искусственным историческим контекстом длиной $\{512, 2048, 8192\}$ токенов, сгенерированным детерминированным шаблоном; всего $164 \times 4 = 656$ случаев. Значения seed: $\{42, 123, 456, 789, 1337\}$. **Сравниваемые конфигурации:**

- B0 Single-Large (один вызов крупной модели без итераций);
- B1 Single-Large + Self-Refine [7], три итерации;
- B2 Classical-MAS (planner, worker, critic — отдельные вызовы, архитектура в духе MetaGPT);
- B3 Hybrid-INoT ($K = 3$, $I = 3$).

**Метрики:** pass@1, $T$ (суммарно), $U_{\text{tok}}$, $C_{\text{inf}}$ (долл. США на 1000 задач при ценах от {дата}), $Q_{\$}$, время ответа. **Критерий успеха H1:** B3 даёт $\Delta U_{\text{tok}} \geq 15\%$ по сравнению с B2 на подмножестве с $|\mathcal{C}_0| > 2048$, $p < 0.05$ после Holm–Bonferroni; значение pass@1 не ухудшается более чем на 2 п.п. **Критерий неудачи:** при невыполнении этих условий H1 считается неподтверждённой, а выводы формулируются без утверждения о преимуществе Hybrid-INoT.

Таблица 3 задаёт формат представления результатов после выполнения эксперимента.

**Таблица 3** Формат представления результатов эксперимента E1

| Конфигурация | pass@1 | токены/задача | $U_{\text{tok}}$ | долл. США/1000 |
|---|---|---|---|---|
| B0 | — | — | — | — |
| B1 Self-Refine | — | — | — | — |
| B2 Classical-MAS | — | — | — | — |
| B3 Hybrid-INoT | — | — | — | — |

## 7.3 E2 — Абляционный анализ и неблагоприятные сценарии

**E2a.** B3 vs B3a (без компрессии), B3b (без критика), B3c (без самопроверки). Данные: HumanEval, $n = 164$. Критерий: каждый компонент должен давать статистически значимый вклад; если $\Delta_{\text{B3}-\text{B3b}}$ незначимо, роль критика исключается из архитектуры. **E2b** (неблагоприятный сценарий — систематическая ошибка критика). Подмножество из 50 задач, где базовая конфигурация B0 ошибается; измеряется, как часто $r_{\text{crit}}$ подтверждает неверного кандидата; порог тревоги: $> 20\%$ означает необходимость внешнего обучения критика. **E2c** (неблагоприятный сценарий — параллельные инструменты, H3). 50 задач с явно независимыми подзадачами из Synthetic Tool-Use Suite; сравнивается время ответа B3 и B2; ухудшение времени ответа B3 до 30% считается допустимым. **E2d** (анализ чувствительности метрик). Ранжирование конфигураций при $w \pm 20\%$, $\lambda \in \{0, 0.25, 0.5, 0.75, 1\}$.

### 7.4 E3 — Масштабирование по длине контекста

**Цель:** эмпирически оценить $\tau^\star$ из Утв. 2. **Данные:** 50 задач HumanEval $\times$ 4 длины контекста $\{256, 1024, 4096, 16384\} = 200$ случаев. **Метод:** построить $U_{\text{tok}}(|\mathcal{C}_0|)$ для B0, B2, B3; найти точку пересечения $U^{B3}_{\text{tok}}(|\mathcal{C}_0|) = U^{B2}_{\text{tok}}(|\mathcal{C}_0|)$. **Критерий:** $\tau^\star$ должен быть конечен и $< 16384$; иначе H1 и Утв. 2 не подтверждаются на практически значимом диапазоне.

### 7.5 E4 — Оценка процедуры самопроверки и H2

**Цель:** проверить (2). **Данные:** 100 задач HumanEval + 50 SWE-bench Lite [16]. **Измерения:** $\rho_0$ (доля неверных решений без самопроверки), $\rho_1$ (с самопроверкой), $C^S_{\text{check}}$, $C^L_{\text{rerun}}$, полученные прямыми измерениями. **Дополнительно:** полнота SCR и соотношение стоимости и полезности процедуры самопроверки. **Критерий H2:** $C^S_{\text{check}} < (\rho_0 - \rho_1)C^L_{\text{rerun}}$ на обоих датасетах с 95% CI.

### 7.6 E5 — TCO на реальных данных

**Цель:** заменить синтетический расчёт TCO (старая Таблица 4) наблюдаемыми измерениями. **Данные:** $N = 500$ задач разной длины контекста, B2 и B3. **Измерения:** входные и выходные токены каждой роли, число вызовов API, число перезапусков. $C_{\text{inf}}$ определяется по актуальным ценам, для которых фиксируются версия модели и дата измерения. **Экстраполяция:** к 10 000 задач/месяц с CI, *не* с точечной оценкой. **Анализ чувствительности:** изменение цены токена на $\pm 50\%$. **Критерий:** если даже нижняя граница CI $\Delta$TCO $< 0$, заявить выгоду нельзя.

## 8 Экономическая модель

### 8.1 Формализация TCO

$$TCO_{\text{month}} = C_{\text{inf}} + C_{\text{hw}} + C_{\text{energy}} + C_{\text{storage}} + C_{\text{ops}}. \tag{8}$$

Формула (8) задаёт структуру совокупной стоимости владения; её параметризация выполняется на основе измерений, описанных в E5.

### 8.2 Условия экономической целесообразности

- **Выгоден:** $|\mathcal{C}_0| > \tau^\star$; $|\mathcal{A}| \geq 3$; доля ошибок, выявляемых дешёвой процедурой самопроверки, $\geq 30\%$; отсутствует доминирующий параллелизм.
- **Не выгоден:** $|\mathcal{C}_0| < \tau^\star$; истинная независимость подзадач; требование изоляции привилегий на процесс; модель плохо удерживает ролевой формат (измеряется в E2b).

Количественная оценка этих режимов проводится в экспериментах E1, E3 и E5.

# 9 Ограничения и угрозы валидности

## 9.1 Когда внутренняя интроспекция хуже внешней оркестрации

1. **Истинная независимость подзадач.** Параллельный запуск нескольких вызовов большой модели даёт линейное ускорение по времени ответа; внутренний цикл является последовательным.
2. **Необходимость изоляции привилегий.** Выполнение недоверенного кода и работа с секретами требуют процессных границ между ролями, что исключает внутренний режим.
3. **Слабое следование ролевому формату.** Если модель не удерживает ролевые префиксы, критик фактически превращается в генератор с иной инструкцией, и архитектурное преимущество исчезает. Этот риск оценивается в E2b.
4. **Систематическая ошибка критика.** Критик, опирающийся на собственные генерации, может устойчиво одобрять ошибочные кандидаты. Основным механизмом защиты в этом случае остаётся внешняя верификация.
5. **Компрессия, удаляющая критически важный факт.** Алгоритм 2 может исключить редкий, но существенный фрагмент; поэтому в сжатом контексте обязательно сохраняются трассы с ошибками и API-сигнатуры.

## 9.2 Угрозы валидности

**Внутренняя валидность:** на результаты могут влиять выбор seed и дрейф API; для уменьшения этого эффекта фиксируются идентификаторы версий моделей и используется набор из пяти значений seed. **Внешняя валидность:** HumanEval содержит короткие синтетические задачи, поэтому перенос выводов на реальные задачи программной инженерии дополнительно проверяется на SWE-bench Lite в E4. **Конструктная валидность:** метрики $U_{\mathrm{tok}}$ и $Q_{\$}$ чувствительны к ценам токенов; этот фактор анализируется в E5 при вариации цен на $\pm 50\%$. **Статистическая валидность:** множественные сравнения учитываются поправкой Холма–Бонферрони, а при небольших $n$ основной упор делается на доверительные интервалы.

## 9.3 Область применимости выводов

Полученные теоретические выводы относятся к задачам программной инженерии с длинным общим контекстом и не переносятся автоматически на иные классы задач. Промежуточные ролевые тексты рассматриваются как вычислительный инструмент, а не как интерпретируемое объяснение поведения модели [9]. Наконец, конкретные гиперпараметры $K = 3$, $I = 3$ и $\lambda = 0.5$ используются как рабочая конфигурация и могут быть дополнительно оптимизированы в последующих исследованиях.

# 10 Направления дальнейшего исследования

Дальнейшее развитие работы связано прежде всего с полной эмпирической валидацией предложенной архитектуры и уточнением условий её применимости.

## 10.1 Ближайшие задачи

**R1.** Реализовать воспроизводимый прототип конфигураций B0 и B3 со сквозным запуском на HumanEval.

**R2.** Провести пилотное сравнение на HumanEval в соответствии с протоколом E1 и получить первые оценки pass@1, токенного расхода и стоимости.

**R3.** Выполнить абляционный анализ E2a–E2d, включая оценку роли компрессии, критика, процедуры самопроверки и чувствительности метрик.

**R4.** Уточнить разграничение с Self-Refine либо путём усиления теоретического анализа, либо через прямое эмпирическое сравнение по $U_{\text{tok}}$ на длинном контексте.

**R5.** Оценить TCO на реальных измерениях для выборки из $N = 500$ задач с доверительными интервалами и анализом чувствительности к ценам токенов.

**R6.** Калибровать веса таблицы 2 на основе экспертного опроса или дополнительных нормативных источников, сохранив анализ чувствительности.

## 10.2 Расширение экспериментальной программы

**R7.** Выполнить E3 и E4 в полном объёме и получить эмпирическую оценку порога $\tau^\star$ с доверительными интервалами.

**R8.** Расширить набор базовых конфигураций за счёт Reflexion [8], ReAct [6] и SWE-agent [17].

**R9.** Перенести оценку с SWE-bench Lite на SWE-bench Full на выборке не менее 300 задач.

**R10.** Провести экспертную оценку качества кода на подмножестве из 50 задач для валидации метрики $M_i$ относительно профессионального суждения.

**R11.** Исследовать механизмы распространения ошибки и сравнить влияние ошибочного критика в Hybrid-INoT и Classical-MAS.

## 10.3 Целевые результаты эмпирической проверки

Центральный тезис о преимуществе внутренней ролевой сегрегации при длинном общем контексте может считаться подтверждённым при одновременном выполнении следующих условий:

1. E1: $\Delta U_{\text{tok}}^{B3-B2} \geq 15\%$ на $|\mathcal{C}_0| > 2048$, $p < 0.05$ после Holm–Bonferroni.
2. E1: pass@1 B3 не хуже B2 в пределах допуска на неухудшение 2 п.п.
3. E2a: каждый из компонентов (компрессия, критик, самопроверка) даёт значимый независимый вклад.
4. E3: $\tau^\star$ конечен и $< 16\,384$.
5. E4: $C_{\text{check}}^{S} < (\rho_0 - \rho_1) C_{\text{rerun}}^{L}$ на обоих датасетах с 95% CI.
6. E5: $\Delta\text{TCO} < 0$ при нижней границе CI, устойчиво к $\pm 50\%$ ценам.
7. R4: доказательство или эмпирическая значимость против Self-Refine.

При неполном выполнении этих условий объём выводов должен соотноситься с фактически полученными результатами.

### 10.4 Фокус исследования

Дальнейшие исследования следует сосредоточить на формальном и эмпирическом разграничении Hybrid-INoT и внешней мультиагентной оркестрации по токенной эффективности в задачах программной инженерии с длинным контекстом. Система метрик поддерживаемости и TCO-анализ при этом выступают как вспомогательные компоненты общей исследовательской программы.

## 11 Заключение

Статья формализует Hybrid-INoT как промежуточную архитектуру между внутриконтекстной самокритикой и внешней мультиагентной оркестрацией. Для этой архитектуры заданы состояние системы, функция маршрутизации и внутренний ролевой цикл; получено утверждение о токенном преимуществе при длинном контексте и числе ролей не менее трёх, выведена верхняя оценка расхода токенов в худшем случае и предложено условие экономической эффективности малой модели самопроверки. Кроме того, разработана система метрик для оценки токенной эффективности, стоимости и поддерживаемости кода и сформирована программа эмпирической валидации, необходимая для количественной проверки теоретических выводов. В совокупности эти результаты задают формальную основу для дальнейшего сопоставления Hybrid-INoT с Classical-MAS и родственными подходами на задачах программной инженерии.

## References


[1] H. Sun and S. Zeng, “Introspection of Thought Helps AI Agents,” arXiv preprint arXiv:2507.08664, 2025.

[2] A. J. Ko, R. DeLine, and G. Venolia, “Information Needs in Collocated Software Development Teams,” in *Proc. 29th Int. Conf. Software Engineering*, 2007, pp. 344–353.

[3] C. Parnin and S. Rugaber, “Resumption Strategies for Interrupted Programming Tasks,” *Software Quality Journal*, vol. 19, no. 1, pp. 5–34, 2011.

[4] M. K. Goncalves, C. R. B. de Souza, and V. M. Gonzalez, “Collaboration, Information Seeking and Communication,” *J. Universal Computer Science*, vol. 17, no. 11, pp. 1529–1550, 2011.

[5] J. Wei *et al.*, “Chain-of-Thought Prompting Elicits Reasoning in Large Language Models,” in *NeurIPS*, vol. 35, 2022, pp. 24824–24837.

[6] S. Yao *et al.*, “ReAct: Synergizing Reasoning and Acting in Language Models,” *ICLR*, 2023.

[7] A. Madaan *et al.*, "Self-Refine: Iterative Refinement with Self-Feedback," *NeurIPS*, 2023.

[8] N. Shinn *et al.*, "Reflexion: Language Agents with Verbal Reinforcement Learning," *NeurIPS*, 2023.

[9] M. Turpin, J. Michael, E. Perez, and S. R. Bowman, "Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting," *NeurIPS*, 2023.

[10] G. Weiss, *Multiagent Systems*. MIT Press, 1999.

[11] M. Wooldridge, *An Introduction to MultiAgent Systems*, 2nd ed. Wiley, 2009.

[12] S. Hong *et al.*, "MetaGPT: Meta Programming for A Multi-Agent Collaborative Framework," *ICLR*, 2024.

[13] C. Qian *et al.*, "ChatDev: Communicative Agents for Software Development," *ACL*, 2024.

[14] T. Guo *et al.*, "Large Language Model based Multi-Agents: A Survey of Progress and Challenges," arXiv:2402.01680, 2024.

[15] C. Qian *et al.*, "Scaling Large Language Model-based Multi-Agent Collaboration," arXiv:2406.07155, 2024.

[16] C. E. Jimenez *et al.*, "SWE-bench: Can Language Models Resolve Real-World GitHub Issues?," *ICLR*, 2024.

[17] J. Yang *et al.*, "SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering," *NeurIPS*, 2024.

[18] M. Chen *et al.*, "Evaluating Large Language Models Trained on Code," arXiv:2107.03374, 2021.

[19] J. Austin *et al.*, "Program Synthesis with Large Language Models," arXiv:2108.07732, 2021.

[20] H. Jiang *et al.*, "LongLLMLingua: Accelerating and Enhancing LLMs in Long Context Scenarios via Prompt Compression," *ACL*, 2024.

[21] Z. Pan *et al.*, "LLMLingua-2: Data Distillation for Efficient and Faithful Task-Agnostic Prompt Compression," *ACL Findings*, 2024.

[22] H. Jia, E. T. Barr, and S. Mechtaev, "Compressing Code Context for LLM-based Issue Resolution," arXiv:2603.28119, 2026.

[23] Z. Bi *et al.*, "Iterative Refinement of Project-Level Code Context for Precise Code Generation with Compiler Feedback," arXiv:2403.16792, 2024.

[24] C.-Y. Su and C. McMillan, "Do Code LLMs Do Static Analysis?," arXiv:2505.12118, 2025.

[25] M. Sepidband, H. Taherkhani, S. Wang, and H. Hemmati, "Enhancing LLM-Based Code Generation with Complexity Metrics," arXiv:2505.23953, 2025.

[26] ISO/IEC 25010:2023, "Systems and software engineering — SQuaRE — Product quality model," ISO, 2023.

[27] T. J. McCabe, "A Complexity Measure," *IEEE Trans. Software Engineering*, vol. SE-2, no. 4, pp. 308–320, 1976.