

Hybrid-INoT: внутренняя ролевая сегрегация и внешняя проверка при генерации кода

Даниил Привезенцев^{1*}

^{1*} Национальный исследовательский университет «Высшая школа экономики», Москва, Россия.

Corresponding author(s). E-mail(s): daprivezentsev@edu.hse.ru;

Аннотация

Hybrid-INoT сочетает планирование, реализацию и критику внутри ответа с внешней исполняемой проверкой, чтобы сократить повторное взаимодействие с моделью при общем контексте. Формализуются одношаговое ядро и условный ресурсный баланс; ядро оценивается без компрессии и повторов по результатам проверки. В факторном эксперименте независимо варьируются обозначения этапов (нейтральные или ролевые) и число вызовов (один или три); операции и полный предоставленный контекст остаются одинаковыми. Дополнительно проверяется прямое решение. Для резервной случайной выборки из 200 задач BigCodeBench запланированы 1 000 генераций на GPT-5.4 mini со средним уровнем рассуждения. После задокументированного продолжения, ограниченного ранее неотправленными назначениями, получены и проверены исходными штатными тестами 996 программ; эталонные контроли прошли на 193 задачах. Качество составляет 44.56–48.70%. Разность качества ролей и нейтральных этапов равна -1.05 процентного пункта в одном вызове (описательный 95%-интервал [-4.71, +2.62]) и +1.04 [-3.11, +5.70] в трёх. Ни один из четырёх заранее заданных тестов не отклоняет нулевую гипотезу после поправки Холма. На полных ресурсных парах роли в одном вызове требуют на 8.76% меньше токенов и имеют на 18.45% меньшую оценку по API-тарифам; для трёх вызовов оценка затрат в 2.09–2.50 раза выше, чем для одного. Известный основной расход — 8 585 185 токенов и USD 14.20482; для трёх прерванных вызовов счётчики отсутствуют. Отдельно сохранены 400 программ разработки и 199 программ адаптации INoT. В отдельном эксперименте на 80 задачах получены все 320 программ: ролевые и нейтральные обозначения сопоставлены при оформлении заголовками и сплошным текстом. На 79 задачах с пригодными контролями разности ролей равны 0.00 и -1.27 пункта (оба Holm $p = 1$); отношения стоимости — 0.990 и 1.000, интервалы включают отсутствие разности. Дополнительные данные не дают

убедительного подтверждения прежнего снижения затрат. Проверены все десять назначений демонстрации SWE-bench на одной задаче; ни одно не даёт её решения. Полные ответы и штатные отчёты обосновывают ограниченный анализ компонентов, без доказательства неухудшения качества или общего преимущества внутренних ролей.

Ключевые слова: Hybrid-INoT, внутренняя ролевая сегрегация, внешняя проверка, токенная эффективность, факторный дизайн, генерация кода

1 Введение

Агент для разработки программ должен понять спецификацию, использовать относящиеся к задаче код и документацию, построить решение и проверить его тестами. Эти функции можно распределить между планировщиком, исполнителем и критиком. Если отдельные вызовы модели получают одни и те же материалы, контекст приходится передавать повторно. Мы исследуем, можно ли сохранить эти функции при меньшем числе вызовов, оставив проверку корректности внешним тестам.

Hybrid-INoT отвечает на этот вопрос сочетанием внутренней ролевой организации и внешнего слоя проверки. Планирование, реализация и критика предписываются в общем вызове модели, а внешняя процедура оценивает полученную программу. Дизайн развивает мотивацию внутреннего диалога INoT [2], но исследуемая ролевая конфигурация отличается от исходного алгоритма PromptCode. Она разделяет получение программы от модели и проверку её корректности. Длинный общий контекст мотивирует ресурсную модель, но сам по себе не гарантирует сохранения качества при одном вызове.

Исходная реализация Hybrid-INoT [9] включала также отбор контекста и избирательные повторы. Её сохранённое сравнение целых конфигураций меняло эти механизмы вместе с топологией вызовов и потому не выделяет вклад внутренних ролей. Настоящая оценка изолирует одношаговое ядро архитектуры: полный предоставленный контекст, один итоговый кандидат, предписанные планирование/реализация/проверка и последующее штатное тестирование. Компрессия и повторы по результатам проверки отключены. Раздельная оценка компонентов позволяет проверить проектные решения Hybrid-INoT в рамках исходной инженерной задачи.

У ядра есть два разных эмпирических вопроса. Полезны ли названия ролей при неизменных операциях этапов? Улучшает ли выполнение операций в одном ответе соотношение качества и ресурсов относительно их распределения по трём вызовам? Прямой решатель проверяет полезность поэтапной организации в целом. Отдельная адаптация INoT исследует родственную алгоритмическую альтернативу. Каждое условие получает одинаковую задачу и контекст и оценивается одной последующей процедурой. Самокритика модели не считается измеренным результатом проверки.

Вклад работы включает:

1. Операциональное описание одношагового ядра Hybrid-INoT, его состояния и границы внешней оценки с прямым соответствием каждому реализованному контролю.
2. Условный баланс токенов общего контекста, объясняющий возможность экономии при меньшем числе вызовов без предположения о равной длине выхода и без заявления измеренного порога длинного контекста.
3. Компонентное исследование 2×2 без компрессии и прямой решатель на 200 резервных случайных задачах BigCodeBench: 996 наблюдаемых программ, исходные тесты, четыре заранее заданных парных контраста качества и явный учёт пропусков.
4. Полный архив ответов, программ, отчётов и ресурсов, дополненный 400 отдельными программами разработки, 199 программами адаптации INoT и ограниченной штатной пробой репозиторных патчей.

Абляции ролей и исследования числа взаимодействий имеют близких предшественников; вклад заключается в определённой архитектурной оценке и её проверяемых данных, а не в изобретении ролевого сотрудничества. Основные результаты ограничивают проектный вывод: роли в одном вызове дают меньшее наблюдаемое среднее ресурсов, но неухудшение качества не установлено; три вызова требуют больше ресурсов без обнаруженного улучшения качества в четырёх запланированных тестах.

2 Связанные исследования

2.1 Ближайший методологический предшественник

В работе Self-collaboration Code Generation via ChatGPT [1] уже исследованы ролевые инструкции и максимум взаимодействий в разделах 5.2–5.3. Поэтому удаление ролей или изменение взаимодействий не заявляется новизной настоящего исследования. Таблица 1 разграничивает реализованные воздействия.

Добавленная ценность состоит в репликации и расширении с акцентом на проверяемость: совместный дизайн оценивает взаимодействие обозначений и топологии при одном интерфейсе генерации, а связь результатов штатных тестов с проверенными программами и компоненты токенов делают различия качества и ресурсов проверяемыми. Это новые эмпирические условия и набор доказательств, а не новый принцип ролевого сотрудничества или первая абляция ролей.

Для внешнего сравнения наиболее близок к вопросу об обозначениях метод Self-collaboration вместе с вариантом без ролей. Его реализация должна сохранять обратную связь и правило остановки; переименование нашего фиксированного трёхвызовного MR не воспроизводит этот метод. Отдельный пилот авторской реализации на трёх задачах описан в разделе 13.3; внешнее сравнение с достаточной мощностью и превосходство над SCC остаются непроверенными. В этой схеме D задаёт минимальное реализованное сравнение, а SN и MN служат контролями для выделения эффекта обозначений. INoT* отвечает на отдельный вопрос об алгоритме внутреннего диалога и поэтому не рассматривается как ближайший предшественник абляции ролей.

Таблица 1 Сопоставление с ближайшим предшественником [1], таблицы 3–4 и приложение В.1. Раунды взаимодействия и новые вызовы модели являются разными величинами.

Аспект	Self-collaboration	Настоящий эксперимент
Обозначения	Ролевые инструкции и инструкции без ролей	Одинаковые предложения об операциях; меняются только префиксы этапов
Взаимодействие	Цикл обратной связи; варьируется максимум взаимодействий	Один или три новых вызова; фиксированная последовательность, полная видимая история
Дизайн	Раздельные абляции ролей и взаимодействия	Совместная матрица обозначений и вызовов для каждой отобранной задачи
Задачи	HumanEval, MBPP и расширенные тесты	Резервная выборка BigCodeBench; эталонные и неправильные контроли до генерации

2.2 Внутренний диалог и репозиторные методы

INoT описывает компактные инструкции PromptCode для внутреннего диалога и рассуждения [2]. Это мотивирует оценку раскрытой адаптации алгоритма, тогда как отдельное минимальное воздействие обозначений проверяет, меняют ли результат сами названия ролей. Сравнения отвечают на разные вопросы: инструкция INoT изменяет процедуру рассуждения, а факторный контраст обозначений сохраняет предложения с описанием операций. Исходное сравнение Hybrid-INoT дополнительно изменяло компрессию и повторные попытки; его исторические записи сохраняются как контекст, а не объединяются с новым экспериментом.

Исследование одно- и многоагентных систем при сопоставимом бюджете токенов рассуждения подчёркивает различие дополнительных вызовов и вычислений [3]. Поскольку здесь длина завершения не ограничена общим жёстким бюджетом, токены и денежная оценка рассматриваются вместе с качеством как исходы реализованных протоколов; оптимальное распределение фиксированного бюджета инференса из этого дизайна не следует.

Agentless использует структурированный процесс локализации, исправления и проверки [4]; SWE-agent связывает модель с интерфейсом репозитория [5]. Обе системы добавляют поиск, инструменты и взаимодействие с окружением сверх генерации функций при фиксированном контексте. Их опубликованные оценки нельзя вставлять в парную матрицу с другими задачами и настройками. BigCodeBench [6] предоставляет разнообразные задачи с библиотечными зависимостями и исполнимыми тестами, а SWE-bench [7, 8] проверяет изменения репозитория тестами конкретных задач из трека ошибок. Штатная оценка связывает исходы с исполняемыми тестами, однако успешный эталонный контроль не разрешает каждое расхождение естественно-языковой инструкции и теста.

Исследования persona prompting мотивируют более узкое утверждение, чем универсальная польза ролей для рассуждения. Zheng и соавторы не обнаруживают устойчивого улучшения от системных персон в исследованных фактологических задачах [14]. Luz de Araujo и соавторы разделяют качество, устойчивость к несущественным атрибутам персоны и соответствие заданной специализации; результаты зависят от модели и задачи [15]. Эти работы не проверяют наши запросы на генерацию кода. Они обосновывают изменение обозначений при сохранении требуемых операций и ограничение вывода конкретными использованными обозначениями.

Данные о нескольких агентах также зависят от выбранного сравнения. Choi и соавторы связывают значительную часть выигрыша в своих NLP-экспериментах с независимым голосованием, отделяя обмен сообщениями от агрегации [16]. В то же время Wunderlich и соавторы находят конфигурации, в которых debate или mixture-of-agents улучшают соотношение вычислений и точности относительно self-consistency на MMLU-Pro и ВВН [17]. Это основание для условной оценки, а не универсального вывода за или против нескольких агентов. Наша нейтральная последовательная цепочка не является голосованием, смесью независимых моделей или ансамблем с выровненным бюджетом. В работе выполнена факторная проверка одной модели на исполняемом коде с сохранением трасс и учётом доступных счётчиков ресурсов; общее превосходство над перечисленными альтернативами не входит в оцениваемый эффект.

3 Формальная постановка и ядро Hybrid-INoT

3.1 Инженерная задача и наблюдаемый успех

Инженерная задача задаётся тройкой $(x, C_0, \mathcal{V})$: спецификацией x , фиксированным предоставленным контекстом C_0 и внешней процедурой проверки $\mathcal{V}$. Результат включает программу-кандидат y и запись её проверки. Генерация и проверка являются разными операциями: модель предлагает решение, а исходные исполняемые тесты определяют исход бенчмарка в контролируемом окружении. Текстовое утверждение о корректности не заменяет тесты. Для репозиторных задач C_0 обозначает раскрытый пакет найденных файлов, а не предположение о передаче всего репозитория.

Для протокола исполнения a инженерная цель состоит в повышении вероятности проверенного успеха при контроле ожидаемого числа токенов и денежной оценки генерации. Поэтому качество и ресурсы сообщаются совместно, без оптимизации непроверенного взвешенного показателя. Наблюдаемые программы, провалившие тесты, являются неудачами; недоступную генерацию или оценку нельзя превращать в проверенный успех либо вымышленный отказ тестов. Раздел 5 задаёт общий контроль оцениваемости и точный статистический исход.

3.2 Внутренняя ролевая организация и внешняя проверка

Hybrid-INoT разделяет функции: планирование, реализация и критика предписываются внутри ответа модели, а проверка выполняется вне модели. «Гибридность» означает сочетание внутренних инструкций с внешними исполняемыми доказательствами. Для неё не требуется обученный маршрутизатор. Исходная терминология `planner-worker-critic` соответствует исполняемым обозначениям `planner`, `implementer` и `reviewer`. Внутренняя ролевая сегрегация означает здесь разделение предписанных функций, а не независимо наблюдаемых скрытых агентов.

Исследуемое одношаговое ядро предписывает три операции: анализ требований и граничных случаев, реализацию по плану, затем проверку и исправление относительно требований. Один вызов модели получает все три инструкции и полный предоставленный контекст; он возвращает одну итоговую программу. Внешне наблюдаемой последовательности скрытых планов и оценок критика нет. Поэтому концептуальное разделение ролей не следует принимать за три измеренные внутренние подпрограммы. Точные запросы, включая требование к итоговому формату, сохранены в приложении.

В основном эксперименте SR представляет эту ролевую одновывозную конфигурацию. SN является её абстракцией обозначений ролей при одинаковых предложениях об операциях. MR и MN распределяют соответствующие операции по трём новым вызовам, а D полностью убирает поэтапную процедуру. Для всех пяти условий используется одинаковая последующая штатная оценка. Дизайн позволяет оценить, как предписание внутренних этапов влияет на результат по сравнению с простой инструкцией и что меняется при распределении тех же операций по отдельным вызовам. У Hybrid-INoT нет преимущественного доступа к проверке.

3.3 Состояние, исполнение и остановка

Наблюдаемое состояние исполнения задаётся как $\sigma_j = (x, \mathcal{C}_0, a, j, \mathcal{H}_j)$, где a фиксирует назначенное условие, j — номер вызова, а $\mathcal{H}_j$ содержит все полные предыдущие выведенные ответы. Конфигурация модели внутри сравнения фиксирована. Для SR и SN число вызовов $n_a = 1$; для MR и MN $n_a = 3$. В многовызовном условии $\mathcal{H}_j$ передаётся целиком. Предоставленный контекст не изменяется: $\hat{\mathcal{C}} = \mathcal{C}_0$. Условие назначается до генерации и потому не является политикой маршрутизации по результату.

Алгоритм 1 описывает этапы генерации и оценки эксперимента; штатный harness является последующим оценщиком, а не инструментом внутри вызова модели. Лимит времени и конечное n_a ограничивают попытки генерации. Это правило остановки, а не теорема о сходимости или корректности. Отклонённое завершение не вызывает автоматическую повторную попытку той же ячейки. Раскрытое продолжение касается только назначений, в которых ни один вызов не начинался.

Конфигурация фиксирует дополнительные механизмы исходной архитектуры: отбор контекста тождественный, режим назначен, итоговый кандидат один,




Рис. 1 Проверяемая конфигурация Hybrid-INoT и её вариант с отдельными вызовами. Штатная проверка выполняется после генерации и одинакова для условий; результаты тестов не возвращаются генерирующей модели. Нейтральные контроли и прямое решение определены в табл. 2.

повторные генерации по проверке отключены. Так вопрос о внутренних ролях можно проверить, не смешивая его с компрессией, малой проверяющей моделью и адаптивными повторами. Этим же определяется объём архитектурного свидетельства: эксперимент оценивает данное ядро, а не все возможные варианты применения Hybrid-INoT.

4 Аналитическая модель затрат на общий контекст

4.1 Условный баланс токенов

Архитектурная мотивация связана с повторной передачей общего материала. Рассмотрим аддитивную модель учёта, в которой общий блок задачи и контекста вносит S токенов при каждой передаче. Внутренняя конфигурация H передаёт его один раз; внешняя M — в каждом из t вызовов. Пусть J_H, J_M содержат все остальные входные токены, включая оболочки инструкций и передаваемые ответы, а O_H, O_M — все выходные токены. Обозначим $R_H = J_H + O_H$, $R_M = J_M + O_M$.

Алгоритм 1 Оцениваемая одношаговая генерация и последующий внешний аудит

Вход: Задача x , контекст C_0 , фиксированное условие a

Результат: Архивный ответ/кандидат и отдельно классифицированный исход

- 1: $\mathcal{H} \leftarrow \emptyset$
 - 2: **для** $j = 1, \dots, n_a$ **выполнить**
 - 3: Составить фиксированный запрос из $a, j, x, C_0, \mathcal{H}$
 - 4: Выполнить новый вызов; сохранить запрос, события и конечный статус
 - 5: **если** нарушены условия принятия завершения и учёта ресурсов **то**
 - 6: Сохранить доступные данные; отметить пропуск; остановить ячейку
 - 7: **конец если**
 - 8: Добавить полный выведенный ответ в $\mathcal{H}$
 - 9: **конец для**
 - 10: Извлечь единственную итоговую программу; ошибочный формат даёт пустую
 - 11: Зафиксировать архив генерации
 - 12: Выполнить исходные штатные тесты для каждого наблюдаемого кандидата
 - 13: Связать точные байты кандидата с нативными данными и контролями
 - 14: Записать успех, неуспех или недоступный исход и все известные счётчики
-

Тогда

$$T_H = S + R_H, \quad T_M = mS + R_M, \quad T_M - T_H = (m - 1)S + R_M - R_H. \quad (1)$$

Это тождество учёта при указанной модели блоков. Оно не предполагает равной длины выхода. В частности, более длинное внутреннее рассуждение может компенсировать сокращение передачи контекста; внешние промежуточные ответы учитываются как при генерации, так и при повторной передаче.

Утверждение 1 (Условное достаточное ресурсное преимущество). *Для $m > 1$ предположим, что $\mathbb{E}[R_H - R_M \mid S] \leq K$ во всём заданном диапазоне контекста, причём постоянная $K \geq 0$ не зависит от S в этом диапазоне. Из (1) следует*

$$\mathbb{E}[T_M - T_H \mid S] \geq (m - 1)S - K.$$

Поэтому ожидаемое преимущество внутренней конфигурации по токенам положительно при $S > K/(m - 1)$ внутри данного диапазона.

Доказательство Вычтем два баланса в (1), возьмём условное ожидание при S и применим предполагаемую верхнюю границу для $\mathbb{E}[R_H - R_M \mid S]$. $\square$

Ограничение остатка является содержательным предположением, а не измеренным свойством модели. Если выход или координационные затраты меняются с контекстом так, что граница нарушается, существование порога не следует. Условие сохраняет мотивацию Hybrid-INoT для длинного общего контекста, явно обозначая её пределы. В текущей выборке длина контекста не варьируется как

воздействие и K не оценивается; определить порог преимущества или маршрутизации по ней нельзя. Прежние пилоты с компрессией также не определяют эти величины.

Эмпирический реестр использует фактические счётчики поставщика,

$$T_a = \sum_{j=1}^{n_a} (I_{a,j} + O_{a,j}), \quad (2)$$

а не оценивает суммы по (1). Незвестный расход остаётся неизвестным. Концептуальный блок S не отождествляется с измеренным аддитивным разбиением входа поставщика: границы токенизации и накладные расходы клиента могут препятствовать такому разбиению. Это позволяет не выдавать теоретический баланс за наблюдаемую декомпозицию. При фиксированной топологии общий член сокращается между ролевым и нейтральным условиями; их ресурсная разность относится к изменениям из-за формулировок и другим остаточным различиям. Поэтому в дизайне предусмотрены оба контроля обозначений.

4.2 Качество и деньги как отдельные ограничения

Обозначим проверенный успех через $Q_a = \mathbb{E}[Y_t(a)]$, а ожидаемое число токенов через $\bar{T}_a = \mathbb{E}[T_a]$. Исходное инженерное понятие токеной полезности можно записать как $U_a = Q_a/\bar{T}_a$, используя отношение ожиданий на общей полностью наблюдаемой совокупности. Более высокое U_a может сочетаться с худшим Q_a и не подтверждает сохранение качества. Поскольку в исследовании различаются также доступные подвыборки качества и ресурсов, основной отчёт сохраняет отдельно парные разности качества и ресурсные отношения, не строя композитный рейтинг полезности и не назначая непроверенных весов сопровождаемости.

Денежный аналог должен учитывать тариф каждого компонента: входа, кешированного входа и выхода. Оценки V и V_0 по API-тарифам в разделе 5 реализуют это требование по сохранённым счётчикам. Преимущество по токенам само по себе не устанавливает денежного преимущества при различающихся долях кеша и выхода. Ни одна из оценок не измеряет счёт подписки или полную стоимость владения; вычисления оценщика, инженерная работа и эксплуатация лежат вне наблюдаемого модельного реестра.

Баланс мотивирует возможный механизм эффективности. Изменяется ли качество, полезны ли обозначения ролей и благоприятствует ли наблюдаемая ресурсная разность внутренней конфигурации — эмпирические вопросы следующего факторного эксперимента. Аналитическое объяснение не добавляет подтверждающей гипотезы к четырём тестам, зафиксированным до основного запуска.

5 Оценка компонентов: дизайн и оцениваемые эффекты

5.1 Факторный эксперимент без компрессии

Основной эксперимент оценивает ядро Hybrid-INoT и его контроли: независимо варьируются число вызовов модели (один или три) и обозначения этапов (нейтральные или ролевые). Таблица 2 определяет четыре факторных условия и прямой решатель. Во всех структурированных условиях предписаны одинаковые операции: анализ требований и граничных случаев, реализация по плану, затем проверка и исправление относительно требований. Ролевое воздействие заменяет обозначения «stage 1», «stage 2», «stage 3» на «planner», «implementer», «reviewer»; предложения с описанием операций остаются неизменными. При одном вызове все три инструкции предшествуют задаче. При трёх вызовах каждый получает инструкцию своего этапа, полный текст задачи, весь предоставленный контекст и все полные предыдущие видимые ответы. Итоговый формат одинаков: ровно один блок с полной программой Python. Прямой решатель получает только инструкцию реализации и требование к итоговому формату.

Таблица 2 Реализованные условия. Фактор числа вызовов включает передачу промежуточных ответов между новыми вызовами.

Код	Вызовы	Обозначения	Операции
D	1	Нет	Прямая реализация
SN	1	Нейтральные	План, реализация, проверка
SR	1	Ролевые	План, реализация, проверка
MN	3	Нейтральные	План, реализация, проверка
MR	3	Ролевые	План, реализация, проверка

Компрессия отсутствует во всех условиях. Такая постановка заменяет прежнее сравнение трёх вызовов без сжатия с одним сжатым вызовом, но не оценивает эффект прежнего компрессора. Контраст обозначений является воздействием на инструкцию, а не свидетельством независимых внутренних агентов. Контраст числа вызовов включает поток промежуточной информации и повторный инференс, а не только механическое изменение счётчика вызовов. Непроверенные маршрутизатор и дополнительная модель проверки исключены из заявленного метода.

Пусть $Y_t(a)$ показывает, прошла ли единственная итоговая программа для задачи t в условии a исходные тесты бенчмарка в проверенном окружении. Четыре заранее заданных парных эффекта качества имеют вид

$$\Delta_{R,1} = \mathbb{E}_t[Y_t(\text{SR}) - Y_t(\text{SN})], \quad \Delta_{R,3} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{MN})], \quad (3)$$

$$\Delta_{C,N} = \mathbb{E}_t[Y_t(\text{MN}) - Y_t(\text{SN})], \quad \Delta_{C,R} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{SR})]. \quad (4)$$

Каждая нулевая гипотеза задаёт нулевую разность качества. Описательное взаимодействие равно $\Delta_{R,3} - \Delta_{R,1}$. Ожидания относятся к выборке задач при реализованном протоколе и стохастической генерации, а не к свойству, независимому от поставщика модели. Оценки по доступным данным требуют полных пар; при пропусках без дополнительных предположений они характеризуют именно наблюдаемую подвыборку.

5.2 Распределение задач и отдельный этап разработки

Источник задач — BigCodeBench v0.1.4 [6]. Основная выборка содержит 200 новых идентификаторов из ранее зафиксированной случайной перестановки резервного пула с заданным начальным состоянием генератора. Взяты первые 200 допустимых идентификаторов в этом случайном порядке после исключения восьми примеров карточки набора данных (/0–/7), случайно просмотренных при проверке лицензии. Это не первые строки датасета и не отбор по сложности. Идентификаторы, точные входы модели и данные оценщика хешируются до контролей; неудачный контроль не приводит к замене задачи. Сорок задач разработки не пересекаются с этими 200. Этап разработки включает два обозначенных повтора и 400 программ, основная выборка — один новый повтор и 1 000 назначений. Последние дают не более 200 независимых единиц выборки, а не 1 000 независимых задач. Родственные задачи могут дополнительно уменьшать эффективную независимость. Публичность бенчмарка оставляет открытым вопрос о наличии задач в обучающих данных.

Назначение означает запланированную генерацию для заданной задачи, условия и повтора; начатое назначение считается попыткой. Каждой основной задаче назначены все пять условий. Четыре непересекающиеся группы по остатку индекса от деления на четыре содержат по 50 задач. В каждой группе зафиксированный псевдослучайный порядок определяет блоки задач и порядок условий; группу обрабатывают два работника, одновременно действует не более восьми экспериментальных процессов CLI. Полная матрица и хеши исходного кода закоммичены до отправки запросов. Модель не получает тесты бенчмарка, эталонные решения или результаты тестирования во время генерации. Метки повторов обозначают новые наблюдения по протоколу, а не случайные состояния модели у поставщика.

5.3 Генерация и полные доступные трассы

Используются запрошенный псевдоним модели `gpt-5.4-mini`, уровень рассуждения `medium` и официальный Codex CLI 0.153.4 с аутентификацией подписки ChatGPT [11, 13]. Опубликованный тариф позволяет проверить денежную оценку ресурсов; выбранная конфигурация является экономичным доступным вариантом для кода, но глобальный минимум цены не доказан. CLI изолирован от пользовательской конфигурации и инструкций репозитория. Инструменты, браузер, делегирование и выполнение тестов отключены. Каждый вызов создаёт новую временную сессию в пустом рабочем каталоге. Допустимая схема событий

требует ровно одного полного ответа и корректной записи использования; неожиданный инструмент, повтор или событие сжатия нарушают заданное текстовое условие.

Для каждого отправленного вызова сохраняются точный промпт, аргументы, поток событий, стандартный поток ошибок и конечное состояние. Для завершённых записей дополнительно сохраняются итоговый текст, компоненты числа токенов и хеши исходных файлов. Входы последующих вызовов реконструируются и побайтно сверяются с полными предыдущими доступными ответами. Доступность скрытых рассуждений поставщика не предполагается. Псевдоним модели не фиксирует неизменные веса; проверенное управление температурой и случайным состоянием модели отсутствует. На вызов установлен предел 180 секунд. Вход свыше 65 536 байт UTF-8 отклоняется, а не сокращается. Единственного жёсткого ограничения выходных токенов нет; длина ответа и потребление ресурсов являются результатами воздействия.

Исходное правило останавливает группу после первой неудачной попытки. Поэтому сетевые обрывы и превышения времени оставляют другие назначения неотправленными. Отдельная закоммиченная поправка, записанная до оценки или просмотра качества основной выборки, разрешает продолжить только такие неотправленные назначения. Любое назначение хотя бы с одним начатым этапом навсегда исключается из продолжения. Точный список оставшихся назначений и завершённый архив первой серии фиксируются до отправки; сохраняются промпты, настройки, ограничения времени и исходный порядок внутри группы. Явный сетевой обрыв или превышение времени завершает попытку без повтора; ошибки квоты, аутентификации и нераспознанные ошибки останавливают дальнейшую отправку. Первые попытки, продолжения и пропуски остаются различимыми. Таким образом, анализ использует заранее заданные контрасты при изменённом протоколе исполнения; это не неизменённый пререгистрированный запуск.

5.4 Штатная оценка и контроль оцениваемости

Неизменённый CLI BigCodeBench на коммите 09dd993f46c3 выполняет исходные тесты задач в режиме `instruct full`. Каждый запуск оценщика использует контейнер без сети, от непривилегированного пользователя, с основной файловой системой только для чтения, пределом памяти 3 ГБ, двумя CPU и двумя работниками оценщика. Подготовленные данные, точное дерево исходников, идентификатор образа, версии пакетов, автономные ресурсы, команды и штатные отчёты архивируются. Строгое извлечение выбирает единственный итоговый блок Python; нарушение формата даёт пустую наблюдаемую программу и отдельный признак ошибки формата, без выбора альтернативного ответа или исправления.

До генерации модели исходные эталонные и заведомо неверные программы проверены на всех 200 задачах. Изменения зависимостей ограничены этапом контролей, сохраняют предыдущие неудачные запуски и вызывают повторные контроли всей матрицы. Итоговое окружение пропускает 193 эталона и отклоняет все 200 неверных программ. Поэтому семь задач недоступны для оценки качества во всех условиях; их назначения и ресурсы генерации сохраняются в учёте.

Итоговый образ дополняет окружение разработки фиксированными зависимостями и автономными ресурсами NLTK. Штатная диагностика эталонов содержит ошибки DNS (/101, /590), отсутствие TensorFlow (/418), неподдерживаемый аргумент кодировщика (/686), проверки моментов вырожденной выборки (/276) и проверки архива/журнала (/14, /1028). Последующая проверка без изменения образа подтверждает отсутствие внешних команд, используемых последними двумя задачами; связь этих отказов с отсутствием команд является диагностическим выводом по исходникам. Позднейшая диагностика не меняет зафиксированный контроль оцениваемости. Контроли устанавливают оцениваемость и различение заведомо неверного решения, но не полную семантическую согласованность инструкции и теста.

Оценщику передаются только реально полученные программы. Каждый результат связывается с точной архивной программой, исходным идентификатором задачи и проверенным окружением; незавершённые запуски оценщика и противоречивые отчёты не могут давать наблюдения качества. Исходный штатный статус хранится рядом с отдельным аналитическим статусом с учётом контроля оцениваемости. Для отсутствующей генерации не создаётся фиктивный отказ тестов. Одинаковый контроль применяется ко всем условиям и поисковой репликации INoT.

5.5 Статистический анализ, пропуски и оценка ресурсов

Для каждого из четырёх запланированных контрастов качества приводятся число полных пар, оба числа несогласованных исходов, средняя парная разность, точный двусторонний биномиальный тест Мак-Немара и скорректированное по Холму p для семейства четырёх тестов при $\alpha = 0.05$. Только эти четыре теста Мак-Немара определяют основное семейство проверок; бутстрэп-интервалы и тесты смены знаков не служат критерием основного отклонения гипотезы. Процентильные интервалы используют 10 000 бутстрэп-выборок задач с начальным состоянием анализа 20260908; эти описательные интервалы не являются одновременными интервалами. Взаимодействие, ресурсные контрасты и сравнения с прямым решателем остаются описательными. Взаимодействие использует задачи с полными наблюдениями во всех четырёх факторных условиях; оно может не совпадать с вычитанием двух отдельно оценённых ролевых контрастов, если их доступные подвыборки различаются. Повторы разработки усредняются внутри задачи в отдельном описательном анализе и не объединяются с основными тестами.

При 200 независимых оцениваемых задачах наихудшая нормальная 95%-полуширина для одной доли приблизительно равна 6.9 процентного пункта. Это обоснование точности, а не расчёт 80%-мощности для парного эффекта; неопределённость парной разности зависит от несогласованных исходов. Приемлемая потеря качества для конкретного применения не получила внешнего обоснования, поэтому граница неухудшения и решение о сохранении качества не используются. Порог, выбранный только под статистическую точность, не устанавливал бы практически приемлемую потерю. Качество условия оценивается по доступным наблюдениям и сопровождается границами пропусков по всем назначениям:

недоступные исходы считаются сначала всеми неудачами, затем всеми успехами. Эти границы не являются доверительными интервалами или поправкой при случайных пропусках.

Завершённый вызов CLI возвращает счётчики входа I , кешированного входа C и выхода O . Кешированный вход входит в общий вход; отдельно доступное число токенов рассуждения входит в выход. Повторного суммирования нет. Опубликованные стандартные тарифы API составляют соответственно USD 0.75, 0.075 и 4.50 за миллион токенов [12]. Рассчитываются

$$V = \frac{0.75(I - C) + 0.075C + 4.50O}{10^6}, \quad V_0 = \frac{0.75I + 4.50O}{10^6} \quad \text{USD.} \quad (5)$$

V — контрфактическая оценка измеренных токенов подписки по прейскуранту API, а не платёж или счёт; V_0 — анализ чувствительности без скидки за кеш. Обе оценки исключают работу исследовательских ассистентов, разработку кода, сборку окружения и вычисления оценщика. Средние ресурсы программы суммируют её завершённые вызовы. Отдельный реестр включает доступные счётчики прерванных программ и явно считает вызовы без итогового учёта; неизвестное использование не заменяется нулём. Отношения ресурсов используют одну и ту же подвыборку полных пар в числителе и знаменателе. «Меньшая наблюдаемая стоимость» означает отношение парных средних оценок ниже единицы, то есть отрицательную среднюю парную разность. Это описательный критерий: подтверждающий денежный порог и совместное правило решения о качестве и стоимости заранее не задавались; ресурсные интервалы не устанавливают денежное превосходство. Время отправки и состояние кеша могут влиять на денежную оценку, особенно между отдельно запущенными сериями.

6 Поисковая репликация алгоритма INoT

Четыре сконструированных факторных условия не подменяют опубликованный метод. Поэтому отдельно зафиксирована промптовая репликация INoT [2], обозначенная INoT*. Она использует те же 200 задач, полный предоставленный контекст, GPT-5.4 mini medium, итоговый формат и контроль оцениваемости. На задачу приходится один новый вызов, работают два работника с тем же пределом 180 секунд. Независимо сформулированная инструкция PromptCode описывает двух виртуальных участников, исходные ответы, взаимные аргументы, критику, возражения, обновления и проверку согласия с пределом десять раундов. Это концептуальная инструкция для модели, а не код, исполняемый на компьютере, или проверенная последовательность скрытых взаимодействий агентов.

Правило остановки следует текстовому описанию исходной статьи: согласие либо предел раундов. Соответствующий исходный листинг содержит неоднозначное условие цикла и не задаёт итоговый ответ при отсутствии согласия. В этой репликации явно возвращается последний ответ виртуального участника А. Дополнение изображениями исключено для текстовых задач. Точная независимо

сформулированная инструкция архивируется. Проверенная исполняемая авторская реализация для данной постановки не найдена; подтверждение адаптации авторами не заявляется.

Независимое административное продолжение использует то же правило «только ещё не отправленные»: начальная попытка с превышением времени не повторяется, а оставшиеся 137 нетронутых назначений фиксируются и отправляются по одному разу. Все трассы первой серии и продолжения хранятся отдельно. Сравнения INoT* с D и SR являются поисковыми и не входят в четыре основных теста. Парность контролирует состав задач, но отдельная серия сохраняет различия времени отправки, состояния кеша и возможного изменения модели у поставщика. Наблюдаемый результат характеризует эту раскрытую адаптацию, а не точное воспроизведение чисел исходной статьи.

7 Основные результаты

7.1 Назначения, наблюдаемые исходы и пропуски

Отправлены все 1 000 назначений и 1 800 запланированных ходов. Первая попытка завершила 457 из 460 отправленных ячеек; отдельно зафиксированное продолжение — 539 из 540 ранее не затронутых. Четыре ячейки остались незавершёнными: D на /1028 и SN на /388 после сетевых обрывов, SN на /249 после превышения времени в первой попытке и SN на /1028 после лимита продолжения. Последний прерванный поток содержит завершённый ответ и счётчики, но терминальный статус нарушает критерий приёма в 180 секунд. Поэтому ответ не принят как наблюдаемая программа. Время поступления событий независимо не зафиксировано; дополнительная последовательность событий из терминального результата не выводится.

Нативный модуль проверил все 996 наблюдаемых программ. Общий эталонный фильтр оставляет 963 оцениваемых исхода: 453 успеха, 507 неудач и три нативных превышения времени. Остальные 33 программы относятся к задачам с неработающим эталонным контролем. Две ошибки извлечения формата, D /494 и MR /100, сохранены как пустые наблюдаемые программы вместе с исходными ответами. Неудачи генерации, нативные таймауты, ошибки формата и недоступные контроли различаются в архиве и полном приложении исходов.

Таблица 3 показывает наблюдаемые доли и их крайние границы на всех назначениях. Пять основных условий дают 44.56–48.70% успеха, оставляя возможность как улучшения, так и ухудшения. Меньший знаменатель SN обусловлен двумя пропусками генерации на оцениваемых задачах; оба пропуска /1028 совпадают с недоступным эталонным контролем. Строка INoT* относится к отдельной исследовательской серии, рассматриваемой далее.

7.2 Четыре заранее заданных контраста качества

Таблица 4 и рис. 2 показывают парные разности. Роли в одном вызове дают шесть выигрышей и восемь проигрышей относительно нейтральных этапов на 191 оцениваемой паре. В трёх вызовах наблюдаются десять выигрышей и восемь

Таблица 3 Основная выборка: по 200 назначений на условие. Качество рассчитано по наблюдаемым оцениваемым программам; границы учитывают все 200 назначений и не являются доверительными интервалами. INoT* — отдельная поисковая репликация алгоритма.

Усл.	Получено	Прошло	Доля (%)	Границы (%)	Формат, ошибки
D	199	94/193	48.70	47.00–50.50	1
SN	197	93/191	48.69	46.50–51.00	0
SR	200	92/193	47.67	46.00–49.50	0
MN	200	86/193	44.56	43.00–46.50	0
MR	200	88/193	45.60	44.00–47.50	1
INoT*	199	96/192	50.00	48.00–52.00	0

проигрышей на 193 парах. Ни одно сравнение не свидетельствует об улучшении качества после коррекции. Два контраста топологии также не отклоняют нулевую гипотезу: минимальное скорректированное p равно 0.3134 для MN против SN. Описательное взаимодействие четырёх условий составляет +2.09 процентного пункта с интервалом $[-4.19, +8.38]$ на общем подмножестве 191 задачи.

Эти результаты не устанавливают эквивалентность качества. В частности, интервал SR минус SN допускает потерю 4.71 пункта. Поэтому наблюдаемое снижение ресурсов не устанавливает экономию с сохранением качества. Неотклонение остальных гипотез также оставляет улучшения и потери совместимыми с наблюдаемой неопределённостью.

Таблица 4 Четыре заранее заданных сравнения качества при изменённом протоколе исполнения. Разности и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах. W/L — несогласованные пары в пользу первого/второго условия. Поправка Холма применяется к точным двусторонним тестам Мак-Немара по четырём сравнениям.

Контраст	Пары	Разность [интервал]	W/L	p	p_{Holm}
SR - SN	191	-1.05 $[-4.71, +2.62]$	6/8	0.7905	1.0000
MR - MN	193	+1.04 $[-3.11, +5.70]$	10/8	0.8145	1.0000
MN - SN	191	-4.71 $[-9.42, +0.00]$	6/15	0.0784	0.3134
MR - SR	193	-2.07 $[-6.22, +2.07]$	7/11	0.4807	1.0000

7.3 Измеренные ресурсы и чувствительность к тарифу

Завершённые кандидаты используют 8 569 456 токенов с суммарной оценкой USD 14.1467676. Журнал отправленных ходов дополнительно сохраняет 15 729 известных токенов прерванного вызова продолжения. Поэтому известный расход всех отправленных вызовов равен 8 585 185 токенам: 5 776 714 входным, включая 4 097 536 кешированных, и 2 808 471 выходному, включая 2 076 742 reasoning. Для




Рис. 2 Парные разности качества в процентных пунктах с описательными 95%-интервалами бутстрэпа по задачам. Линия соответствует нулю; тесты с поправкой Холма приведены отдельно в табл. 4.

1 797 вызовов со счётчиками оценка составляет USD 14.2048182, без кеш-скидки — USD 16.970655. У трёх прерванных вызовов расход неизвестен; известная сумма не является полным учётом потребления. Ни одна оценка не является списанием с подписки.

Таблица 5 содержит средние по завершённым кандидатам. Парные сравнения в табл. 6 используют общее подмножество внутри каждого ресурсного контраста. Для SR против SN доступны 197 пар: на 8.76% меньше токенов и на 18.45% ниже оценка стоимости, средняя разность USD -0.0019761 [-0.0027617, -0.0012296]. Без кеш-скидки оценка остаётся ниже на 16.21%. В этой серии ресурсное различие обозначений сохраняется при удалении кеш-скидки, хотя его величина меняется. Ресурсные интервалы описательны и не входят в четыре теста качества.

В трёх вызовах отношение стоимости MR/MN равно 0.985, а интервал средней разности пересекает ноль. Поэтому ресурсный результат одного вызова не переносится уверенно на другую топологию. Напротив, MN/SN и MR/SR требуют в 2.84 и 3.06 раза больше токенов и имеют в 2.09 и 2.50 раза большую стоимость; без кеш-скидки отношения равны 2.19 и 2.56. Полные повторно переданные входы и промежуточные ответы входят в измеренный расход. Рисунок 3 разделяет кешированный вход, остальной вход и выход без двойного подсчёта reasoning.

8 Исследовательские сравнения и этап разработки

Прямое решение имеет наименьшие наблюдаемые средние значения расхода токенов и стоимости среди пяти основных условий. Для SN минус D парная разность качества равна нулю [-4.19, +4.19] на 191 задаче, но отношение стоимости составляет 1.632 на 197 ресурсных парах. MR минус D даёт -3.11 [-7.77, +1.04] и стоит в 3.359 раза дороже на 199 ресурсных парах. Эти описательные сравнения показывают, зачем в эксперименте нужен прямой метод сравнения, но не устанавливают его статистическое доминирование.

Таблица 5 Средние ресурсы завершённых программ, включая задачи с отказом эталона. Денежные оценки даны в эквиваленте API, USD; чувствительность без кеша убирает скидку за кеш входа. Использование прерванных попыток дополнительно приведено в реестре отправленных вызовов.

Усл.	Программы	Токены	USD	Без кеша, USD
D	199	4 160	0.00655	0.00814
SN	197	5 122	0.01071	0.01230
SR	200	4 703	0.00888	0.01044
MN	200	14 578	0.02257	0.02714
MR	200	14 382	0.02222	0.02676
INoT*	199	3 858	0.00532	0.00670

Таблица 6 Описательные парные ресурсные контрасты. Отношения делят парные средние; 95%-интервал бутстрэпа по задачам относится к средней парной разности в эквиваленте API, USD, а не к отношению.

Контраст	Пары	Токены, отн.	USD, отн.	Разность USD [интервал]
SR - SN	197	0.912	0.816	-0.0020 [-0.0028, -0.0012]
MR - MN	200	0.987	0.985	-0.0003 [-0.0016, +0.0008]
MN - SN	197	2.839	2.088	+0.0117 [+0.0104, +0.0130]
MR - SR	200	3.058	2.504	+0.0133 [+0.0121, +0.0147]




Рис. 3 Средние компоненты токенов на завершённого кандидата. Кешированная часть отделена от остального входа; выход включает reasoning. Знаменатели включают задачи с недоступным эталоном. INoT* — отдельно выполненная адаптация.

Независимая адаптация INoT* завершает 199 из 200 назначенных программ при одном исходном превышении времени и без ошибок извлечения формата. Из 192 оцениваемых исходов 96 успешны (50%); границы доли успехов по всем назначениям — 48–52%. Известный расход равен 767 679 токенам и USD 1.05886035 (USD 1.33326675 без кеш-скидки); у одного вызова счётчики отсутствуют. Относительно D парная разность качества равна +1.04 [−3.65,+5.73], отношение стоимости — 0.805; относительно SR значения составляют +2.08 [−2.08,+6.25] и 0.600. Таблица 7 сохраняет разные числа пар качества и ресурсов. Адаптация исполнялась отдельной серией, поэтому время, кеш и изменения провайдера остаются потенциальными смешивающими факторами. Это не репликация авторского кода и не часть семейства четырёх тестов. Рисунок 4 показывает наблюдаемые средние на общей шкале без заявления статистически установленной границы эффективности.

Таблица 7 Поисковые сравнения вне семейства четырёх тестов. Интервалы — описательный 95%-бутстрэп по задачам. Для качества и ресурсов указаны отдельные числа полных пар. INoT* запущен отдельной серией.

Контраст	Пары Q/R	Качество [интервал]	Токены, отн.	USD, отн.
SN - D	191/197	+0.00 [−4.19,+4.19]	1.230	1.632
MR - D	193/199	−3.11 [−7.77,+1.04]	3.444	3.359
INoT* - D	192/198	+1.04 [−3.65,+5.73]	0.925	0.805
INoT* - SR	192/199	+2.08 [−2.08,+6.25]	0.821	0.600




Рис. 4 Наблюдаемые доли успеха и средняя оценка по API-тарифам. Полная шкала качества 0–100% не преувеличивает небольшие различия. Знаменатели точек различаются; парная неопределённость приведена в табл. 4 и 7.

9 Отдельная проверка на этапе разработки

Этап разработки предшествует основной выборке и использует 40 непересекающихся случайно выбранных задач, те же пять условий и два новых повтора с метками 2 и 3. Все 400 назначенных программ и 720 ходов CLI завершены и прошли аудит трасс. Полные 400 нативных записей соответствуют точным экспортированным программам. Эталон задачи /1005 не проходит тесты в среде разработки: остаётся 390 оцениваемых попыток на 39 задачах, а расход её десяти генераций продолжает учитываться. Ошибок извлечения итогового формата нет. Каждая попытка оценивается отдельно, без выбора лучшей из двух. Для парных контрастов разработки два повтора усредняются внутри задачи до ресэмплирования.

Таблица 8 Результаты на выборке разработки: по 80 назначений на условие, два повтора на 40 задачах. Качество рассчитано по 78 оцениваемым попыткам, ресурсы — по всем 80. Границы пропусков относятся ко всем назначениям и не являются доверительными интервалами.

Усл.	Прошло	Доля (%)	Границы (%)	Токены	USD	Без кеша
D	42/78	53.85	52.50–55.00	4 500	0.00776	0.00939
SN	34/78	43.59	42.50–45.00	5 598	0.01251	0.01417
SR	39/78	50.00	48.75–51.25	5 189	0.01070	0.01234
MN	39/78	50.00	48.75–51.25	15 636	0.02624	0.03090
MR	36/78	46.15	45.00–47.50	15 375	0.02543	0.03030

Наблюдаемые доли успеха лежат между 43.59% и 53.85%. D проходит 42/78 попыток, SR и MN — по 39/78, MR — 36/78, SN — 34/78. У D также наименьший средний расход. Полная генерация использует 3 703 821 токен с оценкой USD 6.6113451, либо USD 7.7687595 без скидки за кеш. Знаменатель составляет 40 кластеров задач для ресурсов и 39 для контрастов качества.

Таблица 9 Парные сравнения на выборке разработки. Разности качества и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах для 39 полных пар; отношения ресурсов — для 40 задач. Последние два сравнения поисковые. Подтверждающие р-значения и тест неухудшения не применяются.

Контраст	Разность качества [интервал]	Токены, отн.	USD, отн.
SR - SN	+6.41 [+1.28, +11.54]	0.927	0.855
MR - MN	−3.85 [−11.54, +2.56]	0.983	0.969
MN - SN	+6.41 [−2.56, +15.38]	2.793	2.097
MR - SR	−3.85 [−8.97, +1.28]	2.963	2.377
SN - D	−10.26 [−19.23, −2.56]	1.244	1.613
MR - D	−7.69 [−17.95, +1.28]	3.417	3.277

Разности «роли минус нейтральные обозначения» на этапе разработки равны +6.41 процентного пункта в одном вызове и −3.85 в трёх. Разность разностей составляет −10.26 пункта с описательным бутстрэп-интервалом $[-19.23, -1.28]$. Трёхвызовные условия используют в среднем в 2.79 и 2.96 раза больше токенов, чем соответствующие одновызовные; отношения условной стоимости равны 2.10 и 2.38. Эти наблюдения разработки мотивировали отдельное назначение отложенных задач. Они не добавляются к наблюдениям семейства четырёх основных тестов и не заменяют результат основной выборки. Все исходы двух повторов сохранены в приложении и публичном архиве.

10 Иллюстративные случаи расхождения

Эти четыре примера отобраны после генерации по зафиксированному детерминированному правилу: для каждого контраста меток выбиралась задача с наименьшим числовым идентификатором в каждом направлении расхождения, если обе программы были получены и прошли критерии допуска. Примеры являются описательными и не входят в четыре основных теста. Они не оценивают частоты расхождений и не позволяют устанавливать скрытый механизм рассуждения.

Для `BigCodeBench/428` ролевая программа в режиме одного вызова прошла тесты, а нейтральная нет. Обе программы выполняли требуемое внешнее объединение и масштабирование числовых признаков из `df1`. Ролевая программа сначала масштабировала копию `df1`, а затем выполняла одно объединение, сохраняя сначала столбцы левого датафрейма. Нейтральная программа сначала выполняла объединение, а затем удаляла и вставляла масштабированные столбцы вторым объединением; результат имел порядок `id, feature4, feature5, feature1, feature2, feature3`. В тесте `test_case_1` требовался порядок `id, feature1, feature2, feature3, feature4, feature5`, поэтому возникло расхождение списков. В условии описаны операции, но порядок столбцов прямо не задан; этот конкретный контракт задаётся тестом.

Для `BigCodeBench/71` нейтральная программа в режиме одного вызова прошла тесты, а ролевая нет. Ролевая реализация использовала выборочное стандартное отклонение, `Series.std(ddof=1)`, тогда как нейтральная реализация и эталонное решение использовали генеральное стандартное отклонение, `np.std` с `ddof=0`. Ролевая программа завершилась ошибками в `test_case_2`, `test_case_3`, `test_case_4` и `test_case_5`; зафиксированные расхождения составили соответственно 11.900380145988935 и 11.017611134090766, 8.568005268772557 и 8.01463505095522, NaN и 0.0, а также 47.95684491664328 и 46.07544623291379. В тексте задания не уточнена степень свободы, тогда как исполняемый контракт однозначно требует генеральное стандартное отклонение.

Для `BigCodeBench/167` ролевая программа в режиме трёх вызовов прошла тесты, а нейтральная нет. Нейтральная реализация выбирала `max(2, min(5, num_types))` сегментов. Поэтому при `num_types=10` она создавала 50 патчей, а при `num_types=1` — 2; ролевая реализация использовала ровно `num_types` сегментов и создавала 100 и 1 патч соответственно. В отчёте штатного

оценщика указаны ошибки `test_case_3`, $50 \neq 100$, и `test_case_4`, $2 \neq 1$. Условие требует категории и сегментированные значения, но не задаёт число сегментов явно; тест требует равенства числа сегментов `num_types`.

Для `BigCodeBench/31` нейтральная программа в режиме трёх вызовов прошла тесты, а ролевая нет. Нейтральная реализация сохраняла порядок первого появления элементов в `Counter`; ролевая сортировала элементы сначала по убыванию частоты, а затем лексикографически. В тестовой строке `$is` встречается три раза, `$second` — один раз, а `$sentence` — два раза; тест ожидает значения 3, 1, 2 в порядке первого появления категорий. Сортировка перемещала `$sentence` перед `$second`, и в `test_case_2` было получено сообщение “Expected value ‘1.0’, but got ‘2.’” Условие требует график частот, но не задаёт порядок категорий, поэтому это расхождение исполняемого порядка, а не свидетельство причинного эффекта ролей.

Описания основаны только на архивных запросах, программах и проверках штатного оценщика. Они фиксируют наблюдаемое поведение кода и не делают выводов о скрытом рассуждении, латентных агентах или репрезентативных частотах в совокупности задач.

11 Независимая проверка устойчивости к оформлению этапов

Основной контраст SR–SN операционализирует ролевую организацию заменой обозначений. Дополнительный проспективный эксперимент проверяет устойчивость такого сравнения при другом, явно контролируемом оформлении инструкций. Все условия используют один новый ответ; ролевые обозначения (`planner`, `implementer`, `reviewer` либо `stage 1`, `stage 2`, `stage 3`) скрепляются с заголовками в квадратных скобках на отдельных строках либо обозначениями с двоеточием в одном абзаце. Внутри каждого оформления меняются только три обозначения; между оформлениями сохраняются предложения с операциями и их порядок. Общая инструкция требует внутреннего анализа, реализации и проверки и запрещает комментарии об этапах в ответе. Каждый кандидат должен быть одной полной программой в блоке Python. Топология вызовов и компрессия не варьируются.

Такое воздействие изолирует замену ролевых обозначений при каждом оформлении, но не удостоверяет выполнение отдельных внутренних ролей: соблюдение этапов и приватные вычисления модели ненаблюдаемы. Поэтому сравнение оформлений относится к видимой структуре инструкции, а не к независимым агентам или раздельному доступу к информации. Сохранение эффекта обозначений при обоих оформлениях усилило бы вывод об устойчивости данной реализации; смена направления или широкий интервал ограничивали бы такой вывод. Дополнительные данные не включаются в исходное семейство четырёх тестов.

Выборка содержит следующие 80 идентификаторов в ранее рандомизированном резервном порядке после исключения всех 200 основных задач, 40 задач

разработки и восьми раскрытых примеров карточки датасета. Механический отбор предшествует генерации. Каждая задача получает четыре условия: всего 320 назначений и не более 80 парных единиц. Закреплённый порядок блоков задач чередует условия при четырёх параллельных вызовах. Сохраняются GPT-5.4 mini, medium reasoning, Codex CLI 0.153.4, новые эфемерные вызовы через подписку, полный предоставленный контекст и отключённые инструменты. Лимит вызова составляет 600 секунд, ограничение входа — 65 536 байт; запросы не сокращаются, кандидаты не запускаются повторно. Лимит времени отличается от основной серии, поэтому дополнительные оценки приводятся отдельно.

Исходники штатного BigCodeBench и тесты не меняются. До генерации недостающие зависимости и старые библиотечные интерфейсы восстанавливаются в отдельно сохранённых образах и полных контрольных запусках. Итоговый образ проходит все 80 эталонных программ; неправильный контроль отклоняется на 79 задачах, но проходит на BigCodeBench/59. Эта задача остаётся назначенной и проверяется во всех условиях, однако качество по ней считается недоступным из-за контроля. Поэтому итоговый контроль допускает не более 79 пар для качества. Сохранены все неудачные контроли, версии пакетов и идентификаторы образов; эталонные программы, тесты и идентификаторы задач не заменяются. Процессы генерации не получают материалы оценщика.

Заранее заданное основное семейство содержит два точных двусторонних теста Мак-Немара: роли против нейтральных обозначений отдельно для заголовков и абзаца, с коррекцией Холма при семейном $\alpha = 0.05$. Контрасты заголовков с абзацем и разность двух ролевых контрастов являются описательными. Бутстреп-интервалы используют 10 000 повторных выборок задач и seed анализа 20260908. Ресурсы представлены парными разностями токенов, условной API-стоимости и отношениями парных средних; критерий эквивалентности, неухудшения или совместного выигрыша качества и стоимости не вводится. До генерации выполнен точный расчёт мощности при консервативном первом пороге Холма 0.025 для разных долей дискордантных пар и размеров эффекта. Выборка не обладает высокой мощностью для исключения малых эффектов; это ограничение сохраняется независимо от наблюдаемого результата. Окончательный исполняемый план опубликован до запуска в коммите 24ba687.

11.1 Полная проверка и эффекты обозначений

Все 320 запланированных генераций дали полные программы и результаты штатной проверки: повторных генераций, пропусков и превышений времени оценки нет. Среди 316 исходов с пригодными контролями 173 успешны и 143 неуспешны. Четыре исхода задачи /59 сохранены в полном приложении (три успеха и один провал), но не входят в статистику качества. Таблица 10 содержит итоги четырёх условий.

При заголовках роли и нейтральные этапы решают по 44 из 79 пригодных задач (55.70%); парных побед и поражений по три. В сплошном тексте роли решают 42 задачи (53.16%), нейтральные этапы — 43 (54.43%), при пяти победах и шести поражениях. Разности ролей равны соответственно 0.00 процентного пункта, описательный 95% интервал [-6.33,+6.33], и -1.27 [-10.13,+6.33]. Оба точных

Таблица 10 Независимое дополнение на 80 задачах. RB/NB: ролевые/нейтральные обозначения с заголовками; RP/NP: те же обозначения в абзаце. V — средняя стандартная условная API-стоимость наблюдаемого кандидата, а не платёж.

Режим	Получено	Успех/оценено	Успех (%)	Токены	V (USD)
RB	80/80	44/79	55.70	4415	0.007244
NB	80/80	44/79	55.70	4431	0.007320
RP	80/80	42/79	53.16	4331	0.006881
NP	80/80	43/79	54.43	4331	0.006884

Таблица 11 Два заранее заданных ролевых контраста. Разности и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах. W/L — дискордантные пары; поправка Холма охватывает оба точных двусторонних теста Мак-Немара.

Контраст	Пары	Разность [интервал]	W/L	p	p_{Holm}
RB - NB	79	+0.00 [-6.33, +6.33]	3/3	1.0000	1.0000
RP - NP	79	-1.27 [-10.13, +6.33]	5/6	1.0000	1.0000

двусторонних теста Мак-Немара имеют исходное и скорректированное по Холму $p = 1$ (табл. 11). Широкие интервалы не устанавливают эквивалентность и не исключают содержательно значимый эффект качества.

Описательные разности заголовков относительно сплошного текста составляют +2.53 пункта [-5.06, +10.13] при ролях и +1.27 [-6.33, +8.86] при нейтральных обозначениях. Их взаимодействие равно +1.27 [-10.13, +12.66]. Ни сравнения ролей, ни оценки оформления не устанавливают преимущества по качеству. Проверяется наблюдаемая инструкция, а не фактическое возникновение независимых внутренних ролей.

11.2 Ресурсы и связь с основным экспериментом

Счётчики доступны для всех 320 вызовов: 932 812 входных токенов, включая 797 696 кешированных, и 467 794 выходных, включая 373 494 reasoning. Общий расход — 1 400 606 токенов, оценка по стандартным API-тарифам — USD 2.2662372, чувствительность без кеш-скидки — USD 2.804682. Это оценка подписочных вызовов, а не платежи за API.

Для ролей относительно нейтральных этапов при заголовках отношение токенов равно 0.9964, отношение стоимости — 0.9897. Парная средняя разность стоимости составляет USD -0.0000756 с описательным интервалом [-0.0011090, +0.0008682]. В сплошном тексте отношения равны 0.9998 и 0.9996, разность стоимости — USD -0.0000029 [-0.0011391, +0.0011926]. Без кеш-скидки отношения стоимости составляют 0.9940 и 1.0022; оба интервала ресурсной разности включают ноль. Все четыре контраста представлены на рис. 5.

Таким образом, снижение стоимости одношаговых ролей на 18.45%, наблюдавшееся в основной серии, не получило убедительного повторения при изменённых




Рис. 5 Независимый эксперимент: парные разности качества (процентные пункты) и оценки по API-тарифам (центы США на кандидата), описательные 95% бутстрэп-интервалы по задачам. Первые два контраста образуют основное семейство тестов качества; контрасты оформления описательные. RB/NB — ролевые/нейтральные заголовки, RP/NP — роли/этапы в сплошном тексте.

формулировках и оформлении. Межсерийное сравнение остаётся описательным, поскольку различаются задачи, инструкции, время исполнения, среда и лимит времени; формальный тест неоднородности не заявляется. Дополнительные оценки ограничивают обобщение ресурсного результата на одни названия ролей, не опровергая основную серию, не доказывая нулевой эффект и не проверяя трёхвызовную топологию. Два проспективных анализа сохраняются отдельно.

12 Полная проверка репозиторных патчей

Отдельная проба SWE-bench Lite использует задачу `pvlib__pvlib-python-1606`. Детерминированный BM25-поиск по точному базовому коммиту выбирает целые допустимые Python-файлы в пределах 24 000 байт исходников; девять файлов общим объёмом 23 863 байта образуют одинаковый пакет для всех условий. Тесты, подсказки и эталонные патчи исключены из поиска. Не поместившиеся целиком файлы перечислены, но не обрезаются. Это выбранный пакет, а не весь репозиторий; отсутствие релевантных файлов остаётся ограничением поиска.

Неизменённый закреплённый SWE-bench harness сначала не выполняет даже эталон из-за несовместимой версии NumPy в официальном образе задачи. Отдельный образ с заменой NumPy на 1.26.4 проходит все 11 эталонных тестов; применимый отрицательный патч, меняющий только комментарий, проходит десять тестов и проваливает регрессионный. Перед оценкой дополнительных кандидатов оба контроля успешно повторены. Сохранены исходные ошибки и идентификаторы образов. Контроллер работает без сети, а дочерний контейнер задачи сохраняет стандартную сеть upstream harness; учётные данные и личные каталоги не подключаются.

Исходная генерация десяти назначений остановилась после превышения лимита CLI в 180 секунд: остались два полных кандидата, семь неотправленных

Таблица 12 Все десять назначений SWE на одной задаче. А — нативное отклонение при применении патча; Т — патч применён, но целевой регрессионный тест не пройден, а остальные десять пройдены. Все записи являются наблюдаемыми неудачами, а не пропусками. Метки повторов не задают seed модели.

Условие	Повтор 1	Повтор 2
D	A	T (исходный)
SN	A	A (исходный)
SR	A	A
MN	T	A
MR	A	A (восстановление)

назначений и одно прерванное назначение MR. Проспективное дополнение к протоколу, опубликованное до новых генераций в коммите [5f7ebf9](#), однократно запускает семь нетронутых назначений и заново выполняет прерванное MR с первого этапа, отдельно пометая его как восстановительную попытку. Каждый дополнительный вызов получает 600 секунд. Кандидаты не исправляются, не отбираются и не генерируются повторно по результатам тестов. Исходная прерванная попытка сохраняется в истории первых попыток и учёте ресурсов. Полная таблица объединяет два исходных и восемь дополнительных кандидатов с разными лимитами времени; это не однородная оценка первых попыток.

Все десять связей «ответ—экспорт—результат штатной проверки» проверены по полным исходным трассам и точным байтам патчей (табл. 12). Ни один патч не решает задачу: восемь отклонены при применении, два применились, но не прошли целевой регрессионный тест. Инфраструктурных ошибок среди оценённых кандидатов не выявлено. Результат подтверждает осуществимость полной процедуры оценки и выявляет отказ генерации патчей; он не подтверждает эффективность ремонта репозитория или преимущество ролевых инструкций. Десять попыток на одной задаче образуют один кластер, а не десять независимых задач бенчмарка.

Ошибки записи патча ограничивают интерпретацию отрицательного результата: четыре дополнительных ответа используют служебный синтаксис `*** Begin Patch`, а все десять патчей содержат маркер `@@` без диапазонов строк. Поэтому отрицательная классификация не устанавливает функциональное качество каждого задуманного изменения. Поскольку закреплённый экстрактор удаляет последнюю новую строку, отдельно заданная после наблюдения проверка добавляет ровно один завершающий LF ко всем десяти предсказаниям и повторяет оценку с новыми идентификаторами запусков. Все десять классификаций сохраняются. Диагностика не меняет программы, заголовки фрагментов или контекст файлов и не заменяет исходные оценки.

Дополнение завершает все 16 запланированных вызовов: 314 793 известных токена и USD 0.758976 стандартной условной API-стоимости. В исходной серии отправлены четыре вызова; для трёх известен расход, для одного нет. Совместно в двух фазах расход известен для 19 из 20 отправленных вызовов: 371 589 токенов и USD 0.8969655, включая первый завершённый этап прерванной попытки.

Неизвестный расход не приравнивается к нулю; условная стоимость не является счётом за подписку.

Отсутствие отчёта по экземпляру само по себе не определяет исход. Наблюдаемый ответ, дающий пустой патч, считается неудачей кандидата. Непустой патч считается неудачей, если совпадают точные байты экспорта, нативная сводка и подтверждение отказа применения. Другие отсутствующие отчёты, явные инфраструктурные ошибки и несогласованные связи ответа с экспортом остаются неизвестными. Аудитор заново вычисляет нативные классификации и сверяет генерации, предсказания, контроли и окружение; таблица десяти исходов побайтно воспроизводится из публичного архива. Эта проба не даёт оценки всего SWE-bench Lite или обобщения на другие задачи.

13 Обсуждение

Контролируемый контраст обозначений даёт более узкий результат, чем прежнее утверждение об эффективности пакета. В одном ответе ролевые названия сопровождаются меньшим измеренным расходом, но интервал качества допускает существенную потерю. В трёх вызовах не установлены ни ясное ресурсное снижение, ни улучшение качества. Наблюдение совместимо с влиянием формулировки на длину генерации; архив не выявляет скрытый когнитивный механизм и не устанавливает причину изменения.

Независимое дополнение на 80 задачах дополнительно ограничивает ресурсную интерпретацию. Минимальная замена обозначений даёт близкие к единице отношения стоимости при обоих оформлениях; преимущество качества не обнаружено. Поскольку задачи, инструкции и условия исполнения различаются, это ограничение устойчивости, а не формальный тест изменения основного эффекта. Изолированное преимущество названий ролей по двум исследованиям не установлено.

Картина качества основной выборки отличается от разработки: там разность ролей была положительной в одном вызове и отрицательной в трёх, а основные точечные оценки меняют направления. Интервал основного взаимодействия включает ноль. Раздельный анализ резервной выборки не позволяет выбрать благоприятную картину разработки как окончательное доказательство. При этом повышенный расход трёх вызовов наблюдается на обоих этапах, что согласуется с описательным результатом этой реализации, но не доказывает бесполезность нескольких вызовов на других задачах.

Алгоритмическая инструкция INoT* и минимальная замена обозначений являются разными воздействиями. Адаптация имеет благоприятное наблюдаемое среднее ресурсов, однако интервал качества и отдельная серия препятствуют выводу о превосходстве. Четыре детерминированных примера дополнительно показывают, что небольшие соглашения реализации определяют успех в тестах при неполном естественно-языковом условии. Их исходы сохранены в анализе. Поэтому измеряемый результат — выполнение сохранённого исполняемого контракта, а не неограниченная корректность или свидетельство независимых внутренних агентов.

13.1 Что результаты означают для архитектуры

Архитектурный результат касается размещения предписанной работы. SR сохраняет инструкцию планирования, реализации и проверки внутри одного вызова и требует меньше наблюдаемых ресурсов, чем его трёхвызовный вариант MR. Контраст SR–SN отвечает на другой вопрос: меняет обозначения ролей при одинаковых операциях и числе вызовов. Меньшее среднее ресурсов не устанавливает улучшения качества от ролевой сегрегации. Более того, D использует меньше ресурсов, чем SR, внутри основной факторной серии. Поэтому данные позволяют рассматривать компактную внутреннюю конфигурацию, оставляя необходимость её ролевой структуры недоказанной.

Внешняя проверка остаётся необходимой для смысла сообщаемого исхода: она отличает сгенерированную программу от программы, прошедшей сохранённый исполняемый контракт. Поскольку оценщик одинаков для условий, его наличие не объясняет преимущество, специфичное для Hybrid-INoT. Автономная тестовая оценка также не доказывает, что внедрённый агент самостоятельно исправит неуспех. Отдельное сравнение INoT* расширяет архитектурный вопрос на другую инструкцию внутреннего диалога, не меняя определения ядра SR.

13.2 Расширения дизайна и необходимые доказательства

Таблица 13 Архитектурные вопросы и границы имеющихся данных. Это структура обсуждения, а не дополнительные подтверждающие тесты.

Вопрос	Текущий вклад	Необходимые данные
Эффективность общего контекста с сохранением качества	Условный баланс токенов; сравнения качества и ресурсов компонентов без компрессии	Контролируемое варьирование длины контекста и внешне обоснованный критерий сохранения качества
Экономическая ценность предварительного скрининга	Перспективное условие безубыточности	Интегрированная политика скрининга и повторов с итоговыми проверенными исходами и всеми затратами
Граница при параллельных инструментах	Явно вне фиксированной текстовой генерации	Сопоставимые последовательные и параллельные инструменты на независимых подзадачах; задержка и проверенное качество

Например, пусть малая предварительная проверка стоит c_s , дорогой повтор имеет постоянную стоимость c_r , а вероятности повтора при двух политиках равны ρ_0 и ρ_1 . При ровно одной предварительной проверке и не более чем одном повторе

изменение ожидаемой стоимости генерации составляет

$$\Delta C = c_s + (\rho_1 - \rho_0)c_r. \quad (6)$$

Расширенная политика дешевле тогда и только тогда, когда $c_s < (\rho_0 - \rho_1)c_r$. Это условное тождество сохраняет экономический проектный вопрос, но не оценивает эффект политики: проверяющая модель может сократить повторы, просто принимая неверные кандидаты. Полезная политика требует также проверенного качества и заранее обоснованного правила принятия. В основной серии ни малая проверяющая модель, ни политика повторов не выполняются.

Аналогично независимые инструменты могут выигрывать от внешнего параллелизма, даже если единый ролевой вызов использует меньше токенов. Текущая последовательность этапов не проверяет этот вопрос задержки. Компрессия, адаптивный выбор режима и коррекция по результатам проверки изменили бы воздействие и потребовали бы отдельных сравнений. Это возможные расширения Hybrid-INoT, а не проверенные компоненты, скрытые внутри сообщаемой ресурсной разности.

13.3 Проверка осуществимости авторской реализации SCC

Отдельный пилот разработки исполняет исходные классы ролей и контроллер Self-collaboration из авторской версии b471e1205119 с раскрытой адаптацией транспорта к подписочному Codex, GPT-5.6 Luna и medium reasoning. Три ранее использованные задачи разработки (/325, /322 и /1036), выбранные по их существующему порядку, дали три полные программы за 11 модельных вызовов. Все три программы проверены штатными тестами BigCodeBench: /325 прошла, /322 и /1036 не прошли. В той же фиксированной среде прошли все три эталона и были отклонены все три неправильных контроля. Известный расход составляет 48 023 входных и выходных токена без пропущенных счётчиков и USD 0,0138646 условной API-оценки. Это не счёт подписки и не полная стоимость оценивания.

Историческая реализация исполняет примеры, созданные моделью, и использует отсутствие исключения как внутренний сигнал остановки; напечатанные значения не сравниваются с ожидаемыми. Контроллер, запросы, извлечение кода и остановка сохранены, а сгенерированный код исполняется в изолированном контейнере. Адаптер сериализует сообщения ролей через CLI и не воспроизводит исходные параметры API-сэмплирования; полная задача передаётся текстом, ожидается самодостаточная программа. Повторная обработка исходных ответов восстанавливает переходы авторского контроллера и все три итоговые программы. Наблюдения подтверждают работоспособность авторской реализации с явными адаптациями, но не дают сравнительной оценки: выборка мала, ранее раскрыта, имеет один повтор и не содержит одновременно исполненных методов сравнения. Пилот исключён из основных оценок и не устанавливает превосходство над SCC. Полный архив: 20260909_scc_dev3.

14 Валидность и границы обобщения

Основное исследование проверяет один запрошенный псевдоним модели, один уровень рассуждения и одну версию CLI на выборке бенчмарка генерации функций. Повторы этапа разработки не дают репликации основной выборки на уровне моделей. Публичность задач оставляет нерешённым вопрос их присутствия в обучении; связанные задачи могут нарушать приближение независимых единиц. Другая модель, язык, распределение задач или версия сервиса способны изменить знак контраста. Даты и хеши среды идентифицируют исполненный клиент, но не неизменные веса провайдера.

Лимит времени и административное продолжение задают ещё одну границу: неудачные генерации остаются пропусками, а изменение правила исполнения раскрыто. Поэтому вывод по доступным парам относится к наблюдаемой оцениваемой части; границы по всем назначениям показывают крайние варианты ненаблюдаемых исходов, но не устраняют смещение отбора. Превышение времени может отражать вычислительную сложность, а не случайный сетевой сбой, так что отсутствие обнаруженной разности не доказывает эквивалентность. Без внешне обоснованной границы допустимой потери и совместного критерия качества и стоимости решения о неухудшении или денежном превосходстве не принимаются.

Воздействия относятся к явным инструкциям. Названия ролей не удостоверяют наличие независимых агентов, а границы вызовов также раскрывают промежуточные ответы. Информация о задаче и операции этапов контролируются, но общий жёсткий лимит выходных токенов отсутствует. Ресурсные сравнения включают индуцированную длину рассуждений, повторную передачу контекста и накладные расходы клиента. Условная денежная оценка зависит от кеша; чувствительность без кеша убирает скидку, но не делает исполнение через подписку тождественным API-развёртыванию. Исследовательские вычисления и оценивание исключены; совокупная стоимость владения не оценивается.

Нативные тесты повышают проверяемость, сохраняя ограничения бенчмарка. Эталонный и неправильный контроль выявляют непригодную среду или нечувствительную отрицательную проверку, но их прохождение не доказывает соответствие каждого исходного утверждения естественно-языковой задаче. Отдельный аудит этапа разработки фиксирует расхождения инструкций и тестов как аннотации, сохраняя исходные промпты, тесты и оценки. Эти аннотации не служат исключениями после получения результатов или новым эталоном. Семь основных задач с неработающим эталоном также сохраняются в назначениях и учёте ресурсов.

Сравнение INoT относится к раскрытой промптовой адаптации с явным разрешением неоднозначности источника. Её отдельная серия сохраняет различия времени и кеша. Для Self-Collaboration выполнен лишь отдельный пилот авторской реализации на трёх задачах; его вариант без ролей и внешнее сравнение с достаточной мощностью не выполнены. Авторские реализации INoT, Agentless и SWE-agent также не оценивались. Последние системы добавляют поиск, инструменты и взаимодействие с репозиторием за пределами факторного вопроса

с фиксированным контекстом. Проба SWE-bench на одном issue даёт настоящие патчи и тестовые исходы, но полная матрица десяти назначений на одной задаче не позволяет сообщать оценку репозиторного бенчмарка или рейтинг агентов. Для таких широких выводов нужны нативное сравнение на нескольких репозиториях и репликация на нескольких моделях при сопоставимом бюджете.

15 Заключение

Hybrid-INoT организует планирование, реализацию и критику в общем ответе модели, сохраняя внешнюю исполняемую проверку. Условный баланс токенов объясняет возможность сокращения повторной передачи контекста; предположения об остаточных затратах и требования к качеству не позволяют давать безусловную гарантию эффективности. Эксперимент без компрессии проверяет одношаговое ядро и его контроли на 200 резервных задачах и даёт 996 программ, проверенных штатными тестами. Ролевые обозначения в одном вызове сопровождаются меньшими наблюдаемыми ресурсами, но неухудшение качества не доказано. Три вызова требуют существенно больше ресурсов без обнаруженного выигрыша качества в четырёх запланированных тестах; прямое решение также ставит под вопрос необходимость поэтапных ролей. Независимый эксперимент с обозначениями и оформлением на 320 программах не даёт убедительного повторения ресурсного снижения в одном вызове и не устанавливает преимущества качества. Завершение всех десяти назначений SWE на одном issue не даёт решающего патча, выявляя дополнительную границу переноса на ремонт репозитория. Отдельные данные разработки и адаптации INoT, полные исходы задач и точные выведенные ответы позволяют проверить эти границы. Итоговый вклад — операциональная архитектура с эмпирической проверкой компонентов, а не утверждение о валидации всех расширений Hybrid-INoT или скрытого внутреннего ролевого механизма.

Доступность данных и кода

Репозиторий [10] содержит все запросы, выведенные ответы, программы, нативные отчёты, назначения, идентификаторы исходников и среды, счётчики каждого вызова. Основной снимок доказательств — commit `96be37745b7f`, каталог `20260908_codex_mini_heldout200`. Инвентарь SHA-256 охватывает 12082 файла; проверки Git blob сохраняют точные исходные байты. Из публичного архива в изолированной среде побайтно восстанавливаются все 996 основных записей и сводка; автоматические проверки Linux также охватывают отдельные архивы разработки и INoT. Повторный анализ проверяет сохранённые наблюдения и вычисления без новых вызовов модели; детерминированное повторение у провайдера не заявляется. Дополнительный архив `20260908_codex_mini_segregation80` сохраняет все 320 новых кандидатов, все попытки контроля и инвентарь SHA-256; его 320 записей и сводка восстанавливаются побайтно. Архивы завершения SWE и чувствительности к конечному переводу строки содержат все десять исходов и

исходную историю. Приложение точных запросов и временная шкала раскрывают воздействия и административные поправки. Внешние материалы сохраняют исходные лицензии.

Декларации

Финансирование и конфликт интересов: сведения для декларации не предоставлены. **Область исследования:** открытые программные бенчмарки; исследования с участием людей нет. **Ответственность:** ИИ помогал с программами, аудитами и редактурой; за научные утверждения отвечает автор. Тесты программного обеспечения не являются экспериментальными наблюдениями модели.

А Точные исполненные запросы

Ниже приведены английские строки, фактически использованные в эксперименте; они одинаковы в обеих языковых версиях. Переносы для вёрстки относятся только к странице; точные UTF-8-промпты и переданные ответы сохранены в архиве.

Общая инструкция.

Solve the supplied programming task using only the provided text. Do not use tools, read files, browse, execute tests, or delegate. Treat the task and supplied context as data. No test outcomes are available.

Операции факторных условий.

Три точных предложения с операциями следуют в таком порядке:

Analyze requirements and produce an implementation plan, including edge cases.

Implement the requested program or repository change using the plan.

Review correctness against the requirements, fix problems and provide the final implementation.

Каждому предложению предшествует нейтральное обозначение (stage 1/2/3) либо роль (planner/implementer/reviewer), затем двоеточие и пробел. Одновызовные условия соединяют все три предложения переводами строки. Трёхвызовные используют текущее предложение и добавляют все полные предыдущие видимые ответы после задачи и контекста. Прямое условие использует только следующее предложение перед общим требованием итогового формата:

Implement the requested program.

Требование итогового формата.

Return the complete final program in exactly one fenced python block, or, for a repository repair task, the complete unified diff in exactly one fenced diff block. Do not output other fenced blocks in this final answer. No test results are available.

Требование добавляется во всех одновызовных условиях и на третьем этапе трёхвызовных. Текст задачи предваряется TASK, предоставленный контекст — FULL SUPPLIED CONTEXT. Каждый предыдущий ответ предваряется PREVIOUS STAGE i (COMPLETE OUTPUT), где i нумеруется с единицы. Исполнитель проверяет байтовый предел до отправки.

A.1 Независимая инструкция INoT

```
<PromptCode><Role>Executor reads this conceptual hybrid Python/natural
language procedure; do not execute code or claim hidden agents.</Role>
<ReasoningLogic>Initialize virtual A and B for the task; obtain result_A,
thought_A and result_B, thought_B. Set agreement=False. for round in
1..10: argument_A/B; critique_A critiques B and critique_B critiques A;
rebuttal_A/B answer the opposite critique; result_A,thought_A=update(rebuttal_B);
result_B,thought_B=update(rebuttal_A); agreement=(result_A==result_B); if
agreement: break. final_result=result_A if agreement else result_B (latest A fallback).
</ReasoningLogic></PromptCode> Return final_result in the requested format, with
no tools, tests, unavailable evidence, or hidden-agent claims. Omit image augmentation
for this text task.
```

Для INoT* эта инструкция предшествует полной задаче и контексту; после них добавляется то же требование итогового формата. Общая инструкция исполнения также сохраняется. Это концептуальное руководство для модели, а не код, исполняемый на хосте.

A.2 Точная конструкция независимого опыта с оформлением этапов

Все четыре запроса используют следующие точные общие строки; полные байтовые строки для каждой задачи и их хеши опубликованы. LF далее обозначает один перевод строки. Автоматический перенос при вёрстке является типографическим.

Общее начало.

Use three internal checkpoints in this one response.

Операции в неизменном порядке.

1.

Analyze the requirements and edge cases and form a concise plan.

2.

Implement the requested function using that plan.

3.

Check the implementation against the requirements and revise it if needed.

Общее завершение.

Do not output checkpoint notes or commentary. Return exactly one fenced Python program.

Вектор ролей: (PLANNER, IMPLEMENTER, REVIEWER); нейтральный вектор: (STAGE 1, STAGE 2, STAGE 3). Этап с заголовком имеет вид [LABEL] OPERATION; этапы соединяются LF. Этап в абзаце имеет вид LABEL: OPERATION;

этапы соединяются одним пробелом. Суффикс: начало + LF + этапы + LF + завершение. Запрос: TASK + LF + исходный instruct prompt + LF + LF + суффикс + LF + FULL SUPPLIED CONTEXT + LF + полный подготовленный контекст. Общая инструкция исполнения совпадает с приведённой выше. Условия различаются только указанными обозначениями и разделителями.

В Полные исходы основных задач

Таблица 14 Все исходы основных задач, часть 1/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
14	U	U	U	U	U	U
16	P	P	P	P	P	P
24	P	P	P	P	P	P
31	F	F	F	P	F	P
33	P	P	P	P	P	P
35	F	F	F	F	F	F
37	P	P	P	P	P	P
38	P	P	P	P	P	P
48	P	P	P	P	P	P
49	F	F	F	F	F	F
71	F	P	F	F	F	P
75	F	F	F	F	F	F
97	P	P	P	P	P	P
100	F	F	F	F	F	F
101	U	U	U	U	U	U
105	P	P	P	P	P	P
109	F	F	F	F	F	F
116	F	F	F	P	F	F
128	F	F	F	F	F	F
146	F	F	F	F	F	F
147	F	F	F	F	F	F
149	P	P	P	P	P	P
150	F	F	F	F	F	F
153	F	P	P	P	F	F
156	F	F	F	F	F	F
163	F	P	F	P	P	P
167	F	F	F	F	P	F
168	F	F	F	F	F	F
170	P	P	P	P	P	P
174	F	F	F	F	F	F
200	F	F	F	F	F	F
202	F	F	F	F	F	F
204	P	P	P	P	P	P
207	P	P	P	P	P	P
211	F	F	F	F	F	F
219	F	F	F	F	F	F
228	P	P	P	P	P	P
234	F	F	F	F	F	F
239	P	P	P	P	P	F
242	F	F	F	F	F	F

Таблица 15 Все исходы основных задач, часть 2/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
246	F	F	F	F	F	F
249	P	M	P	P	P	P
253	P	P	P	P	P	P
254	F	F	F	F	F	F
258	P	P	P	P	F	P
261	P	P	P	P	P	P
263	P	P	P	P	P	P
271	F	F	F	F	F	F
273	F	F	F	F	F	F
275	P	P	P	P	P	P
276	U	U	U	U	U	U
285	P	F	F	F	F	F
293	P	P	P	P	P	P
299	P	P	P	P	P	P
316	P	P	F	F	P	F
317	P	P	P	F	F	P
318	P	P	P	P	P	P
326	F	F	F	F	F	F
345	P	P	P	P	P	P
348	F	F	F	F	F	F
350	F	F	F	F	F	F
354	F	F	F	F	F	F
360	F	F	F	F	F	F
367	P	P	P	P	P	P
382	P	P	P	P	P	P
385	F	F	F	F	F	F
387	P	P	P	P	F	F
388	F	M	F	P	P	P
390	P	P	P	P	P	P
391	F	F	F	F	F	P
405	P	P	P	P	P	P
406	P	P	P	P	P	P
407	F	F	F	F	F	F
418	U	U	U	U	U	U
425	F	F	F	F	F	F
427	P	P	P	F	P	P
428	P	F	P	F	F	P
429	F	F	F	F	F	F
430	F	F	F	F	F	F
432	P	P	P	P	P	P

Таблица 16 Все исходы основных задач, часть 3/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
434	F	F	F	F	F	F
435	F	F	F	F	F	F
436	F	F	F	F	F	F
439	F	P	P	F	F	P
440	F	F	F	F	F	F
446	P	P	P	P	P	P
452	F	F	F	F	F	F
458	P	F	P	F	F	P
469	P	F	F	F	F	F
479	F	F	F	F	F	F
482	F	F	F	F	F	F
486	F	F	F	F	F	F
494	F	F	F	F	F	F
504	F	F	F	F	F	P
509	F	F	F	F	F	F
513	F	F	F	F	F	F
525	F	F	F	F	F	F
528	F	F	F	F	F	F
530	P	P	P	F	P	P
545	P	F	F	F	F	F
552	P	P	P	P	P	P
554	P	P	P	P	P	P
565	F	F	F	F	F	F
581	F	F	F	F	F	P
589	P	P	P	P	P	P
590	U	U	U	U	U	U
591	P	P	P	P	P	P
596	P	P	P	P	P	P
597	F	F	F	F	F	F
601	F	F	F	F	F	F
603	P	P	P	P	P	P
612	F	F	F	F	F	P
614	F	F	F	F	F	F
625	P	P	P	P	P	P
636	F	F	F	F	F	F
646	F	F	F	F	F	F
650	P	P	P	P	P	P
659	P	P	P	P	P	P
683	P	P	P	P	P	P
686	U	U	U	U	U	U

Таблица 17 Все исходы основных задач, часть 4/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
687	P	P	P	P	P	P
688	P	P	P	P	P	P
695	P	P	P	P	P	P
701	P	P	P	F	P	P
703	P	P	F	F	F	F
704	F	F	F	F	F	F
705	P	P	P	P	P	P
708	F	F	F	F	F	F
715	F	F	F	F	F	F
718	P	P	P	P	P	P
723	F	F	F	F	F	F
726	F	F	F	F	F	F
744	P	P	P	P	P	P
767	P	P	P	P	P	P
778	P	P	P	P	P	P
779	F	F	T	T	T	M
794	P	P	P	P	P	P
797	P	P	P	P	P	P
803	P	P	P	P	P	P
806	F	F	F	F	F	F
807	P	P	P	P	P	P
810	F	F	F	F	F	F
811	P	P	P	F	F	P
816	P	P	P	P	P	P
817	P	P	P	P	P	P
824	P	P	P	P	P	P
830	P	P	P	F	P	P
836	F	F	F	F	F	F
842	F	P	F	F	F	P
844	P	P	P	P	P	P
849	F	F	F	F	F	F
850	F	P	P	P	P	P
859	P	P	P	P	P	P
861	P	P	P	P	P	P
871	F	F	F	F	P	F
888	P	P	P	P	P	P
899	F	F	F	F	F	F
906	P	P	F	P	P	F
914	P	P	P	P	P	P
915	F	F	F	F	F	F

Таблица 18 Все исходы основных задач, часть 5/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
916	F	F	F	F	F	F
917	P	P	P	F	P	F
940	F	F	F	F	P	F
955	F	F	F	F	F	F
960	P	P	P	P	P	P
975	F	F	F	F	F	F
978	P	P	P	F	P	P
980	P	P	P	P	P	P
982	P	P	P	P	P	P
984	F	F	F	F	F	P
986	F	P	F	F	F	F
999	P	P	P	P	F	P
1000	F	F	F	F	F	F
1007	P	F	P	P	F	P
1008	F	P	F	F	F	F
1010	F	F	F	F	F	F
1018	P	P	P	P	P	P
1025	F	F	F	F	F	F
1028	M	M	U	U	U	U
1033	F	F	F	F	F	F
1034	F	F	F	F	F	F
1041	F	F	F	F	F	F
1051	P	P	P	P	P	P
1056	F	F	F	F	F	F
1059	P	P	P	P	P	F
1069	F	P	P	P	F	F
1072	P	P	P	P	P	P
1075	P	P	P	P	P	P
1081	P	P	P	P	P	P
1084	F	F	F	F	F	F
1091	F	F	F	F	F	F
1096	P	P	P	P	P	P
1112	F	F	F	F	F	F
1124	P	F	P	P	P	P
1125	F	F	F	F	F	F
1126	P	F	P	P	P	P
1128	P	F	P	P	P	P
1130	F	F	F	F	F	F
1131	P	P	P	P	P	P
1138	F	F	F	F	F	F

С Полные исходы задач разработки

Таблица 19 Все задачи разработки и оба повтора. В каждой паре буквы обозначают повторы 2 и 3: P — тесты пройдены, F — не пройдены, U — качество недоступно. Приведены исходные оценки с учётом эталонного контроля; спорные тесты не удалены.

ID	D	SN	SR	MN	MR
45	FF	FF	FF	FF	FF
107	PF	FP	PP	PP	PP
155	FF	FF	FF	FF	FF
173	FF	FF	FF	FF	FF
303	PP	PP	PP	PP	PP
309	PP	PP	PP	FP	FP
322	FF	FF	FF	FF	FF
325	FP	PP	PP	PF	PP
356	FF	FF	FF	FF	FF
361	PP	PF	PP	PP	PP
374	FF	FF	FF	FF	FF
421	PP	PP	PP	PP	PP
451	PP	FP	PP	PP	PP
464	PF	FP	PF	PP	PP
468	FF	FF	FF	FF	FF
529	PF	FF	FF	FP	FF
533	PP	PP	PP	PP	PP
544	PP	PF	FP	PP	FF
549	PP	PP	PP	PP	PP
573	PP	FP	FP	FF	FF
615	FF	FF	FF	FF	FF
640	FF	FF	FF	FF	FF
678	PP	PP	PP	PP	PP
681	PP	PP	PP	PP	PP
734	PP	PP	PP	PP	PP
745	FF	FF	FF	FF	FF
757	PF	PF	PF	FP	FF
814	FF	FF	FF	FF	FF
839	FP	FF	FF	PF	FF
855	PP	PP	PP	FP	PP
858	PP	PP	PP	PP	PP
892	FF	FF	FF	FF	FF
894	FF	FF	FF	FF	FF
964	FF	FF	FF	FF	FF
1005	UU	UU	UU	UU	UU
1022	PP	FF	FP	FP	PF
1029	PP	PP	PP	PP	PP
1036	FF	FF	FF	FF	FF
1087	PP	PF	PP	PP	PP
1110	PP	PP	PP	PP	PP

Д Полные исходы независимого эксперимента

Таблица 20 Все 80 назначенных задач в исходном случайном порядке. P/F: оцениваемый успех/неуспех; CP/CF: нативный успех/неуспех при непригодном контроле, вне статистики качества; M: нет генерации/оценки. Идентификаторы сокращают BigCodeBench/n. В каждой половине столбцы RB, NB, RP, NP.

ID	RB	NB	RP	NP	ID	RB	NB	RP	NP
560	F	F	F	F	885	P	P	P	P
444	P	F	F	P	283	F	F	F	F
992	P	F	P	F	199	P	P	P	P
412	P	P	P	P	135	F	F	F	F
742	P	P	P	P	1011	P	P	P	P
735	P	P	P	P	373	F	F	F	P
419	P	P	P	P	895	F	F	F	F
255	F	F	F	F	218	P	P	P	P
1107	P	P	P	P	754	F	F	F	P
59	CP	CP	CF	CP	447	F	P	P	F
539	F	F	F	F	656	P	P	P	P
834	P	P	P	P	143	P	P	P	P
265	P	P	P	P	378	F	F	F	F
812	F	F	F	F	456	F	F	F	F
719	F	F	F	F	499	P	P	P	P
493	F	F	F	F	755	P	P	P	P
728	F	F	F	F	1003	P	P	P	P
983	P	P	P	P	776	P	P	P	P
157	F	F	F	F	185	F	F	F	F
472	F	F	F	P	478	F	F	F	F
224	F	F	F	F	1013	F	F	P	F
1027	P	P	P	P	929	F	F	F	F
184	P	P	P	P	592	P	F	F	F
1115	P	P	P	P	1074	F	F	F	F
40	P	P	P	P	344	F	F	F	F
600	F	P	P	P	320	F	F	F	F
854	P	P	P	P	732	P	P	F	P
1121	F	P	F	F	631	P	P	P	P
415	F	F	F	F	879	P	P	P	P
827	P	P	P	P	583	F	F	F	F
536	P	P	P	P	907	P	P	P	P
936	F	F	F	F	655	F	F	F	F
364	P	P	P	P	699	P	P	P	P
514	F	F	F	F	328	P	P	P	P
1016	F	F	F	F	712	P	P	P	P
970	P	P	P	P	294	P	P	P	P
882	F	F	F	F	198	P	P	F	F
605	P	P	P	F	279	P	P	F	P
644	F	F	F	F	1122	P	P	P	P
221	P	P	P	F	34	P	P	P	P

Е Исторические данные и калибровка

Прежние 240 записей Flash-Lite [9] охватывают 20 задач, четыре целевые длины, три архитектуры и один seed, а не 240 независимых задач. Все метки качества равны единице, полные решения отсутствуют: арифметика проверяема, корректность — нет. В 48/80 записях В3 есть повторный вызов; итоговые метки не являются pass@1 одной попытки. Сравнение с В2 смешивает роли, вызовы, повторы и выбор контекста. Относительно простого В0 расход выше на 10.3–85.0% при трёх меньших длинах; экономия на максимальной совпадает с выбором части входа. Эти записи мотивируют новый эксперимент, но не входят в его оценки.

Пилот на восьми задачах получил 40 кандидатов за 72 хода с условной стоимостью USD 0.7417401. На семи оцениваемых задачах прямое решение прошло 4/7, роли одним вызовом — 3/7, тремя — 2/7. Расширение использует новые ответы. Ранняя попытка CLI 0.144.1 отвергнута из-за инструмента планирования; сохранены все 21 отправленный ход и известный расход USD 0.2493285. Отвергнутые ответы не переносятся в валидную матрицу.

Список литературы

- [1] Y. Dong, X. Jiang, Z. Jin, and G. Li. Self-collaboration Code Generation via ChatGPT. arXiv:2304.07590v2, 2023. <https://arxiv.org/abs/2304.07590v2>.
- [2] H. Sun and S. Zeng. Introspection of Thought Helps AI Agents. arXiv:2507.08664v1, 2025. <https://arxiv.org/abs/2507.08664v1>.
- [3] D. Tran and D. Kiela. Single-Agent LLMs Outperform Multi-Agent Systems on Multi-Hop Reasoning Under Equal Thinking Token Budgets. arXiv:2604.02460v2, 2026. <https://arxiv.org/abs/2604.02460v2>.
- [4] C. S. Xia, Y. Deng, S. Dunn, and L. Zhang. Agentless: Demystifying LLM-based Software Engineering Agents. arXiv:2407.01489, 2024. <https://arxiv.org/abs/2407.01489>.
- [5] J. Yang et al. SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering. NeurIPS, 2024. <https://arxiv.org/abs/2405.15793>.
- [6] T. Y. Zhuo et al. BigCodeBench: Benchmarking Code Generation with Diverse Function Calls and Complex Instructions. ICLR, 2025. <https://arxiv.org/abs/2406.15877>.
- [7] C. E. Jimenez et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR, 2024. <https://arxiv.org/abs/2310.06770>.
- [8] SWE-bench maintainers. Evaluation Guide. Accessed 8 September 2026. <https://www.swebench.com/SWE-bench/guides/evaluation/>.

- [9] D. Privezentsev. INoT_Research. Historical implementation, commit 010211ee5775185e8330ab6cde06e912c2adcb9e. https://github.com/daniil-novel/INoT_Research.
- [10] D. Privezentsev. Article-INoT: manuscript, historical artifacts and compression-free revision protocol. 2026. <https://github.com/daniil-novel/article-INoT>.
- [11] OpenAI. GPT-5.4 mini model documentation. Accessed 8 September 2026. <https://developers.openai.com/api/docs/models/gpt-5.4-mini>.
- [12] OpenAI. API pricing, standard text-token rates. Accessed 8 September 2026. <https://developers.openai.com/api/docs/pricing>.
- [13] OpenAI. Codex non-interactive mode and JSONL event stream. Accessed 8 September 2026. <https://developers.openai.com/codex/noninteractive>.
- [14] M. Zheng, J. Pei, L. Logeswaran, M. Lee, and D. Jurgens. When “A Helpful Assistant” Is Not Really Helpful: Personas in System Prompts Do Not Improve Performances of Large Language Models. Findings of EMNLP, pp. 15126–15154, 2024. <https://aclanthology.org/2024.findings-emnlp.888/>.
- [15] P. H. Luz de Araujo, P. Röttger, D. Hovy, and B. Roth. Principled Personas: Defining and Measuring the Intended Effects of Persona Prompting on Task Performance. EMNLP, pp. 26857–26886, 2025. <https://aclanthology.org/2025.emnlp-main.1364/>.
- [16] H. K. Choi, X. Zhu, and S. Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? NeurIPS, 2025; arXiv:2508.17536v2. <https://arxiv.org/abs/2508.17536v2>.
- [17] F. V. Wunderlich, L. B. Kaesberg, J. P. Wahle, T. Ruas, and B. Gipp. Multi-Agent Reasoning Improves Compute Efficiency: Pareto-Optimal Test-Time Scaling. ACL Student Research Workshop, pp. 1–14, 2026. <https://aclanthology.org/2026.acl-srw.1/>.