

Ролевые обозначения и границы вызовов при генерации кода: факторный эксперимент без компрессии

Даниил Привезенцев^{1*}

^{1*}Национальный исследовательский университет «Высшая школа экономики», Москва, Россия.

Corresponding author(s). E-mail(s): daprivezentsev@edu.hse.ru;

Аннотация

Ролевые конвейеры часто одновременно меняют инструкции и число вызовов модели. Эти воздействия разделены в факторном эксперименте без компрессии на GPT-5.4 mini со средним уровнем рассуждения. Сорок случайно выбранных задач разработки, пять условий и два повтора дают 400 завершённых программ и 720 свежих ходов Codex CLI. Сохранены полные выведенные ответы, история, счётчики токенов и нативные отчёты BigCodeBench. Контроли позволяют оценить 39 задач. Прямое решение проходит 42/78 попыток при наименьшем среднем расходе; роли в одном вызове — 39/78, в трёх — 36/78. Разности качества ролей и нейтральных этапов составляют +6.41 и -3.85 процентного пункта; это оценки разработки с неопределённостью на уровне задач. Измерены 3 703 821 токен и условная стоимость USD 6.61135 по опубликованным API-тарифам, не списание с подписки. Проба настоящих патчей SWE-bench останавливается по времени генерации: два наблюдаемых патча не решают задачу, восемь назначений остаются пропусками. Получен проверяемый непотолочный эксперимент, ослабляющий общее утверждение об эффективности ролей. Готовится отложенная серия; неухудшение и превосходство над нативными агентами не заявляются.

Keywords: Code generation, role prompting, factorial design, token accounting, BigCodeBench, SWE-bench

1 Введение: ролевые обозначения и границы вызовов

В конвейерах генерации кода обычно выделяют этапы планирования, реализации и проверки. В таком описании часто скрыты два различных воздействия. Ролевое обозначение может изменить инструкции, данные одному ответу модели, тогда как граница вызова может разделить работу между отдельно сэмплированными ответами с передачей промежуточного текста. Если оба воздействия изменяются одновременно, наблюдаемое различие нельзя приписать ни формулировке ролей, ни повторному выводу, ни информации, раскрываемой между вызовами. Настоящее исследование на этапе разработки изолирует этот вопрос на уровне протокола: отличаются ли инструкции с ролевыми обозначениями от нейтральных инструкций этапов при изменении топологии вызовов в одной и той же совокупности задач и при одном и том же предоставленном контексте?

Оцениваемый эффект намеренно уже, чем утверждение о независимых агентах или скрытом мышлении. В исследовании сравниваются пять реализованных условий: прямой решатель с одним вызовом, ответ с нейтральными этапами в одном вызове, ответ с ролевыми этапами в одном вызове, нейтральный конвейер из трёх вызовов и конвейер из трёх вызовов с ролевыми обозначениями. В условиях одного вызова три процедурных этапа размещаются в одном ответе модели. В условиях нескольких вызовов каждый следующий этап получает предыдущий ответ целиком. Поэтому топология вызовов и поток промежуточной информации являются частью определения воздействия. Результат может поддержать утверждение об этих зафиксированных промптах и границах, но не может установить, что профессиональные обозначения создают независимых внутренних агентов.

2 Связанные работы

Ролевое описание имеет предшественников в программном промптинге и внутреннем диалоге. INoT организует рассуждение с помощью явных этапов и инструкций [1]. Эта работа мотивирует контролируемое сравнение, однако само наличие названий ролей не определяет причинный эффект ролей. Полезное сравнение должно отделять формулировку ролей от числа вызовов модели и сохранять информацию, доступную каждому условию.

Бюджет и структура взаимодействия также представляют собой разные факторы в связанных исследованиях. Работа об односоставных и многосоставных рассуждающих системах при сопоставимых бюджетах токенов мышления подчёркивает, что дополнительные вызовы и дополнительные вычисления не являются взаимозаменяемыми воздействиями [2]. Поэтому в настоящем исследовании фиксируются счётчики входных, кэшированных входных и выходных токенов, а оценка по стандартным API-тарифам приводится как описательная мера ресурса. Канал подписки не трактуется как счёт API, а сравнение токенов не объявляется полным сравнением совокупной стоимости владения.

В области программной инженерии Agentless использует структурированный рабочий процесс локализации, исправления и проверки [3], тогда как SWE-agent

использует интерфейс репозитория с инструментами [4]. Эти системы предназначены для практического исправления репозитория и включают политики поиска или взаимодействия, отсутствующие в используемых здесь задачах функций с фиксированным контекстом. BigCodeBench предоставляет разнообразные задачи генерации кода с вызовами библиотек и сложными инструкциями [5]. Он подходит для проверки следования инструкциям и исполнимых результатов, но распределение задач на уровне функций не заменяет исправление репозитория. SWE-bench оценивает изменения по тестам репозитория [6, 7] и остаётся отдельной внешней границей настоящего исследования.

Исследования persona prompting мотивируют более узкое утверждение, чем универсальная польза ролей для рассуждения. Zheng и соавторы не обнаруживают устойчивого улучшения от системных персон в исследованных фактологических задачах [16]. Luz de Araujo и соавторы разделяют качество, устойчивость к несущественным атрибутам персоны и соответствие заданной специализации; результаты зависят от модели и задачи [17]. Эти работы не проверяют наши запросы на генерацию кода. Они обосновывают изменение обозначений при сохранении требуемых операций и ограничение вывода конкретными использованными обозначениями.

Данные о нескольких агентах также зависят от выбранного сравнения. Choi и соавторы связывают значительную часть выигрыша в своих NLP-экспериментах с независимым голосованием, отделяя обмен сообщениями от агрегации [18]. В то же время Wunderlich и соавторы находят конфигурации, в которых debate или mixture-of-agents улучшают соотношение вычислений и точности относительно self-consistency на MMLU-Pro и BBH [19]. Это основание для условной оценки, а не универсального вывода за или против нескольких агентов. Наша нейтральная последовательная цепочка не является голосованием, смесью независимых моделей или ансамблем с выровненным бюджетом. Вклад работы — факторная проверка одной модели на исполняемом коде с полным учётом трасс и расходов; общее превосходство над перечисленными альтернативами не входит в оцениваемый эффект.

3 Выполненные методы исследования на этапе разработки

Выполненное расширение использует GPT-5.4 mini со средним уровнем рассуждения через Codex CLI 0.153.4. Решатель работает через канал подписки и зафиксированный псевдоним модели; утверждение о неизменном снимке весов не делается. Каждое условие получает один и тот же текст задачи и полный предоставленный контекст. В условиях нескольких вызовов каждый последующий этап получает весь предшествующий раскрытый ответ. Вход не сжимается и не сокращается выборочно для отдельного условия. Во время генерации отключены инструменты, просмотр веб-страниц, делегирование и выполнение тестов; для каждого свежего эфемерного потока требуется строгая трасса JSONL.

Совокупность задач состоит из 40 случайно упорядоченных задач разработки из BigCodeBench v0.1.4. Порядок, заданный начальным числом, и точное распределение задач записаны в неизменяемом манифесте. Все задачи сохраняются, включая задачу, контроль эталона которой непригоден для измерения корректности. Две помеченные повторами репликации, с идентификаторами 2 и 3, сопоставляются внутри задачи и условия. Эти обозначения являются идентификаторами повторов, а не сэмплирующими сидами провайдера: CLI не предоставляет проверяемый сид сэмплирования, а температура не контролируется. Следовательно, повторы дают повторные наблюдения в рамках одного заявленного протокола, но не означают детерминированного воспроизведения модели.

Пять условий, применённые к 40 задачам и двум меткам повторов, дают 400 назначенных программ-кандидатов. В условиях одного вызова и прямого решения на одного кандидата приходится один CLI-вызов; каждое трёхэтапное условие использует три свежих вызова. Поэтому полная матрица содержит 720 свежих CLI-вызовов. Упорядоченные задачи разделяются на четыре непересекающиеся группы по десять задач для каждой волны повторов. Четыре группы запускаются параллельно, каждая с двумя рабочими потоками решателя, что даёт не более восьми одновременно работающих CLI-процессов. Волна повторов 3 начинается только после завершения волны 2. Порядок отправки внутри каждой группы рандомизируется зафиксированным решателем, тогда как состав задач и обозначения условий остаются заданными манифестом.

Решатель устанавливает ограничение в 180 секунд на один CLI-вызов, предварительную проверку входа на 65 536 байт и отсутствие единого жёсткого лимита завершения, сопоставленного между условиями. Отсутствие сопоставленного лимита является заявленным ограничением: дизайн фиксирует информацию о задаче и настройке, не относящиеся к воздействию, но не фактическую длину завершения, использование рассуждения, время выполнения или общие расходы. Автоматические повторы, исправление архивированного итогового кандидата после выполнения, сжатие раскрытых ответов перед передачей и выбор более удачного блока кода запрещены. Этапы реализации и проверки внутри заявленного воздействия могут пересматривать код согласно инструкции. Если группа завершается ошибкой, отправленные события и наблюдаемое использование сохраняются, уже активная волна доводится до конца, а следующая волна повторов не запускается. Частичная матрица остаётся частичной, а ненаблюдавшиеся назначенные ячейки сохраняются как пропуски.

До генерации модели эталонные и намеренно неправильные контроли были выполнены для всех 40 назначенных задач через неизменённый upstream CLI BigCodeBench в итоговой изолированной среде, с исходными тестами, отключённой сетью и штатным режимом “instruct”. Контрольные данные показывают 39 задач с успешно прошедшим эталоном и не прошедшим неправильным решением. Для одной задачи эталон завершился ошибкой, поэтому она сохраняется в назначении, но исключается из измерения корректности во всех условиях. Архивированы gate, хэши образа и пакетов, набора данных и подготовленного разделения, дерева исходников, команд и исходных контрольных отчётов. Прохождение контроля подтверждает исполнимость и различие неправильного

решения, но не удостоверяет семантическую корректность каждого утверждения бенчмарка.

Независимой единицей является задача. Повторы усредняются внутри задачи только для парных описательных сравнений, когда наблюдаемы оба повтора и оба сравниваемых условия. Анализ сообщает доли среди оцениваемых попыток вместе с границами пропусков по полному назначенному знаменателю. Сравнения ресурсов используют полные парные средние по задачам; описательные средние ресурсов по отдельным условиям сохраняют знаменатели всех наблюдаемых кандидатов, когда матрица неполна. Бутстрэп-интервалы по кластерам задач строятся по 10 000 ресэмплированиям с фиксированным начальным числом анализа. Это описательные 95% бутстрэп-интервалы без подтверждающего статистического теста или расчётного утверждения о не меньшей эффективности; 40 задач не превращаются в 400 независимых наблюдений только потому, что матрица содержит 400 кандидатов.

3.1 Определения условий и учёт ресурсов

Далее используются фиксированные обозначения: D — прямое решение одним вызовом; SN — три нейтральных этапа внутри одного вызова; SR — три этапа с названиями ролей внутри одного вызова; MN — нейтральные этапы в трёх вызовах; MR — ролевые этапы в трёх вызовах. Операции планирования, реализации и проверки одинаковы для нейтральных и ролевых инструкций. Четыре структурированных условия образуют факторный дизайн 2×2 «топология $\times$ обозначения»; D служит простым дополнительным сравнением.

Предложенный рецензентом дизайн «топология $\times$ компрессия» позволил бы разложить эффект прежнего пакета. В настоящем исследовании компрессия отсутствует, а названия ролей варьируются непосредственно. Поэтому новый эксперимент не измеряет исторический эффект компрессии и не отделяет топологию от передачи промежуточной информации. Исключение роутера и малого проверяющего из воздействия также исключает их неизмеренные эффекты из заявленного вклада.

CLI возвращает счётчики входных I , кешированных входных C и выходных O токенов каждого завершённого хода [14]. Кешированные токены входят во входные, а токены рассуждения, когда их счётчик доступен отдельно, — в выходные. Повторно они не складываются. Для каждого хода используются опубликованные стандартные API-тарифы GPT-5.4 mini [12, 13]:

$$V = \frac{0.75(I - C) + 0.075C + 4.50O}{10^6} \quad \text{USD.} \quad (1)$$

Расчёт без кеша равен $V_0 = (0.75I + 4.50O)/10^6$. Это условная оценка измеренных токенов канала подписки по API-тарифам, а не платёж API, счёт подписки или совокупная стоимость владения. Работа исследовательских помощников, подготовка среды и выполнение тестов в эти суммы генерации не входят. Кеширование и порядок отправки могут влиять на V ; расчёт V_0 показывает эту зависимость.

Отдельный счётчик рассуждения не требуется для вычисления V , но без него нельзя сравнить именно токены рассуждения.

4 Результаты разработки: полная матрица и непотолочные оценки

Все 400 назначенных программ и 720 ходов CLI завершены и прошли аудит трасс. Каждый сохранённый итоговый ответ и расход токенов согласуются с исходным потоком событий; входы многошаговых условий содержат полные предыдущие ответы без изменений. Архив содержит 3 703 821 измеренный токен с условной оценкой USD 6.6113451; расчёт без кеша равен USD 7.7687595. Ошибок извлечения итогового формата в этой матрице нет. Все 400 строк нативного оценщика соответствуют точным экспортированным программам и ID задач. Ошибка эталона /1005 делает десять назначенных исходов недоступными, оставляя 390 оцениваемых попыток на 39 задачах.

Таблица 1 Результаты на выборке разработки: по 80 назначений на условие, два повтора на 40 задачах. Качество рассчитано по 78 оцениваемым попыткам, ресурсы — по всем 80. Границы пропусков относятся ко всем назначениям и не являются доверительными интервалами.

Усл.	Прошло	Доля (%)	Границы (%)	Токены	USD	Без кеша
D	42/78	53.85	52.50–55.00	4 500	0.00776	0.00939
SN	34/78	43.59	42.50–45.00	5 598	0.01251	0.01417
SR	39/78	50.00	48.75–51.25	5 189	0.01070	0.01234
MN	39/78	50.00	48.75–51.25	15 636	0.02624	0.03090
MR	36/78	46.15	45.00–47.50	15 375	0.02543	0.03030

Наблюдаемые доли успеха лежат между 43.59% и 53.85%: прежнего потолка качества нет. D имеет наибольшее число успехов (42/78) и наименьший средний расход. SR и MN проходят по 39/78 попыток, MR — 36/78, SN — 34/78. Учитывается каждая отдельная попытка; лучшее из двух решений не выбирается. Успех в тестах не тождествен корректности относительно естественно-языкового условия из-за обсуждаемых ниже проблем согласованности тестов.

Ролевые обозначения меняют качество по-разному при разных топологиях: SR минус SN составляет +6.41 процентного пункта, MR минус MN — −3.85 пункта. Разность этих разностей равна −10.26 пункта с описательным бутстрэп-интервалом $[-19.23, -1.28]$. Такое взаимодействие на выборке разработки мотивирует отдельную проверку на отложенных задачах, но не является результатом подтверждающего теста. Трёхвызовные условия расходуют в 2.79 и 2.96 раза больше токенов, чем соответствующие одновызовные. Отношения условной стоимости равны 2.10 и 2.38, поскольку кешированный вход дешевле выхода. Таким образом, меньшее число вызовов снижает измеренный расход в




Рис. 1 Наблюдаемые средние на выборке разработки. Обозначены пять условий, определённых выше. Точки показывают исходное тестовое качество и условную оценку по API-тарифам; это не доверительные области и не граница эффективности на всём бенчмарке. Знаменатели качества и ресурсов различаются только из-за задачи с неработающим эталоном, расход которой продолжает учитываться.

Таблица 2 Парные сравнения на выборке разработки. Разности качества и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах для 39 полных пар; отношения ресурсов — для 40 задач. Последние два сравнения поисковые. Подтверждающие р-значения и тест неухудшения не применяются.

Контраст	Разность качества [интервал]	Токены, отн.	USD, отн.
SR - SN	+6.41 [+1.28, +11.54]	0.927	0.855
MR - MN	-3.85 [-11.54, +2.56]	0.983	0.969
MN - SN	+6.41 [-2.56, +15.38]	2.793	2.097
MR - SR	-3.85 [-8.97, +1.28]	2.963	2.377
SN - D	-10.26 [-19.23, -2.56]	1.244	1.613
MR - D	-7.69 [-17.95, +1.28]	3.417	3.277

данной реализации, а последствия для качества зависят от инструкций и имеют существенную неопределённость.

5 Репозиторные патчи и явно незавершённая серия

Отдельная проба SWE-bench Lite использует задачу `pvlib__pvlib-python-1606`. Детерминированный BM25-поиск по точному базовому коммиту выбирает целые допустимые Python-файлы в пределах 24 000 байт исходников; девять файлов общим объёмом 23 863 байта образуют одинаковый пакет для всех условий. Тесты,

подсказки и эталонные патчи исключены из поиска. Не поместившиеся целиком файлы перечислены, но не обрезаются. Это явно выбранный пакет, а не весь репозиторий; отсутствие релевантных файлов остаётся ограничением поиска.

Неизменённый закреплённый SWE-bench harness сначала не выполняет даже эталон из-за несовместимой версии NumPy в официальном образе задачи. Отдельный образ с заменой NumPy на 1.26.4 проходит все 11 эталонных тестов; применимый отрицательный патч, меняющий только комментарий, проходит десять тестов и проваливает регрессионный. Сохранены исходные ошибки и идентификаторы обоих образов. Эти контроли подтверждают исправленную среду, а не неизменённый официальный образ. Контроллер работает без сети, но дочерний контейнер неизменённого upstream-оценщика сохраняет стандартную сеть Docker; учётные данные и личные каталоги не подключаются.

Зафиксированная генерация десяти кандидатов останавливается после превышения одним вызовом CLI лимита 180 секунд. Остаются два полных патча: D применяется, но не проходит целевой регрессионный тест (десять остальных пройдены); SN отвергается нативным применением патча. Восемь назначенных кандидатов остаются пропусками. Оба наблюдаемых оценивания проходят сверку входа, патча и отчёта; инфраструктурных ошибок в них не выявлено. Отправлены четыре хода CLI; для трёх доступны полные счётчики: 56 796 токенов и USD 0.1379895 условной стоимости. Для одного расход недоступен. Это неполная проба без решённого экземпляра, а не оценка бенчмарка Lite. Она заменяет прежнюю заглушку `check()` настоящим применением патчей и тестами, сохраняя факт незавершённости запланированной матрицы.

6 Ограничения и внешняя граница

Выполненный дизайн характеризует поведение одного запрошенного псевдонима модели, одной настройки рассуждения, одной версии CLI, пяти условий промптинга и выбранной совокупности из 40 задач разработки. Он не характеризует устойчивое свойство модели у провайдера, универсальный эффект ролей или причинный эффект, независимый от потока информации. Поскольку сид сэмплирования провайдера и контроль температуры недоступны, метки повторов следует интерпретировать как повторные наблюдения на уровне протокола, а не как точные стохастические репликации. Отсутствие общего жёсткого лимита вывода оставляет качество, длину завершения и использование ресурсов совместно информативными, но не уравненными по бюджету.

Валидность тестов BigCodeBench остаётся отдельным вопросом. Независимый аудит инструкций и тестов фиксирует проблемы согласованности промптов и тестов как аннотации, тогда как исходные промпты, тесты и оценки сохраняются без изменений. Успешный эталонный контроль необходим для включения задачи в оценивание, но не может доказать, что каждое утверждение измеряет естественно-языковую задачу. Все назначенные задачи остаются в знаменателе. Контрольные или инфраструктурные ошибки дают пропущенные результаты; расхождения инструкций и тестов остаются аннотациями и не стирают исходные

оценки. Ресэмплирование задач учитывает повторные наблюдения внутри задачи, но не устраняет зависимость между связанными задачами бенчмарка.

Исследование также ограничено относительно утверждений о внешних агентах для репозитория. В нём не выполняются нативные системы INoT, Agentless или SWE-agent и не приводится внешний результат этих систем на бенчмарке. Эти системы различаются поиском, использованием инструментов, состоянием репозитория, применением патчей и взаимодействием с тестами. Будущее сравнение должно зафиксировать каждую нативную реализацию, модель и бюджет, собрать полные траектории и использовать соответствующий официальный оценщик. В частности, результат генерации функции нельзя переименовать в свидетельство о ремонте репозитория, а опубликованный внешний процент нельзя вставить в эту матрицу как парное условие.

Таким образом, настоящее исследование представляет собой ограниченный выполненный эксперимент на этапе разработки. Оно даёт проверяемое сравнение ролевых обозначений и границ вызовов при полном предоставленном контексте, повторно раскрываемой истории, нативных тестах BigCodeBench и явном учёте ресурсов. Само по себе оно не обосновывает утверждение о скрытом многоагентном поведении, превосходстве на всём бенчмарке, не меньшей эффективности или внешней валидности для современной разработки репозитория.

7 Интерпретация и следующая отложенная проверка

Исследование разделяет вопросы, смешанные в прежнем пакете Hybrid-INoT. Дополнительные вызовы повторно передают вход и промежуточную работу; их измеренный расход здесь выше. Ролевые обозначения дают положительный контраст качества внутри одного ответа, но не в трёх вызовах. Прямое решение имеет лучшее наблюдаемое сочетание качества и расхода на выборке разработки. Это аргумент в пользу простого сравнения при оценке внутренних ролей; польза дополнительных вызовов на других задачах не исключается.

Отдельное назначение фиксирует 200 новых задач из исходной случайной перестановки, исключая восемь примеров, случайно показанных карточкой данных при проверке лицензии. Задачи разработки не используются повторно. Пять условий и новая метка повтора дают 1 000 кандидатов и 1 800 ходов CLI. Контроли предшествуют генерации; для четырёх парных контрастов качества заранее заданы точные тесты Мак-Немара с поправкой Холма. Доказанная мощность теста неухудшения с допуском два пункта не обеспечена. На данном этапе отложенные модельные исходы недоступны и не представляются выполненными результатами.

8 Заключение

Полные ответы и официальные тесты заменяют смешанное утверждение об экономике выполненным сравнением ролей и границ вызовов. На выборке разработки прямое решение сочетает наибольшую наблюдаемую долю успеха с наименьшим

расходом и условной стоимостью. Эффекты ролей различаются между протоколами, мотивируя отложенную проверку. Сохраняются ограничения выборки, оценщика и версии модели.

Доступность данных и кода

Репозиторий статьи [11] содержит полные архивы генерации и нативного оценивания, хэши задач, контролей и исходников, оригинальные ответы, программы и результаты по задачам. Манифест разработки и контрольный допуск зафиксированы до генерации. Описи SHA-256 связывают артефакты. Прежний пилот, отвергнутая попытка и исторические данные сохранены отдельно. Доступ к скрытому рассуждению провайдера или неизменному снимку весов не заявляется; исходные лицензии приложены.

Декларации

Финансирование и конфликт интересов: в предшествующей рукописи внешнее финансирование и конфликт интересов не заявлены. **Область:** публичные программные бенчмарки, без исследования с участием людей. **Ответственность:** ИИ помогал в подготовке ПО, аудите и редактировании; автор отвечает за научные выводы. Программные тесты не являются экспериментальными наблюдениями модели.

А Полные результаты разработки

Таблица 3 Все задачи разработки и оба повтора. В каждой паре буквы обозначают повторы 2 и 3: P — тесты пройдены, F — не пройдены, U — качество недоступно. Приведены исходные оценки с учётом эталонного контроля; спорные тесты не удалены.

ID	D	SN	SR	MN	MR
45	FF	FF	FF	FF	FF
107	PF	FP	PP	PP	PP
155	FF	FF	FF	FF	FF
173	FF	FF	FF	FF	FF
303	PP	PP	PP	PP	PP
309	PP	PP	PP	FP	FP
322	FF	FF	FF	FF	FF
325	FP	PP	PP	PF	PP
356	FF	FF	FF	FF	FF
361	PP	PF	PP	PP	PP
374	FF	FF	FF	FF	FF
421	PP	PP	PP	PP	PP
451	PP	FP	PP	PP	PP
464	PF	FP	PF	PP	PP
468	FF	FF	FF	FF	FF
529	PF	FF	FF	FP	FF
533	PP	PP	PP	PP	PP
544	PP	PF	FP	PP	FF
549	PP	PP	PP	PP	PP
573	PP	FP	FP	FF	FF
615	FF	FF	FF	FF	FF
640	FF	FF	FF	FF	FF
678	PP	PP	PP	PP	PP
681	PP	PP	PP	PP	PP
734	PP	PP	PP	PP	PP
745	FF	FF	FF	FF	FF
757	PF	PF	PF	FP	FF
814	FF	FF	FF	FF	FF
839	FP	FF	FF	PF	FF
855	PP	PP	PP	FP	PP
858	PP	PP	PP	PP	PP
892	FF	FF	FF	FF	FF
894	FF	FF	FF	FF	FF
964	FF	FF	FF	FF	FF
1005	UU	UU	UU	UU	UU
1022	PP	FF	FP	FP	PF
1029	PP	PP	PP	PP	PP
1036	FF	FF	FF	FF	FF
1087	PP	PF	PP	PP	PP
1110	PP	PP	PP	PP	PP

В Исторические данные и калибровка

Прежние 240 записей Flash-Lite охватывают 20 задач, четыре целевые длины, три архитектуры и один seed, а не 240 независимых задач. Все метки качества равны единице, полные решения отсутствуют: арифметика проверяема, корректность — нет. В 48/80 записях V3 есть повторный вызов; итоговые метки не являются pass@1 одной попытки. Сравнение с V2 смешивает роли, вызовы, повторы и выбор контекста. Относительно простого V0 расход выше на 10.3–85.0% при трёх меньших длинах; экономия на максимальной совпадает с выбором части входа. Эти записи мотивируют новый эксперимент, но не входят в его оценки.

Пилот на восьми задачах получил 40 кандидатов за 72 хода с условной стоимостью USD 0.7417401. На семи оцениваемых задачах прямое решение прошло 4/7, роли одним вызовом — 3/7, тремя — 2/7. Расширение использует новые ответы. Ранняя попытка CLI 0.144.1 отвергнута из-за инструмента планирования; сохранены все 21 отправленный ход и известный расход USD 0.2493285. Отвергнутые ответы не переносятся в валидную матрицу.

Список литературы

- [1] H. Sun and S. Zeng. Introspection of Thought Helps AI Agents. arXiv:2507.08664v1, 2025. <https://arxiv.org/abs/2507.08664v1>.
- [2] D. Tran and D. Kiela. Single-Agent LLMs Outperform Multi-Agent Systems on Multi-Hop Reasoning Under Equal Thinking Token Budgets. arXiv:2604.02460v2, 2026. <https://arxiv.org/abs/2604.02460v2>.
- [3] C. S. Xia, Y. Deng, S. Dunn, and L. Zhang. Agentless: Demystifying LLM-based Software Engineering Agents. arXiv:2407.01489, 2024. <https://arxiv.org/abs/2407.01489>.
- [4] J. Yang et al. SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering. NeurIPS, 2024. <https://arxiv.org/abs/2405.15793>.
- [5] T. Y. Zhuo et al. BigCodeBench: Benchmarking Code Generation with Diverse Function Calls and Complex Instructions. ICLR, 2025. <https://arxiv.org/abs/2406.15877>.
- [6] C. E. Jimenez et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR, 2024. <https://arxiv.org/abs/2310.06770>.
- [7] SWE-bench maintainers. Evaluation Guide. Accessed 8 September 2026. <https://www.swebench.com/SWE-bench/guides/evaluation/>.
- [8] OpenAI. Why SWE-bench Verified no longer measures frontier coding capabilities. 2026. <https://openai.com/index/why-we-no-longer-evaluate-swe-bench-verified/>.

- [9] OpenRouter. Models API and provider usage metadata. Snapshot accessed 8 September 2026. <https://openrouter.ai/api/v1/models>.
- [10] D. Privezentsev. INoT_Research. Historical implementation, commit 010211ee5775185e8330ab6cde06e912c2adcb9e. https://github.com/daniil-novel/INoT_Research.
- [11] D. Privezentsev. Article-INoT: manuscript, historical artifacts and compression-free revision protocol. 2026. <https://github.com/daniil-novel/article-INoT>.
- [12] OpenAI. GPT-5.4 mini model documentation. Accessed 8 September 2026. <https://developers.openai.com/api/docs/models/gpt-5.4-mini>.
- [13] OpenAI. API pricing, standard text-token rates. Accessed 8 September 2026. <https://developers.openai.com/api/docs/pricing>.
- [14] OpenAI. Codex non-interactive mode and JSONL event stream. Accessed 8 September 2026. <https://developers.openai.com/codex/noninteractive>.
- [15] OpenAI. Codex CLI 0.152.0 release notes: planning tool configuration. 1 September 2026. <https://github.com/openai/codex/releases/tag/rust-v0.152.0>.
- [16] M. Zheng, J. Pei, L. Logeswaran, M. Lee, and D. Jurgens. When “A Helpful Assistant” Is Not Really Helpful: Personas in System Prompts Do Not Improve Performances of Large Language Models. Findings of EMNLP, pp. 15126–15154, 2024. <https://aclanthology.org/2024.findings-emnlp.888/>.
- [17] P. H. Luz de Araujo, P. Röttger, D. Hovy, and B. Roth. Principled Personas: Defining and Measuring the Intended Effects of Persona Prompting on Task Performance. EMNLP, pp. 26857–26886, 2025. <https://aclanthology.org/2025.emnlp-main.1364/>.
- [18] H. K. Choi, X. Zhu, and S. Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? NeurIPS, 2025; arXiv:2508.17536v2. <https://arxiv.org/abs/2508.17536v2>.
- [19] F. V. Wunderlich, L. B. Kaesberg, J. P. Wahle, T. Ruas, and B. Gipp. Multi-Agent Reasoning Improves Compute Efficiency: Pareto-Optimal Test-Time Scaling. ACL Student Research Workshop, pp. 1–14, 2026. <https://aclanthology.org/2026.acl-srw.1/>.