

Hybrid-INoT: разделение функций по ролям и внешняя проверка при генерации кода

Даниил Привезенцев^{1*}

^{1*} Национальный исследовательский университет «Высшая школа экономики», Москва, Россия.

Для корреспонденции: daprivezentsev@edu.hse.ru;

Аннотация

Hybrid-INoT объединяет планирование, реализацию и критику внутри одного ответа модели с внешней проверкой программы тестами. Мы формализуем однопроходное ядро и исследуем ролевые и нейтральные инструкции в сочетании с одним и тремя вызовами, сохраняя операции и полный контекст задачи. Пятое условие — прямой решатель. В крупнейшем эксперименте GPT-5.6 Luna с уровнем рассуждения medium назначено 15 000 генераций для 1 000 кластеров задач BigCodeBench с тремя свежими повторами на условие: 200 идентификаторов задач повторно использованы из первого факторного эксперимента, а 800 являются дополнительными. Штатный оценщик проверил все 14 961 завершённую программу; контрольные проверки позволяют оценить качество на 985 задачах. Наблюдаемый успех составляет от 50.07% до 54.59%. Разности качества между ролевыми и нейтральными инструкциями равны -0.75 процентного пункта в одном вызове и $+1.35$ при трёх; ни одно сравнение не проходит поправку Холма для четырёх основных тестов. Три вызова снижают качество на 4.17 пункта при нейтральных инструкциях и на 2.13 при ролевых, увеличивая денежную оценку по тарифам API в 2.67 и 2.78 раза соответственно. Сравнения дополнены интервалами по целым задачам и группам сходных задач, таблицами всех повторов и явным учётом пропусков; основные контрасты используют оценку по полным парам задач и сохраняют 264 неизвестных исхода. Ранее завершённые факторный эксперимент на 200 задачах и исследование обозначений и разметки на 80 задачах рассматриваются отдельно с учётом различий моделей и выборов. Результаты выявляют издержки проверенной структуры вызовов, но не устанавливают общую пользу названий ролей для качества, неухудшение качества или существование независимых внутренних агентов.

Ключевые слова: Hybrid-INoT, разделение функций по ролям, внешняя проверка, токенная эффективность, факторный дизайн, генерация кода

1 Введение

Система для разработки программ должна интерпретировать спецификацию, использовать относящиеся к задаче код и документацию, построить решение и проверить его тестами. Эти функции можно распределить между этапами планирования, реализации и проверки. Если отдельные вызовы модели получают одни и те же материалы, контекст приходится передавать повторно. Мы исследуем, можно ли сохранить эти функции при меньшем числе вызовов, оставив проверку корректности внешним тестам.

Hybrid-INoT отвечает на этот вопрос сочетанием нескольких предписанных функций в одном ответе модели и последующей проверки программы исполняемыми тестами. Планирование, реализация и проверка задаются в общем вызове модели, а внешняя процедура оценивает полученную программу. Дизайн развивает мотивацию внутреннего диалога INoT [5], но исследуемая ролевая конфигурация отличается от исходного алгоритма PromptCode. Она отделяет генерацию программы от проверки её корректности. Повторная передача длинного общего контекста мотивирует анализ затрат, но сама по себе не гарантирует сохранения качества при одном вызове.

Исходная реализация Hybrid-INoT включала также отбор контекста и избирательные повторы. Сравнение целых конфигураций изменяло эти механизмы вместе с топологией вызовов и потому не выделяет вклад внутренних ролей. Настоящая оценка изолирует одношаговое ядро архитектуры: полный предоставленный контекст, один итоговый кандидат, предписанные планирование, реализацию и проверку, а также последующее штатное тестирование. Компрессия и повторы по результатам проверки отключены. Раздельная оценка компонентов позволяет проверить проектные решения Hybrid-INoT в рамках исходной инженерной задачи.

У ядра есть два разных эмпирических вопроса. Меняют ли названия ролей результат при неизменных операциях этапов? Как выполнение этих операций в одном ответе соотносится по качеству и ресурсам с их распределением по трём вызовам? Прямой решатель проверяет полезность поэтапной организации в целом. Отдельная адаптация INoT исследует родственную алгоритмическую альтернативу. Каждое условие получает одинаковую задачу и контекст и оценивается одной последующей процедурой. Внутренняя проверка, описанная в запросе, не считается отдельным измеренным исходом.

Вклад работы включает:

1. Операционное описание однопроходного ядра Hybrid-INoT, его состояния и границы внешней оценки с соответствием реализованным контрольным условиям.
2. Условный баланс токенов общего контекста, который объясняет возможную экономию при меньшем числе вызовов без предположения о равной длине ответов.

3. Факторный эксперимент 2×2 без компрессии с прямым решателем на 1 000 задачах BigCodeBench, тремя повторами каждого условия и 14 961 программой, проверенной штатными тестами. Четыре заранее заданных сравнения отделяют ролевые обозначения от структуры вызовов.
4. Дополнительные данные первого факторного эксперимента на 200 задачах, исследования обозначений и разметки на 80 задачах, разработки, адаптации INoT и демонстрации исправления одного репозитория. В приложениях сохранены инструкции и все повторные исходы.

Абляции ролей и исследования числа взаимодействий имеют близких предшественников; вклад работы заключается в определённой архитектурной оценке и её проверяемых данных. Большой эксперимент показывает увеличение расхода и снижение успеха тестов при разделении этапов на три вызова. Общая польза названий ролей для качества и неухудшение качества не установлены.

2 Связанные исследования

2.1 Ближайший методологический предшественник

В работе Self-collaboration Code Generation via ChatGPT [1] уже исследованы ролевые инструкции и максимум взаимодействий в разделах 5.2–5.3. Поэтому удаление ролей или изменение взаимодействий не заявляется новизной настоящего исследования. Таблица 1 разграничивает реализованные воздействия.

Таблица 1 Сопоставление с ближайшим предшественником [1], таблицы 3–4 и приложение B.1. Раунды взаимодействия и новые вызовы модели являются разными величинами.

Аспект	Статья Self-collaboration	Компонентный эксперимент
Обозначения	Ролевые инструкции и инструкции без ролей	Одинаковые предложения об операциях; меняются только префиксы этапов
Взаимодействие	Цикл обратной связи; варьируется максимум взаимодействий	Один или три новых вызова; фиксированная последовательность, полная видимая история
Дизайн	Раздельные абляции ролей и взаимодействия	Совместная матрица обозначений и вызовов для каждой отобранной задачи
Задачи	HumanEval, MBPP и расширенные тесты	Резервная выборка BigCodeBench; эталонные и неправильные контроли до генерации

Работа расширяет предшествующее сравнение и делает его проверяемым: совместный дизайн оценивает взаимодействие обозначений и топологии вызовов при

одном интерфейсе генерации, а связь результатов штатных тестов с проверенными программами и компоненты токенов делают различия качества и ресурсов проверяемыми.

Self-collaboration является ближайшим внешним методом: его абляция ролей затрагивает тот же вопрос об источнике эффекта. Во внешнем сравнении используется закреплённая авторская реализация 2024 года, которая исполняет сгенерированные тесты, тогда как статья 2023 года описывает имитацию тестирования (раздел 14.3). Зафиксированное сравнение назначает SCC, новые SR и SN на те же 1 000 задач с тремя повторами; варианта SCC без ролей в нём нет. Поэтому оно оценивает различия полных процедур, включая обратную связь и остановку, а SR–SN и MR–MN выделяют эффект заданных обозначений в компонентном дизайне. Две проверки разработки подтверждают работоспособность процедуры, но основная серия ещё не завершена. Д служит минимальным сравнением. INoT* отвечает на отдельный вопрос об алгоритме внутреннего диалога.

2.2 Внутренний диалог и репозиторные методы

INoT описывает компактные инструкции PromptCode для внутреннего диалога и рассуждения [5]. Это мотивирует оценку раскрытой адаптации алгоритма, тогда как отдельное минимальное воздействие обозначений проверяет, меняют ли результат сами названия ролей. Сравнения отвечают на разные вопросы: инструкция INoT изменяет процедуру рассуждения, а факторный контраст обозначений сохраняет предложения с описанием операций. Исходное сравнение Hybrid-INoT дополнительно изменяло компрессию и повторные попытки; его прежние условия рассматриваются только как контекст и не объединяются с новым экспериментом.

Исследование одно- и многоагентных систем при сопоставимом бюджете токенов рассуждения подчёркивает различие дополнительных вызовов и вычислений [6]. Поскольку здесь длина завершения не ограничена общим жёстким бюджетом, токены и денежная оценка рассматриваются вместе с качеством как исходы реализованных протоколов; оптимальное распределение фиксированного бюджета инференса из этого дизайна не следует.

Agentless использует структурированный процесс локализации, исправления и проверки [7]; SWE-agent связывает модель с интерфейсом репозитория [8]. Обе системы добавляют поиск, инструменты и взаимодействие с окружением сверх генерации функций при фиксированном контексте. Их опубликованные оценки нельзя вставлять в парную матрицу с другими задачами и настройками. BigCodeBench [9] предоставляет разнообразные задачи с библиотечными зависимостями и исполнимыми тестами, а SWE-bench [10, 11] проверяет изменения репозитория тестами конкретных задач из трека ошибок. Штатная оценка связывает исходы с исполняемыми тестами, однако успешный эталонный контроль не разрешает каждое расхождение естественно-языковой инструкции и теста.

Обратная связь является отдельным выбором в дизайне метода. Self-Refine чередует замечания и исправления, полученные от той же модели [3]. Reflexion сохраняет словесные выводы между попытками; в его экспериментах с программированием обратную связь дают исполняемые тесты, созданные моделью [4].

Условия нашего компонентного эксперимента не получают результатов исполнения во время генерации и следуют фиксированной последовательности, поэтому не воспроизводят эти адаптивные процедуры. Авторская реализация SCC использует сгенерированные тесты как часть своей полной процедуры. В наших экспериментах тесты бенчмарка и эталонные программы недоступны интерфейсу генерации; внутреннее исполнение SCC не определяет успех на бенчмарке. Поэтому доступ к обратной связи и остановка входят в сравнение внешних методов, а не доказывают эффект ролевых обозначений. Self-Refine и Reflexion включены в методологическое сопоставление; экспериментальные запуски этих методов здесь не выполнены.

Исследования persona prompting мотивируют более узкое утверждение, чем универсальная польза ролей для рассуждения. Zheng и соавторы не обнаруживают устойчивого улучшения от системных персон в исследованных фактологических задачах [16]. Luz de Araujo и соавторы разделяют качество, устойчивость к несущественным атрибутам персоны и соответствие заданной специализации; результаты зависят от модели и задачи [17]. Эти работы не проверяют наши запросы на генерацию кода. Они обосновывают изменение обозначений при сохранении требуемых операций и ограничение вывода конкретными использованными обозначениями.

Данные о нескольких агентах также зависят от выбранного сравнения. Choi и соавторы связывают значительную часть выигрыша в своих NLP-экспериментах с независимым голосованием, отделяя обмен сообщениями от агрегации [18]. В то же время Wunderlich и соавторы находят конфигурации, в которых debate или mixture-of-agents улучшают соотношение вычислений и точности относительно self-consistency на MMLU-Pro и BVH [19]. Это основание для условной оценки, а не универсального вывода за или против нескольких агентов. Наша нейтральная последовательная цепочка не является голосованием, смесью независимых моделей или ансамблем с выровненным бюджетом. В работе выполнена факторная проверка одной модели на исполняемом коде с сохранением трасс и учётом доступных счётчиков ресурсов; общее превосходство над перечисленными альтернативами не входит в оцениваемый эффект.

3 Формальная постановка и ядро Hybrid-INoT

3.1 Инженерная задача и наблюдаемый успех

Инженерная задача задаётся тройкой $(x, C_0, \mathcal{V})$: спецификацией x , зафиксированным входным контекстом C_0 и внешней процедурой проверки $\mathcal{V}$. Результатом являются программа-кандидат y и запись проверки этой программы. Генерация и проверка являются разными операциями: модель предлагает решение, а исходные исполняемые тесты определяют результат бенчмарка в контролируемом окружении. Текстовое утверждение о корректности не заменяет тесты. Для задач с репозиторием C_0 обозначает раскрытый пакет найденных файлов, а не предположение о передаче всего репозитория.

Для протокола исполнения a инженерная цель состоит в повышении вероятности успешного прохождения тестов при контроле ожидаемого числа токенов

и денежной оценки генерации. Поэтому качество и ресурсы сообщаются совместно, без оптимизации непроверенного взвешенного показателя. Наблюдаемые программы, провалившие тесты, считаются неуспешными; недоступный этап генерации или оценки нельзя превращать в успешный исход либо в вымышленный отказ тестов. Раздел 5 задаёт общий контроль оцениваемости и точный статистический исход.

3.2 Разделение функций и внешняя проверка

Hybrid-INoT задаёт в ответе модели три функции: планирование, реализацию и проверку требований; сама проверка программы выполняется после генерации. «Гибридность» означает сочетание инструкций в запросе с последующими исполняемыми тестами. Для этого не требуется обученный маршрутизатор. Исходная терминология `planner-worker-critic` соответствует исполняемым обозначениям **planner**, **implementer** и **reviewer**. Здесь изучается разделение предписанных функций, а не наличие независимо наблюдаемых скрытых агентов.

Исследуемое одновызовное ядро предписывает три операции: анализ требований и граничных случаев, реализацию по плану, затем проверку и исправление относительно требований. Один вызов модели получает все три инструкции и весь предоставленный контекст; он возвращает одну итоговую программу. Отдельные внутренние планы и оценки не наблюдаются. Поэтому концептуальное разделение функций не следует принимать за три измеренные подпрограммы. Точные запросы, включая требование к итоговому формату, приведены в приложении.

В основном эксперименте SR соответствует этой ролевой одновызывной конфигурации. SN является её аблацией обозначений ролей при одинаковых предложениях об операциях. MR и MN распределяют соответствующие операции по трём новым вызовам, а D полностью убирает поэтапную процедуру. Для всех пяти условий используется одинаковая последующая стандартная оценка. Дизайн позволяет оценить, как заданные этапы соотносятся с результатом по сравнению с простой инструкцией и что меняется при распределении тех же операций по отдельным вызовам. У Hybrid-INoT нет преимущественного доступа к проверке.



Рис. 1 Два варианта генерации: SR задаёт три функции одним запросом, MR распределяет их по трём вызовам. Стрелки между вызовами MR означают передачу полных предыдущих ответов; задача и контекст доступны в каждом вызове. Показан путь полученного ответа. Незавершённая генерация учитывается отдельно по алгоритму 1. Все пять условий из табл. 2 используют одну процедуру внешней оценки, без передачи результатов тестов обратно модели.

3.3 Состояние, исполнение и остановка

Наблюдаемое состояние исполнения задаётся как $\sigma_j = (x, \mathcal{C}_0, a, j, \mathcal{H}_j)$, где a фиксирует назначенное условие, j — номер вызова, а $\mathcal{H}_j$ содержит все полные предыдущие выведенные ответы. Конфигурация модели внутри сравнения фиксирована. Для D, SR и SN число вызовов $n_a = 1$; для MR и MN $n_a = 3$. В многовызовном условии $\mathcal{H}_j$ передаётся целиком. Предоставленный контекст не изменяется: $\hat{\mathcal{C}} = \mathcal{C}_0$. Условие назначается до генерации и потому не является политикой маршрутизации по результату.

Алгоритм 1 Генерация программы и проверка результата

Вход: задача, полный предоставленный контекст и заранее назначенное условие.

Выход: полученная программа, исход проверки и известный расход ресурсов.

I. Генерация

1. Определить число вызовов: один для D, SN или SR; три для MN или MR.
2. Выполнить вызовы последовательно. В каждый передать задачу, неизменный контекст и заданную инструкцию. Во второй и третий вызовы добавить все полные предыдущие ответы.
3. Для каждого вызова сохранить запрос, полный ответ, конечный статус и счётчики токенов.
4. Если вызов не завершён или учёт ресурсов не подтверждён, сохранить доступные сведения и остановить это назначение как недоступное. Не повторять его автоматически.
5. Из последнего завершённого ответа извлечь одну программу. Если формат неверен, считать кандидата пустым.

II. Проверка после окончания генерации

6. Проверить каждого полученного кандидата исходными тестами бенчмарка.
 7. Сопоставить проверенную программу, отчёт оценщика и результаты общих контрольных проверок.
 8. Записать успех, неуспех или недоступный исход. Сохранить все известные показатели ресурсов; не возвращать результаты тестов модели.
-

Алгоритм 1 описывает этапы генерации и оценки эксперимента; стандартный оценщик запускается после генерации и не является инструментом внутри вызова модели. Лимит времени и конечное n_a ограничивают попытки генерации. Это правило остановки, а не теорема о сходимости или корректности. Отклонённое завершение не вызывает автоматическую повторную попытку той же ячейки. Дополнительно запускаются только те назначения, для которых не начался ни один вызов.

Конфигурация фиксирует дополнительные механизмы исходной архитектуры: отбор контекста тождественный, режим назначен, итоговый кандидат один, повторные генерации по проверке отключены. Так вопрос о заданных функциях

можно исследовать, не смешивая его с компрессией, малой проверяющей моделью и адаптивными повторами. Этим же определяется объём вывода: эксперимент оценивает данное ядро, а не все возможные варианты применения Hybrid-INoT.

4 Аналитическая модель затрат на общий контекст

4.1 Условный баланс токенов

Архитектурная мотивация связана с повторной передачей общего материала. Рассмотрим аддитивную модель учёта, в которой общий блок задачи и контекста вносит S токенов при каждой передаче. Внутренняя конфигурация H передаёт его один раз; внешняя M — в каждом из m вызовов. Пусть J_H, J_M содержат все остальные входные токены, включая оболочки инструкций и передаваемые ответы, а O_H, O_M — все выходные токены. Обозначим $R_H = J_H + O_H$, $R_M = J_M + O_M$. Тогда

$$T_H = S + R_H, \quad T_M = mS + R_M, \quad T_M - T_H = (m - 1)S + R_M - R_H. \quad (1)$$

Это тождество учёта при указанной модели блоков. Оно не предполагает равной длины выхода. В частности, более длинное рассуждение внутри одного вызова может компенсировать сокращение передачи контекста; внешние промежуточные ответы учитываются и при генерации, и при повторной передаче.

Утверждение 1 (Условное достаточное ресурсное преимущество). *Для $m > 1$ предположим, что $\mathbb{E}[R_H - R_M \mid S] \leq K$ во всём заданном диапазоне контекста, причём постоянная $K \geq 0$ не зависит от S в этом диапазоне. Из (1) следует*

$$\mathbb{E}[T_M - T_H \mid S] \geq (m - 1)S - K.$$

Поэтому ожидаемое преимущество внутренней конфигурации по токенам положительно при $S > K/(m - 1)$ внутри данного диапазона.

Доказательство Вычтем два баланса в (1), возьмём условное ожидание при S и применим предполагаемую верхнюю границу для $\mathbb{E}[R_H - R_M \mid S]$. $\square$

Ограничение остатка является содержательным предположением, а не измеренным свойством модели. Если выход или координационные затраты меняются с контекстом так, что граница нарушается, существование порога не следует. Условие сохраняет мотивацию Hybrid-INoT для длинного общего контекста и одновременно обозначает её пределы. В текущей выборке длина контекста не варьируется как воздействие и K не оценивается; определить порог преимущества или маршрутизации по ней нельзя. Прежние пилоты с компрессией также не определяют эти величины.

Эмпирический учёт использует фактические счётчики поставщика,

$$T_a = \sum_{j=1}^{n_a} (I_{a,j} + O_{a,j}), \quad (2)$$

а не оценивает суммы по (1). Незвестный расход остаётся неизвестным. Концептуальный блок S не отождествляется с измеренным аддитивным разбиением входа поставщика: границы токенизации и накладные расходы клиента могут препятствовать такому разбиению. Поэтому теоретический баланс не следует выдавать за наблюдаемую декомпозицию. При фиксированной топологии общий член сокращается между ролевым и нейтральным условиями; их ресурсная разность относится к изменениям формулировок и другим остаточным различиям. Поэтому в дизайне предусмотрены оба контроля обозначений.

4.2 Качество и деньги как отдельные ограничения

Обозначим успешное прохождение тестов через $Q_a = \mathbb{E}[Y_t(a)]$, а ожидаемое число токенов через $\bar{T}_a = \mathbb{E}[T_a]$. Исходное инженерное понятие токеной полезности можно записать как $U_a = Q_a/\bar{T}_a$, используя отношение ожиданий на общей полнотью наблюдаемой совокупности. Более высокое U_a может сочетаться с худшим Q_a и не подтверждает сохранение качества. Поскольку в исследовании различаются также доступные подвыборки качества и ресурсов, основной отчёт сохраняет отдельно парные разности качества и ресурсные отношения, не строя составной показатель полезности и не вводя непроверенные веса.

Аналогичный денежный расчёт должен учитывать тарифы для входных, кешированных входных и выходных токенов. Оценки V и V_0 по API-тарифам в разделе 5 реализуют это требование по сохранённым счётчикам. Преимущество по токенам само по себе не устанавливает денежного преимущества при различающихся долях кеша и выхода. Ни одна из оценок не измеряет платёж по подписке или полную стоимость владения; вычисления оценщика, инженерная работа и эксплуатация лежат вне наблюдаемого учёта.

Баланс задаёт возможное объяснение ресурсного различия. Изменяется ли качество, полезны ли обозначения ролей и связана ли наблюдаемая ресурсная разность с конфигурацией одного вызова — эмпирические вопросы факторного эксперимента. Аналитическое объяснение не добавляет подтверждающей гипотезы к четырём тестам, зафиксированным до основного запуска.

5 Оценка компонентов: дизайн и оцениваемые эффекты

5.1 Факторный эксперимент без компрессии

Основной эксперимент оценивает ядро Hybrid-INoT и его контроли: независимо варьируются число вызовов модели (один или три) и обозначения этапов (нейтральные или ролевые). Таблица 2 определяет четыре факторных условия

и прямой решатель. Во всех структурированных условиях предписаны одинаковые операции: анализ требований и граничных случаев, реализация по плану, затем проверка и исправление относительно требований. Ролевое воздействие заменяет обозначения «stage 1», «stage 2», «stage 3» на «planner», «implementer», «reviewer»; предложения с описанием операций остаются неизменными. При одном вызове все три инструкции предшествуют задаче. При трёх вызовах каждый получает инструкцию своего этапа, полный текст задачи, весь предоставленный контекст и все полные предыдущие видимые ответы. Итоговый формат одинаков: ровно один блок с полной программой Python. Прямой решатель получает только инструкцию реализации и требование к итоговому формату.

Таблица 2 Реализованные условия. Фактор числа вызовов включает передачу промежуточных ответов между новыми вызовами.

Код	Вызовы	Обозначения	Операции
D	1	Нет	Прямая реализация
SN	1	Нейтральные	План, реализация, проверка
SR	1	Ролевые	План, реализация, проверка
MN	3	Нейтральные	План, реализация, проверка
MR	3	Ролевые	План, реализация, проверка

Компрессия отсутствует во всех условиях. Такая постановка заменяет прежнее сравнение трёх вызовов без сжатия с одним сжатым вызовом, но не оценивает эффект прежнего компрессора. Контраст обозначений является воздействием на инструкцию, а не свидетельством независимых внутренних агентов. Контраст числа вызовов включает поток промежуточной информации и повторный инференс, а не только механическое изменение счётчика вызовов. Непроверенные маршрутизатор и дополнительная модель проверки исключены из заявленного метода.

Пусть $Y_t(a)$ показывает, прошла ли единственная итоговая программа для задачи t в условии a исходные тесты бенчмарка в проверенном окружении. Четыре заранее заданных парных эффекта качества имеют вид

$$\Delta_{R,1} = \mathbb{E}_t[Y_t(\text{SR}) - Y_t(\text{SN})], \quad \Delta_{R,3} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{MN})], \quad (3)$$

$$\Delta_{C,N} = \mathbb{E}_t[Y_t(\text{MN}) - Y_t(\text{SN})], \quad \Delta_{C,R} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{SR})]. \quad (4)$$

Каждая нулевая гипотеза задаёт нулевую разность качества. Описательное взаимодействие равно $\Delta_{R,3} - \Delta_{R,1}$. Ожидания относятся к выборке задач при реализованном протоколе и стохастической генерации, а не к свойству, независимому от поставщика модели. Оценки по доступным данным требуют полных пар; при пропусках без дополнительных предположений они характеризуют именно наблюдаемую подвыборку.

5.2 Распределение задач и отдельный этап разработки

Источник задач — BigCodeBench v0.1.4 [9]. Основная выборка содержит 200 новых идентификаторов из случайной перестановки резервного пула: идентификаторы сначала сортировались лексикографически, затем перемешивались генератором Python с начальным состоянием 20260908. Взяты первые 200 допустимых идентификаторов в этом случайном порядке после исключения восьми примеров карточки набора данных (/0–/7), случайно просмотренных при проверке лицензии. Это не первые строки датасета и не отбор по сложности. Идентификаторы, входы модели и данные оценщика фиксируются до контрольных запусков; неудачный контроль не приводит к замене задачи. Сорок задач разработки не пересекаются с этими 200. Этап разработки включает два обозначенных повтора и 400 программ, основная выборка — один новый повтор и 1 000 назначений. Последние дают не более 200 независимых единиц выборки, а не 1 000 независимых задач. Родственные задачи могут дополнительно уменьшать эффективную независимость. Публичность бенчмарка оставляет открытым вопрос о наличии задач в обучающих данных.

Назначение означает запланированную генерацию для заданной задачи, условия и повтора; начатое назначение считается попыткой. Каждой основной задаче назначены все пять условий. Четыре непересекающиеся группы по остатку индекса от деления на четыре содержат по 50 задач. В каждой группе зафиксированный псевдослучайный порядок определяет блоки задач и порядок условий; группу обрабатывают два работника, одновременно действует не более восьми экспериментальных процессов CLI. Матрица назначений и реализация зафиксированы до отправки запросов. Построение входа и настройки оценщика приведены в приложении В. Модель не получает тесты бенчмарка, эталонные решения или результаты тестирования во время генерации. Метки повторов обозначают новые наблюдения по протоколу, а не случайные состояния модели у поставщика.

5.3 Генерация и полные доступные трассы

Используется модель с идентификатором `gpt-5.4-mini`, уровень рассуждения `medium` и официальный Codex CLI 0.153.4 с аутентификацией подписки ChatGPT [12, 15]. Опубликованный тариф позволяет проверить денежную оценку ресурсов; выбранная конфигурация является экономичным доступным вариантом для кода, но глобальный минимум цены не доказан. CLI работает с чистой конфигурацией без пользовательских инструкций и инструкций проекта. Инструменты, браузер, делегирование и выполнение тестов отключены. Каждый вызов создаёт новую временную сессию в пустом рабочем каталоге. Допустимая схема событий требует ровно одного полного ответа и корректной записи использования; неожиданный инструмент, повтор или событие сжатия нарушают заданное текстовое условие.

Для каждого отправленного вызова сохраняются точный промпт, аргументы, поток событий, стандартный поток ошибок и конечное состояние. Для завершённых записей дополнительно сохраняются итоговый текст и компоненты числа токенов. Для каждого последующего вызова проверяется, что его вход содержит

все предыдущие доступные ответы целиком. Доступность скрытых рассуждений поставщика не предполагается. Псевдоним модели не фиксирует неизменные веса; проверенное управление температурой и случайным состоянием модели отсутствует. На вызов установлен предел 180 секунд. Вход свыше 65 536 байт UTF-8 отклоняется, а не сокращается. Единого жёсткого ограничения выходных токенов нет; длина ответа и потребление ресурсов являются результатами воздействия.

Исходное правило останавливает группу после первой неудачной попытки. Поэтому сетевые обрывы и превышения времени оставляют другие назначения неотправленными. Отдельная поправка к протоколу, записанная до оценки или просмотра качества основной выборки, разрешает продолжить только такие неотправленные назначения. Любое назначение хотя бы с одним начатым этапом навсегда исключается из продолжения. Список оставшихся назначений и записи первой серии фиксируются до продолжения; сохраняются промпты, настройки, ограничения времени и исходный порядок внутри группы. Явный сетевой обрыв или превышение времени завершает попытку без повтора; ошибки квоты, аутентификации и нераспознанные ошибки останавливают дальнейшую отправку. Первые попытки, продолжения и пропуски остаются различимыми. Таким образом, анализ использует заранее заданные контрасты при изменённом протоколе исполнения; это не неизменённый пререгистрированный запуск.

5.4 Штатная оценка и контроль оцениваемости

Неизменённый оценщик BigCodeBench выполняет тесты набора v0.1.4 в режиме `instruct full`. Каждый запуск оценщика использует контейнер без сети, от непривилегированного пользователя, с основной файловой системой только для чтения, пределом памяти 3 ГБ, двумя CPU и двумя работниками оценщика. Настройки оценщика и зависимости, добавленные на этапе проверки эталонов, приведены в приложении В. Строгое извлечение выбирает единственный итоговый блок Python; нарушение формата даёт пустую наблюдаемую программу и отдельный признак ошибки формата, без выбора альтернативного ответа или исправления.

До генерации модели исходные эталонные и заведомо неверные программы проверены на всех 200 задачах. Изменения зависимостей ограничены этапом контролей, сохраняют предыдущие неудачные запуски и вызывают повторные контроли всей матрицы. Итоговое окружение пропускает 193 эталона и отклоняет все 200 неверных программ. Поэтому семь задач недоступны для оценки качества во всех условиях; их назначения и ресурсы генерации сохраняются в учёте. Итоговый образ дополняет окружение разработки фиксированными зависимостями и автономными ресурсами NLTK. Штатная диагностика эталонов содержит ошибки DNS (/101, /590), отсутствие TensorFlow (/418), неподдерживаемый аргумент кодировщика (/686), проверки моментов вырожденной выборки (/276) и проверки архива/журнала (/14, /1028). Последующая проверка без изменения образа подтверждает отсутствие внешних команд, используемых последними двумя задачами; связь этих отказов с отсутствием команд является диагностическим выводом по исходникам. Позднейшая диагностика не меняет зафиксированный контроль оцениваемости. Контрольные проверки показывают, что задачу можно

оценивать и что тесты отклоняют заведомо неверное решение; они не доказывают полного смыслового соответствия инструкции тестам.

Оценщику передаются только реально полученные программы. Каждый результат связывается с фактически проверенной программой, исходным идентификатором задачи и проверенным окружением; незавершённые запуски оценщика и противоречивые отчёты не могут давать наблюдения качества. Исходный штатный статус хранится рядом с отдельным аналитическим статусом с учётом контроля оцениваемости. Для отсутствующей генерации не создаётся фиктивный отказ тестов. Одинаковый контроль применяется ко всем условиям и поисковой репликации INoT.

5.5 Область завершённого расширения Luna и изменённого исследования SCC

Предшествующие дизайн, оцениваемые эффекты и тесты Мак-Немара описывают первоначальное исследование на 200 задачах и сохраняются как его отдельный исторический анализ. Завершённое расширение является отдельным исследованием Luna на 1 000 задачах: 15 000 назначений, 14 961 завершённая программа и 985 задач, допущенных контрольными проверками; 264 назначения имеют неизвестный исход качества. Оно повторно использует первые 200 идентификаторов и добавляет 800 идентификаторов из зафиксированного случайного порядка, поэтому не является новой отложенной выборкой. Его исходный оценщик трёх повторов и семейство Холма из четырёх тестов сохраняются; с первым мини-опытом результаты не объединяются.

Сравнение с SCC проводится в отдельной области изменённого протокола. Выбранный префикс состоит из первых 2 000 блоков задача–повтор исходного расписания из 3 000 блоков: 6 000 назначений трёх методов на 956 задачах, из которых 941 допускается контрольными проверками. Остальные 3 000 назначений административно не выбраны. Основной изменённый эффект SCC сопоставляет одни и те же выбранные метки повторов только при наличии наблюдаемого нативного исхода у SCC и сравниваемого метода, усредняет парные двоичные разности внутри задачи и даёт участвующим задачам равные веса. Контрасты SCC–SR и SCC–SN образуют фиксированное семейство из двух тестов Холма; процентильные интервалы используют 10 000 выборок целых задач, seed 20260911, NumPy PCG64 и линейную интерполяцию. Генерация продолжается, нативные исходы ещё не просмотрены. Восемь прерванных отправленных попыток остаются неизвестными на паузе и не повторяются. Ресурсный анализ требует полных оценённых по тарифу процессов и известных счётчиков каждого отправленного вызова; частичные суммы учитываются отдельно.

Для оценки ресурсов расширения Luna используются проверенные текущие эквивалентные тарифы API: USD 0,20 за миллион входных токенов, USD 0,02 за миллион кешированных входных токенов и USD 1,20 за миллион выходных токенов. Эти тарифы отделены от тарифа первого мини-опыта и дают контрфактическую оценку, а не счёт за подписку или оценку полной стоимости. Обозначение модели и повторные запросы не фиксируют неизменные веса провайдера и не подтверждают независимость генераций.

5.6 Статистический анализ, пропуски и оценка ресурсов

Для каждого из четырёх запланированных контрастов качества приводятся число полных пар, оба числа несогласованных исходов, средняя парная разность, точный двусторонний биномиальный тест Мак-Немара и скорректированное по Холму p для семейства четырёх тестов при $\alpha = 0.05$. Только эти четыре теста Мак-Немара определяют основное семейство проверок; бутстрэп-интервалы и тесты смены знаков не служат критерием основного отклонения гипотезы. Процентильные интервалы используют 10 000 бутстрэп-выборок задач с начальным состоянием анализа 20260908; эти описательные интервалы не являются одновременно интервалами. Взаимодействие, ресурсные контрасты и сравнения с прямым решателем остаются описательными. Взаимодействие использует задачи с полными наблюдениями во всех четырёх факторных условиях; оно может не совпадать с вычитанием двух отдельно оценённых ролевых контрастов, если их доступные подвыборки различаются. Повторы разработки усредняются внутри задачи в отдельном описательном анализе и не объединяются с основными тестами.

При 200 независимых оцениваемых задачах наихудшая нормальная 95%-полуширина для одной доли приблизительно равна 6.9 процентного пункта. Это обоснование точности, а не расчёт 80%-мощности для парного эффекта; неопределённость парной разности зависит от несогласованных исходов. Приемлемая потеря качества для конкретного применения не получила внешнего обоснования, поэтому граница неухудшения и решение о сохранении качества не используются. Порог, выбранный только под статистическую точность, не устанавливал бы практически приемлемую потерю. Качество условия оценивается по доступным наблюдениям и сопровождается границами пропусков по всем назначениям: недоступные исходы считаются сначала всеми неудачами, затем всеми успехами. Эти границы не являются доверительными интервалами или поправкой при случайных пропусках.

Завершённый вызов CLI возвращает счётчики входа I , кешированного входа C и выхода O . Кешированный вход входит в общий вход; отдельно доступное число токенов рассуждения входит в выход. Повторного суммирования нет. Опубликованные стандартные тарифы API составляют соответственно USD 0.75, 0.075 и 4.50 за миллион токенов [14]. Рассчитываются

$$V = \frac{0.75(I - C) + 0.075C + 4.50O}{10^6}, \quad V_0 = \frac{0.75I + 4.50O}{10^6} \quad \text{USD}. \quad (5)$$

V — эквивалентная стоимость фактически использованных токенов по тарифу API, а не платёж по подписке; V_0 — анализ чувствительности без скидки за кеш. Обе оценки исключают работу исследовательских ассистентов, разработку кода, сборку окружения и вычисления оценщика. Расход на программу рассчитывается как сумма её завершённых вызовов; затем эти значения усредняются по программам. Отдельный реестр включает доступные счётчики прерванных программ и явно считает вызовы без итогового учёта; неизвестное использование не заменяется нулём. Отношения ресурсов используют одну и ту же подвыборку полных

пар в числителе и знаменателе. «Меньшая наблюдаемая стоимость» означает отношение парных средних оценок ниже единицы, то есть отрицательную среднюю парную разность. Это описательный критерий: подтверждающий денежный порог и совместное правило решения о качестве и стоимости заранее не задавались; ресурсные интервалы не устанавливают денежное превосходство. Время отправки и состояние кеша могут влиять на денежную оценку, особенно между отдельно запущенными сериями.

6 Поисковая репликация алгоритма INoT

Четыре факторных условия проверяют отдельные компоненты, но не воспроизводят опубликованный метод целиком. Поэтому отдельно зафиксирована репликация инструкции INoT [5], обозначенная INoT*. Она использует те же 200 задач, полный предоставленный контекст, GPT-5.4 mini medium, итоговый формат и контроль оцениваемости. На задачу приходится один новый вызов, работают два работника с тем же пределом 180 секунд. Независимо сформулированная инструкция PromptCode описывает двух виртуальных участников, исходные ответы, взаимные аргументы, критику, возражения, обновления и проверку согласия с пределом десять раундов. Это концептуальная инструкция для модели, а не код, исполняемый на компьютере, или проверенная последовательность скрытых взаимодействий агентов.

Правило остановки следует текстовому описанию исходной статьи: согласие либо предел раундов. Соответствующий исходный листинг содержит неоднозначное условие цикла и не задаёт итоговый ответ при отсутствии согласия. В этой репликации явно возвращается последний ответ виртуального участника А. Добавление изображений исключено для текстовых задач. Точная инструкция приведена в приложении с запросами. Проверенная исполняемая авторская реализация для данной постановки не найдена; подтверждение адаптации авторами не заявляется.



Рис. 2 Как читать инструкцию INoT*. Пунктирная область описывает действия, предписанные в одном запросе: это не исполняемый цикл и не измеренные внутренние агенты. При согласии ответ A совпадает с ответом B; без согласия после десяти раундов инструкция выбирает последний ответ A. Дословный текст приведён в приложении [A.1](#).

Организационное продолжение использует то же правило «только ещё не отправленные»: начальная попытка с превышением времени не повторяется, а оставшиеся 137 ещё не начатых назначений фиксируются и отправляются по одному разу. Все трассы первой серии и продолжения хранятся отдельно. Сравнения INoT* с D и SR являются поисковыми и не входят в четыре основных теста. Парность контролирует состав задач, но отдельная серия сохраняет различия времени отправки, состояния кеша и возможного изменения модели у поставщика.

Наблюдаемый результат характеризует эту раскрытую адаптацию, а не точное воспроизведение чисел исходной статьи.

7 Факторный эксперимент на 1 000 задачах с повторными генерациями

7.1 Дизайн и завершённая оценка

В большом эксперименте сохранены пять условий D, SN, SR, MN и MR и полный входной контекст задачи. Используется GPT-5.6 Luna с уровнем рассуждения medium через Codex CLI 0.153.4. Для каждого условия выполнены три свежих запроса на задачу: всего 15 000 назначений для 1 000 кластеров задач и 27 000 запланированных вызовов. Метки повторов обозначают свежие запросы, а не задают seed модели у провайдера. Предельное время вызова составляет 600 секунд. Компрессия контекста и исправления по результатам тестов бенчмарка отключены. Кластеры задач являются единицами анализа; 264 исхода качества остаются неизвестными, а четыре контраста используют оценки по полным парам: 982, 964, 968 и 971 пары соответственно.

Выборка включает 200 задач первого факторного эксперимента и 800 дополнительных задач из исходного случайного порядка; задачи разработки и отдельного исследования разметки исключены. Все программы сгенерированы заново, прежние ответы с ними не объединяются. Следовательно, это расширенный эксперимент с другой запрошенной моделью, а не 1 000 новых отложенных задач или повторение при неизменных весах модели. Эталонные и заведомо неверные программы проверены до генерации; по этим контролям качество можно оценивать на 985 задачах. Сходство задач и пересечения между исследованиями рассмотрены отдельно.

Получена 14 961 завершённая программа; ещё 39 отправленных назначений остались незавершёнными. Все полученные программы прошли штатную проверку BigCodeBench. В анализе сохранены все 15 000 назначений, включая 264 неизвестных исхода качества из-за отсутствующих генераций или непригодных контролей. Неизвестный исход не считается провалом теста. В таблице 3 отдельно показаны завершение генерации и доступность оценки качества. Три попытки на одной задаче не считаются тремя независимыми задачами.

Для каждого из четырёх заранее определённых сравнений нужны все три оценки качества в обоих условиях. Разность средних по трём повторам сначала вычисляется внутри задачи, затем усредняется по задачам с равными весами. Поэтому четыре контраста используют свои числа полных пар задач. Основные двусторонние t -тесты образуют одно семейство из четырёх гипотез с поправкой Холма при $\alpha = 0.05$. Описательные 95%-е бутстрэп-интервалы используют 10 000 выборок целых задач и seed 20260909; они не заменяют поправку на множественные проверки. Оценивается успех одной генерации, а не лучшего из трёх выбранных ответов. Формулы и правила обработки пропусков приведены в приложении B.5.

Таблица 3 Факторный эксперимент Lupa: назначения и наблюдаемые исходы.

Условие	Назначено	Получено	Оценено	Успехов	Успех (%)
D	3000	2996	2951	1611	54.59
SN	3000	2998	2953	1604	54.32
SR	3000	2997	2952	1581	53.56
MN	3000	2983	2938	1471	50.07
MR	3000	2987	2942	1514	51.46

Оценено: доступные исходы качества после контроля пригодности, а не число разных задач. Процент успеха равен числу успехов, делённому на число оценённых повторов. В каждом условии назначены три повтора на задачу.

7.2 Роли, число вызовов и качество

Таблица 4 Сравнения качества в эксперименте Lupa. Разности и границы указаны в процентных пунктах.

Сравнение	Задач	Разность	95%-й интервал	p Холма	Границы
SR – SN	982	−0.75	[−1.97, 0.44]	0.2357	[−2.33, 0.83]
MR – MN	964	+1.35	[0.17, 2.56]	0.0599	[−0.63, 3.37]
MN – SN	968	−4.17	[−5.65, −2.75]	1.34×10^{-7}	[−6.00, −2.37]
MR – SR	971	−2.13	[−3.43, −0.82]	0.0044	[−3.83, −0.30]

Для включения задачи нужны три наблюдаемых повтора в каждом из сравниваемых условий. Границы учитывают все 1 000 задач и все назначенные повторы; это не доверительные интервалы.

В одном вызове разность между ролевыми и нейтральными инструкциями составляет −0.75 процентного пункта с 95%-м интервалом [−1.97, 0.44]. При трёх вызовах разность равна +1.35 пункта, интервал — [0.17, 2.56]. Последний интервал не включает ноль, но скорректированное значение $p = 0.0599$ не проходит заранее установленный порог семейства тестов. Таким образом, ни одно из двух сравнений ролевых обозначений не позволяет отклонить нулевую гипотезу по основному правилу вывода.

Распределение этапов по трём вызовам снижает наблюдаемую долю успешных решений относительно одного ответа: на 4.17 пункта при нейтральных инструкциях и на 2.13 пункта при ролевых. Оба сравнения проходят поправку Холма. Границы возможной разности с учётом всех назначений также остаются ниже нуля (таблица 4). Знак этих различий сохраняется даже при заполнении неизвестных двоичных исходов в пользу трёхвызовного варианта. Такие границы

учитывают пропуски, но не выборочную неопределённость и изменения сервиса модели.

Описательная разность двух ролевых эффектов между режимами одного и трёх вызовов составляет +2.08 пункта с интервалом $[0.42, 3.74]$ на общих 963 задачах. Это взаимодействие факторов, рассчитанное на одном наборе задач; оно не входит в семейство четырёх основных тестов. Ни один из четырёх векторов разностей не вырожден. Обоснованный допуск ухудшения качества и совместный критерий преимущества по качеству и стоимости не заданы, поэтому результаты не доказывают сохранение качества.




Рис. 3 Факторный эксперимент Luna: средние по задачам разности качества и описательные 95%-е бутстрэп-интервалы. Положительное значение соответствует преимуществу первого условия. Решения по основным гипотезам определяются отдельной поправкой Холма в таблице 4.

7.3 Расход ресурсов и устойчивость результатов

Таблица 5 Отношения расхода ресурсов в эксперименте Luna: первое условие делится на второе.

Сравнение	Задач	Токены	Оценка	95%-й интервал	Без кэша
SR - SN	997	0.986	0.939	$[0.93, 0.95]$	0.955
MR - MN	979	0.990	0.978	$[0.97, 0.99]$	0.986
MN - SN	983	3.078	2.672	$[2.63, 2.71]$	2.777
MR - SR	986	3.090	2.780	$[2.74, 2.82]$	2.867

Отношения делят суммы средних по трём повторам на задачах с полными ресурсными записями в обоих условиях. Интервал относится к отношению денежных оценок по тарифам API. Последний столбец убирает скидку за кэш входа; платежи за подписку не оцениваются.

Для ролевых инструкций в одном вызове отношение денежной оценки к нейтральным равно 0.939: оценка по тарифам API ниже на 6.08% на 997 задачах с полными тремя повторами в обоих условиях. Отношение числа токенов равно 0.986. При трёх вызовах соответствующие отношения составляют 0.978 и 0.990 на 979 задачах. Это описательные ресурсные различия; их величина меньше, чем разница для одного вызова в первом эксперименте с mini.

Изменение расхода при переходе к трём вызовам гораздо больше. Нейтральный вариант требует в 3.08 раза больше токенов и в 2.67 раза большей денежной оценки, чем нейтральный вариант с одним вызовом. Для ролевых инструкций отношения равны 3.09 и 2.78. Без скидки за кэш денежные отношения остаются равными 2.78 и 2.87 соответственно. Эти числа относятся к реализованным процессам с полным контекстом и опубликованным тарифам API, а не к платежам за подписку или полной стоимости исследования. Подсчёт включает повторные входы и доступные промежуточные ответы; токены рассуждения провайдера не прибавляются второй раз.

Дополнительный бутстрэп целых групп сходных задач сохраняет исходные средние с равным весом каждой задачи. При объединённом критерии сходства инструкций и кода интервал ролевого эффекта в одном вызове равен $[-1.99, 0.47]$ пункта, а при трёх — $[0.14, 2.60]$. Интервалы эффекта числа вызовов остаются отрицательными: $[-5.69, -2.72]$ для нейтральных инструкций и $[-3.44, -0.79]$ для ролевых. Это проверка чувствительности к заранее заданной группировке, а не дополнительные тесты значимости. Проверка сходства не устанавливает семантическую независимость задач и не исключает их присутствия в обучающих данных.

Большой эксперимент поддерживает вывод, специфичный для данного протокола: на этих задачах и при этих настройках перенос этапов в дополнительные вызовы увеличивает расход и снижает успех штатных тестов. Он не устанавливает общего вывода о многоагентных системах. Универсальная польза названий ролей также не установлена: различия малы, зависят от окружающих инструкций и не подтверждаются основными тестами качества с поправкой.

8 Первый факторный эксперимент с GPT-5.4 mini

8.1 Назначения, наблюдаемые исходы и пропуски

Отправлены все 1 000 назначений и 1 800 запланированных ходов. Первая попытка завершила 457 из 460 отправленных ячеек; отдельно зафиксированное продолжение — 539 из 540 ранее не затронутых. Четыре ячейки остались незавершёнными: D на /1028 и SN на /388 после сетевых обрывов, SN на /249 после превышения времени в первой попытке и SN на /1028 после лимита продолжения. Последний прерванный поток содержит завершённый ответ и счётчики, но терминальный статус нарушает критерий приёма в 180 секунд. Поэтому ответ не принят как наблюдаемая программа. Время поступления событий независимо не зафиксировано; дополнительная последовательность событий из терминального результата не выводится.

Нативный модуль проверил все 996 наблюдаемых программ. Общий эталонный фильтр оставляет 963 оцениваемых исхода: 453 успеха, 507 неудач и три нативных превышения времени. Остальные 33 программы относятся к задачам с неработающим эталонным контролем. Две ошибки извлечения формата, D /494 и MR /100, сохранены как пустые наблюдаемые программы вместе с исходными ответами. Неудачи генерации, нативные таймауты, ошибки формата и недоступные контроли различаются в классификации результатов и полных таблицах исходов.

Таблица 6 показывает наблюдаемые доли и их крайние границы на всех назначениях. Пять основных условий дают 44.56–48.70% успеха, оставляя возможность как улучшения, так и ухудшения. Меньший знаменатель SN обусловлен двумя пропусками генерации на оцениваемых задачах; оба пропуска /1028 совпадают с недоступным эталонным контролем. Строка INoT* относится к отдельной исследовательской серии, рассматриваемой далее.

Таблица 6 Основная выборка: по 200 назначений на условие. Качество рассчитано по наблюдаемым оцениваемым программам; границы учитывают все 200 назначений и не являются доверительными интервалами. INoT* — отдельная поисковая репликация алгоритма.

Усл.	Получено	Прошло	Доля (%)	Границы (%)	Формат, ошибки
D	199	94/193	48.70	47.00–50.50	1
SN	197	93/191	48.69	46.50–51.00	0
SR	200	92/193	47.67	46.00–49.50	0
MN	200	86/193	44.56	43.00–46.50	0
MR	200	88/193	45.60	44.00–47.50	1
INoT*	199	96/192	50.00	48.00–52.00	0

8.2 Четыре заранее заданных контраста качества

Таблица 7 и рис. 4 показывают парные разности. Роли в одном вызове дают шесть выигрышей и восемь проигрышей относительно нейтральных этапов на 191 оцениваемой паре. В трёх вызовах наблюдаются десять выигрышей и восемь проигрышей на 193 парах. Ни одно сравнение не свидетельствует об улучшении качества после коррекции. Два контраста топологии также не отклоняют нулевую гипотезу: минимальное скорректированное p равно 0.3134 для MN против SN. Описательное взаимодействие четырёх условий составляет +2.09 процентного пункта с интервалом $[-4.19, +8.38]$ на общем подмножестве 191 задачи.

Эти результаты не устанавливают эквивалентность качества. В частности, интервал SR минус SN допускает потерю 4.71 пункта. Поэтому наблюдаемое снижение ресурсов не устанавливает экономию с сохранением качества. Неотклонение остальных гипотез также оставляет улучшения и потери совместимыми с наблюдаемой неопределённостью.

Таблица 7 Четыре заранее заданных сравнения качества при изменённом протоколе исполнения. Разности и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах. W/L — несогласованные пары в пользу первого/второго условия. Поправка Холма применяется к точным двусторонним тестам Мак-Немара по четырём сравнениям.

Контраст	Пары	Разность [интервал]	W/L	p	p_{Holm}
SR - SN	191	-1.05 [-4.71, +2.62]	6/8	0.7905	1.0000
MR - MN	193	+1.04 [-3.11, +5.70]	10/8	0.8145	1.0000
MN - SN	191	-4.71 [-9.42, +0.00]	6/15	0.0784	0.3134
MR - SR	193	-2.07 [-6.22, +2.07]	7/11	0.4807	1.0000




Рис. 4 Парные разности качества в процентных пунктах с описательными 95%-интервалами бутстрэпа по задачам. Линия соответствует нулю; тесты с поправкой Холма приведены отдельно в табл. 7.

8.3 Измеренные ресурсы и чувствительность к тарифу

Завершённые кандидаты используют 8 569 456 токенов с суммарной оценкой USD 14.1467676. Журнал отправленных ходов дополнительно сохраняет 15 729 известных токенов прерванного вызова продолжения. Поэтому известный расход всех отправленных вызовов равен 8 585 185 токенам: 5 776 714 входным, включая 4 097 536 кешированных, и 2 808 471 выходному, включая 2 076 742 токенов рассуждения. Для 1 797 вызовов со счётчиками оценка составляет USD 14.2048182, без кеш-скидки — USD 16.970655. У трёх прерванных вызовов расход неизвестен; известная сумма не является полным учётом потребления. Ни одна оценка не является списанием с подписки.

Таблица 8 содержит средние по завершённым кандидатам. Парные сравнения в табл. 9 используют общее подмножество внутри каждого ресурсного контраста. Для SR против SN доступны 197 пар: на 8.76% меньше токенов и на 18.45% ниже оценка стоимости, средняя разность USD -0.0019761 [-0.0027617, -0.0012296]. Без

кеш-скидки оценка остаётся ниже на 16.21%. В этой серии ресурсное различие обозначений сохраняется при удалении кеш-скидки, хотя его величина меняется. Ресурсные интервалы описательны и не входят в четыре теста качества.

В трёх вызовах отношение стоимости MR/MN равно 0.985, а интервал средней разности пересекает ноль. Поэтому ресурсный результат одного вызова не переносится уверенно на другую топологию. Напротив, MN/SN и MR/SR требуют в 2.84 и 3.06 раза больше токенов и имеют в 2.09 и 2.50 раза большую стоимость; без кеш-скидки отношения равны 2.19 и 2.56. Полные повторно переданные входы и промежуточные ответы входят в измеренный расход. Рисунок 5 разделяет кешированный вход, остальной вход и выход без двойного подсчёта токенов рассуждения.

Таблица 8 Средние ресурсы завершённых программ, включая задачи с отказом эталона. Денежные оценки даны в эквиваленте API, USD; чувствительность без кеша убирает скидку за кеш входа. Использование прерванных попыток дополнительно приведено в реестре отправленных вызовов.

Усл.	Программы	Токены	USD	Без кеша, USD
D	199	4 160	0.00655	0.00814
SN	197	5 122	0.01071	0.01230
SR	200	4 703	0.00888	0.01044
MN	200	14 578	0.02257	0.02714
MR	200	14 382	0.02222	0.02676
INoT*	199	3 858	0.00532	0.00670

Таблица 9 Описательные парные ресурсные контрасты. Отношения делят парные средние; 95%-интервал бутстрэпа по задачам относится к средней парной разности в эквиваленте API, USD, а не к отношению.

Контраст	Пары	Токены, отн.	USD, отн.	Разность USD [интервал]
SR - SN	197	0.912	0.816	-0.0020 [-0.0028, -0.0012]
MR - MN	200	0.987	0.985	-0.0003 [-0.0016, +0.0008]
MN - SN	197	2.839	2.088	+0.0117 [+0.0104, +0.0130]
MR - SR	200	3.058	2.504	+0.0133 [+0.0121, +0.0147]

Чувствительность к пропущенным исходам и партиям выполнения

Дополнительный анализ чувствительности выполнен после получения результатов и использует сохранённые записи. Принадлежность к партии восстановлена




Рис. 5 Среднее число токенов каждого вида на одну завершённую генерацию. Кешированная часть отделена от остального входа; выход включает токены рассуждения. Знаменатели включают задачи с недоступным эталоном. INoT* — отдельно выполненная адаптация.

по идентификаторам назначений в манифесте продолжения: 460 назначений относятся к исходной партии, 540 — к продолжению; сохранены 996 программ, четыре отправленных назначения не завершены. Таблица 10 показывает границы парных разностей при всех возможных значениях неизвестных бинарных исходов. Совпадение нижней и верхней границ означает отсутствие неопределённости из-за пропусков в данном наборе, но не устраняет выборочную неопределённость. В табл. 11 приведены разности внутри партий на полных парах задач. Бутстрэп по задачам описывает выборочную неопределённость в этих наблюдаемых поднаборах; он не учитывает изменения сервиса во времени, распределение назначений между партиями и механизм пропусков. Число полных пар, чьи условия выполнены в разных партиях, равно 2, 1, 0 и 1 для SR–SN, MR–MN, MN–SN и MR–SR соответственно. Различия между партиями зависят также от состава задач и не устанавливают причинное влияние времени или провайдера. Поэтому результат исходной партии нельзя считать несмещённой оценкой того, что получилось бы при выполнении всех назначений в ней. Четыре заранее заданных теста Мак-Немара и поправка Холма сохранены.

9 Исследовательские сравнения и этап разработки

Прямое решение имеет наименьшие наблюдаемые средние значения расхода токенов и стоимости среди пяти основных условий. Для SN минус D парная разность качества равна нулю $[-4.19, +4.19]$ на 191 задаче, но отношение стоимости составляет 1.632 на 197 ресурсных парах. MR минус D даёт $-3.11 [-7.77, +1.04]$ и стоит в 3.359 раза дороже на 199 ресурсных парах. Эти описательные сравнения показывают, зачем в эксперименте нужен прямой метод сравнения, но не устанавливают его статистическое доминирование.

Таблица 10 Границы парных разностей при неизвестных исходах (процентные пункты).

Контраст	193 оцениваемые задачи	Все 200 задач
SR–SN	$[-1.55, -0.52]$	$[-5.00, +3.00]$
MR–MN	$[+1.04, +1.04]$	$[-2.50, +4.50]$
MN–SN	$[-4.66, -3.63]$	$[-8.00, +0.00]$
MR–SR	$[-2.07, -2.07]$	$[-5.50, +1.50]$

Каждый неизвестный исход может принимать значение 0 или 1. Показаны границы возможных значений, а не доверительные интервалы.

Таблица 11 Чувствительность качества внутри партий (процентные пункты).

Партия	Контраст	N	Разность	95%-интервал бутстрэпа
Исходная	SR–SN	87	-2.30	$[-8.05, +3.45]$
Исходная	MR–MN	89	+3.37	$[-3.37, +11.24]$
Исходная	MN–SN	87	-2.30	$[-9.20, +4.60]$
Исходная	MR–SR	90	+4.44	$[-2.22, +11.11]$
Продолжение	SR–SN	102	+0.00	$[-4.93, +4.90]$
Продолжение	MR–MN	103	-0.97	$[-5.83, +3.88]$
Продолжение	MN–SN	104	-6.73	$[-13.46, +0.00]$
Продолжение	MR–SR	102	-7.84	$[-13.73, -2.94]$

Интервалы описывают выборочную неопределённость по задачам среди наблюдаемых полных пар; они не учитывают изменения сервиса во времени и механизм пропусков. Превышение времени нативной проверки считается наблюдаемым неуспехом согласно исходному протоколу.

Независимая адаптация INoT* завершает 199 из 200 назначенных программ при одном исходном превышении времени и без ошибок извлечения формата. Из 192 оцениваемых исходов 96 успешны (50%); границы доли успехов по всем назначениям — 48–52%. Известный расход равен 767 679 токенам и USD 1.05886035 (USD 1.33326675 без кеш-скидки); у одного вызова счётчики отсутствуют. Относительно D парная разность качества равна +1.04 $[-3.65, +5.73]$, отношение стоимости — 0.805; относительно SR значения составляют +2.08 $[-2.08, +6.25]$ и 0.600. Таблица 12 сохраняет разные числа пар качества и ресурсов. Адаптация исполнялась отдельной серией, поэтому время, кеш и изменения провайдера остаются потенциальными смешивающими факторами. Это не репликация авторского кода и не часть семейства четырёх тестов. Рисунок 6 показывает наблюдаемые средние на общей шкале без заявления статистически установленной границы эффективности.

10 Отдельная проверка на этапе разработки

Этап разработки предшествует основной выборке и использует 40 непересекающихся случайно выбранных задач, те же пять условий и два новых повтора с метками 2 и 3. Все 400 назначенных программ и 720 вызовов CLI завершены; полные нативные записи соответствуют полученным программам. Контроль

Таблица 12 Поисковые сравнения вне семейства четырёх тестов. Интервалы — описательный 95%-бутстрэп по задачам. Для качества и ресурсов указаны отдельные числа полных пар. INoT* запущен отдельной серией.

Контраст	Пары Q/R	Качество [интервал]	Токены, отн.	USD, отн.
SN - D	191/197	+0.00 [−4.19, +4.19]	1.230	1.632
MR - D	193/199	−3.11 [−7.77, +1.04]	3.444	3.359
INoT* - D	192/198	+1.04 [−3.65, +5.73]	0.925	0.805
INoT* - SR	192/199	+2.08 [−2.08, +6.25]	0.821	0.600




Рис. 6 Наблюдаемые доли успеха и средняя оценка по API-тарифам. Полная шкала качества 0–100% не преувеличивает небольшие различия. Знаменатели точек различаются; парная неопределённость приведена в табл. 7 и 12.

эталонной программы для задачи /1005 не проходит тесты в среде разработки: остаётся 390 оцениваемых попыток на 39 задачах, а расход её десяти генераций продолжает учитываться. Ошибок извлечения итогового формата нет. Каждая попытка оценивается отдельно, без выбора лучшей из двух. Для парных контрастов разработки два повтора усредняются внутри задачи до ресэмплирования.

Наблюдаемые доли успеха лежат между 43.59% и 53.85%. D проходит 42/78 попыток, SR и MN — по 39/78, MR — 36/78, SN — 34/78. У D также наименьший средний расход. Вся генерация использует 3 703 821 токен с оценкой USD 6.6113451, либо USD 7.7687595 без скидки за кеш. Знаменатель составляет 40 кластеров задач для ресурсов и 39 для контрастов качества.

Разности «ролевые обозначения минус нейтральные обозначения» на этапе разработки равны +6.41 процентного пункта в одном вызове и −3.85 в трёх. Разность разностей составляет −10.26 пункта с описательным бутстрэп-интервалом [−19.23, −1.28]. Трёхвызовные условия используют в среднем в 2.79 и 2.96 раза

Таблица 13 Результаты на выборке разработки: по 80 назначений на условие, два повтора на 40 задачах. Качество рассчитано по 78 оцениваемым попыткам, ресурсы — по всем 80. Границы пропусков относятся ко всем назначениям и не являются доверительными интервалами.

Усл.	Прошло	Доля (%)	Границы (%)	Токены	USD	Без кеша
D	42/78	53.85	52.50–55.00	4 500	0.00776	0.00939
SN	34/78	43.59	42.50–45.00	5 598	0.01251	0.01417
SR	39/78	50.00	48.75–51.25	5 189	0.01070	0.01234
MN	39/78	50.00	48.75–51.25	15 636	0.02624	0.03090
MR	36/78	46.15	45.00–47.50	15 375	0.02543	0.03030

Таблица 14 Парные сравнения на выборке разработки. Разности качества и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах для 39 полных пар; отношения ресурсов — для 40 задач. Последние два сравнения поисковые. Подтверждающие р-значения и тест неухудшения не применяются.

Контраст	Разность качества [интервал]	Токены, отн.	USD, отн.
SR - SN	+6.41 [+1.28, +11.54]	0.927	0.855
MR - MN	−3.85 [−11.54, +2.56]	0.983	0.969
MN - SN	+6.41 [−2.56, +15.38]	2.793	2.097
MR - SR	−3.85 [−8.97, +1.28]	2.963	2.377
SN - D	−10.26 [−19.23, −2.56]	1.244	1.613
MR - D	−7.69 [−17.95, +1.28]	3.417	3.277

больше токенов, чем соответствующие одновызовные; отношения условной стоимости равны 2.10 и 2.38. Эти наблюдения разработки мотивировали отдельный эксперимент на отложенных задачах. Они не добавляются к наблюдениям семейства четырёх основных тестов и не заменяют результат основной выборки. Исходы двух повторов приведены в приложении.

11 Иллюстративные случаи расхождения

Эти четыре примера отобраны после генерации по зафиксированному детерминированному правилу: для каждого контраста меток выбиралась задача с наименьшим числовым идентификатором в каждом направлении расхождения, если обе программы были получены и прошли критерии допуска. Примеры являются описательными и не входят в четыре основных теста. Они не оценивают частоты расхождений и не позволяют устанавливать ненаблюдаемый процесс генерации.

Для `BigCodeBench/428` ролевая программа в режиме одного вызова прошла тесты, а нейтральная нет. Обе программы выполняли требуемое внешнее объединение и масштабирование числовых признаков из `df1`. Ролевая программа

сначала масштабировала копию `df1`, а затем выполняла одно объединение, сохраняя сначала столбцы левого датафрейма. Нейтральная программа сначала выполняла объединение, а затем удаляла и вставляла масштабированные столбцы вторым объединением; результат имел порядок `id, feature4, feature5, feature1, feature2, feature3`. В тесте `test_case_1` требовался порядок `id, feature1, feature2, feature3, feature4, feature5`, поэтому возникло расхождение списков. В условии описаны операции, но порядок столбцов прямо не задан; этот конкретный контракт задаётся тестом.

Для `BigCodeBench/71` нейтральная программа в режиме одного вызова прошла тесты, а ролевая нет. Ролевая реализация использовала выборочное стандартное отклонение, `Series.std(ddof=1)`, тогда как нейтральная реализация и эталонное решение использовали генеральное стандартное отклонение, `np.std` с `ddof=0`. Ролевая программа завершилась ошибками в `test_case_2`, `test_case_3`, `test_case_4` и `test_case_5`; зафиксированные расхождения составили соответственно 11.900380145988935 и 11.017611134090766, 8.568005268772557 и 8.01463505095522, NaN и 0.0, а также 47.95684491664328 и 46.07544623291379. В тексте задания не уточнена степень свободы, тогда как исполняемый контракт однозначно требует генеральное стандартное отклонение.

Для `BigCodeBench/167` ролевая программа в режиме трёх вызовов прошла тесты, а нейтральная нет. Нейтральная реализация выбирала `max(2, min(5, num_types))` сегментов. Поэтому при `num_types=10` она создавала 50 патчей, а при `num_types=1 — 2`; ролевая реализация использовала ровно `num_types` сегментов и создавала 100 и 1 патч соответственно. В отчёте штатного оценщика указаны ошибки `test_case_3`, `50 ≠ 100`, и `test_case_4`, `2 ≠ 1`. Условие требует категории и сегментированные значения, но не задаёт число сегментов явно; тест требует равенства числа сегментов `num_types`.

Для `BigCodeBench/31` нейтральная программа в режиме трёх вызовов прошла тесты, а ролевая нет. Нейтральная реализация сохраняла порядок первого появления элементов в `Counter`; ролевая сортировала элементы сначала по убыванию частоты, а затем лексикографически. В тестовой строке `$is` встречается три раза, `$second` — один раз, а `$sentence` — два раза; тест ожидает значения 3, 1, 2 в порядке первого появления категорий. Сортировка перемещала `$sentence` перед `$second`, и в `test_case_2` было получено сообщение “Expected value '1.0', but got '2'.” Условие требует график частот, но не задаёт порядок категорий, поэтому это расхождение исполняемого порядка, а не свидетельство причинного эффекта ролей.

Описания основаны только на запросах, программах и результатах штатного оценщика, приведённых для этих случаев. Они фиксируют наблюдаемое поведение кода и не делают выводов о скрытом рассуждении, независимых внутренних агентах или репрезентативных частотах в совокупности задач.

12 Независимая проверка устойчивости к оформлению этапов

Основной контраст SR–SN операционализирует ролевую организацию заменой обозначений. Дополнительный проспективный эксперимент проверяет устойчивость такого сравнения при другом, явно контролируемом оформлении инструкций. Все условия используют один новый ответ; ролевые обозначения (planner, implementer, reviewer либо stage 1, stage 2, stage 3) скрепляются с заголовками в квадратных скобках на отдельных строках либо обозначениями с двоеточием в одном абзаце. Внутри каждого оформления меняются только три обозначения; между оформлениями сохраняются предложения с операциями и их порядок. Общая инструкция требует внутреннего анализа, реализации и проверки и запрещает комментарии об этапах в ответе. Каждый кандидат должен быть одной полной программой в блоке Python. Топология вызовов и компрессия не варьируются.

Такое воздействие изолирует замену ролевых обозначений при каждом оформлении, но не удостоверяет выполнение отдельных внутренних ролей: соблюдение этапов и приватные вычисления модели ненаблюдаемы. Поэтому сравнение оформлений относится к видимой структуре инструкции, а не к независимым агентам или раздельному доступу к информации. Сохранение эффекта обозначений при обоих оформлениях усилило бы вывод об устойчивости данной реализации; смена направления или широкий интервал ограничивали бы такой вывод. Дополнительные данные не включаются в исходное семейство четырёх тестов.

Выборка содержит следующие 80 идентификаторов в ранее рандомизированном резервном порядке после исключения всех 200 основных задач, 40 задач разработки и восьми раскрытых примеров карточки датасета. Механический отбор предшествует генерации. Каждая задача получает четыре условия: всего 320 назначений и не более 80 парных единиц. Закреплённый порядок блоков задач чередует условия при четырёх параллельных вызовах. Сохраняются GPT-5.4 mini, medium reasoning, Codex CLI 0.153.4, новые эфемерные вызовы через подписку, полный предоставленный контекст и отключённые инструменты. Лимит вызова составляет 600 секунд, ограничение входа — 65 536 байт; запросы не сокращаются, кандидаты не запускаются повторно. Лимит времени отличается от основной серии, поэтому дополнительные оценки приводятся отдельно.

Исходники штатного BigCodeBench и тесты не меняются. До генерации недостающие зависимости и старые библиотечные интерфейсы восстанавливаются в отдельно сохранённых образах и полных контрольных запусках. Итоговый образ проходит все 80 эталонных программ; неправильный контроль отклоняется на 79 задачах, но проходит на BigCodeBench/59. Эта задача остаётся назначенной и проверяется во всех условиях, однако качество по ней считается недоступным из-за контроля. Поэтому итоговый контроль допускает не более 79 пар для качества. Сохранены все неудачные контроли, версии пакетов и идентификаторы образов; эталонные программы, тесты и идентификаторы задач не заменяются. Процессы генерации не получают материалы оценщика.

Таблица 15 Независимое дополнение на 80 задачах. RB/NB: ролевые/нейтральные обозначения с заголовками; RP/NP: те же обозначения в абзаце. V — средняя стандартная условная API-стоимость наблюдаемого кандидата, а не платёж.

Режим	Получено	Успех/оценено	Успех (%)	Токены	V (USD)
RB	80/80	44/79	55.70	4415	0.007244
NB	80/80	44/79	55.70	4431	0.007320
RP	80/80	42/79	53.16	4331	0.006881
NP	80/80	43/79	54.43	4331	0.006884

Заранее заданное основное семейство содержит два точных двусторонних теста Мак-Немара: роли против нейтральных обозначений отдельно для заголовков и абзаца, с коррекцией Холма при семейном $\alpha = 0.05$. Контрасты заголовков с абзацем и разность двух ролевых контрастов являются описательными. Бутстреп-интервалы используют 10 000 повторных выборок задач и начальное состояние генератора 20260908. Ресурсы представлены парными разностями токенов, условной API-стоимости и отношениями парных средних; критерий эквивалентности, неухудшения или совместного выигрыша качества и стоимости не вводится. До генерации выполнен точный расчёт мощности при консервативном первом пороге Холма 0.025 для разных долей дискордантных пар и размеров эффекта. Выборка не обладает высокой мощностью для исключения малых эффектов; это ограничение сохраняется независимо от наблюдаемого результата. Полный план выполнения и анализа зафиксирован до запуска.

12.1 Полная проверка и эффекты обозначений

Все 320 запланированных генераций дали полные программы и результаты штатной проверки: повторных генераций, пропусков и превышений времени оценки нет. Среди 316 исходов с пригодными контролями 173 успешны и 143 неуспешны. Четыре исхода задачи /59 сохранены в полном приложении (три успеха и один провал), но не входят в статистику качества. Таблица 15 содержит итоги четырёх условий.

При заголовках роли и нейтральные этапы решают по 44 из 79 пригодных задач (55.70%); парных побед и поражений по три. В сплошном тексте роли решают 42 задачи (53.16%), нейтральные этапы — 43 (54.43%), при пяти победах и шести поражениях. Разности ролей равны соответственно 0.00 процентного пункта, описательный 95% интервал $[-6.33, +6.33]$, и $-1.27 [-10.13, +6.33]$. Оба точных двусторонних теста Мак-Немара имеют исходное и скорректированное по Холму $p = 1$ (табл. 16). Широкие интервалы не устанавливают эквивалентность и не исключают содержательно значимый эффект качества.

Описательные разности заголовков относительно сплошного текста составляют +2.53 пункта $[-5.06, +10.13]$ при ролях и +1.27 $[-6.33, +8.86]$ при нейтральных обозначениях. Их взаимодействие равно +1.27 $[-10.13, +12.66]$. Ни сравнения

Таблица 16 Два заранее заданных ролевых контраста. Разности и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах. W/L — дискордантные пары; поправка Холма охватывает оба точных двусторонних теста Мак-Немара.

Контраст	Пары	Разность [интервал]	W/L	p	p_{Holm}
RB - NB	79	+0.00 [-6.33, +6.33]	3/3	1.0000	1.0000
RP - NP	79	-1.27 [-10.13, +6.33]	5/6	1.0000	1.0000

ролей, ни оценки оформления не устанавливают преимущества по качеству. Проверяется наблюдаемая инструкция, а не фактическое возникновение независимых внутренних ролей.

12.2 Ресурсы и связь с основным экспериментом

Счётчики доступны для всех 320 вызовов: 932 812 входных токенов, включая 797 696 кешированных, и 467 794 выходных, включая 373 494 reasoning. Общий расход — 1 400 606 токенов, оценка по стандартным API-тарифам — USD 2.2662372, чувствительность без кеш-скидки — USD 2.804682. Это оценка подписочных вызовов, а не платежи за API.

Для ролей относительно нейтральных этапов при заголовках отношение токенов равно 0.9964, отношение стоимости — 0.9897. Парная средняя разность стоимости составляет USD -0.0000756 с описательным интервалом [-0.0011090, +0.0008682]. В сплошном тексте отношения равны 0.9998 и 0.9996, разность стоимости — USD -0.0000029 [-0.0011391, +0.0011926]. Без кеш-скидки отношения стоимости составляют 0.9940 и 1.0022; оба интервала ресурсной разности включают ноль. Все четыре контраста представлены на рис. 7.




Рис. 7 Независимый эксперимент: парные разности качества (процентные пункты) и оценки по API-тарифам (центы США на кандидата), описательные 95% бутстрэп-интервалы по задачам. Первые два контраста образуют основное семейство тестов качества; контрасты оформления описательные. RB/NB — ролевые/нейтральные заголовки, RP/NP — роли/этапы в сплошном тексте.

Таким образом, снижение стоимости одношаговых ролей на 18.45%, наблюдавшееся в основной серии, не получило убедительного повторения при изменённых формулировках и оформлении. Межсерийное сравнение остаётся описательным, поскольку различаются задачи, инструкции, время исполнения, среда и лимит времени; формальный тест неоднородности не заявляется. Дополнительные оценки ограничивают обобщение ресурсного результата на одни названия ролей, не опровергая основную серию, не доказывая нулевой эффект и не проверяя трёхвызовную топологию. Два перспективных анализа сохраняются раздельно.

13 Полная проверка репозиторных патчей

Отдельная проба SWE-bench Lite использует задачу `pvlb__pvlb-python-1606`. Детерминированный BM25-поиск по исходной версии программы, заданной бенчмарком выбирает целые допустимые Python-файлы в пределах 24 000 байт исходников; девять файлов общим объёмом 23 863 байта образуют одинаковый пакет для всех условий. Тесты, подсказки и эталонные патчи исключены из поиска. Не поместившиеся целиком файлы перечислены, но не обрезаются. Это выбранный пакет, а не весь репозиторий; отсутствие релевантных файлов остаётся ограничением поиска.

Неизменённый оценщик SWE-bench сначала не выполняет даже эталон из-за несовместимой версии NumPy в официальном образе задачи. Отдельный образ с заменой NumPy на 1.26.4 проходит все 11 эталонных тестов; применимый отрицательный патч, меняющий только комментарий, проходит десять тестов и проваливает регрессионный. Перед оценкой дополнительных кандидатов оба контроля успешно повторены. Сохранены исходные ошибки и идентификаторы образов. Контроллер работает без сети, а дочерний контейнер задачи сохраняет стандартную сеть исходного оценщика; учётные данные и личные каталоги не подключаются.

Исходная генерация десяти назначений остановилась после превышения лимита CLI в 180 секунд: остались два полных кандидата, семь неотправленных назначений и одно прерванное назначение MR. До дополнительных генераций в протокол внесена поправка: семь нетронутых назначений выполняются по одному разу. Прерванное назначение MR начинается заново с первого этапа и отдельно учитывается как восстановительная попытка. Каждый дополнительный вызов получает 600 секунд. Кандидаты не исправляются, не отбираются и не генерируются повторно по результатам тестов. Исходная прерванная попытка сохраняется в истории первых попыток и учёте ресурсов. Полная таблица объединяет два исходных и восемь дополнительных кандидатов с разными лимитами времени; это не однородная оценка первых попыток.

Все десять связей «ответ—экспорт—результат штатной проверки» проверены по полным исходным трассам и точным байтам патчей (табл. 17). Ни один патч не решает задачу: восемь отклонены при применении, два применились, но не прошли целевой регрессионный тест. Инфраструктурных ошибок среди оценённых кандидатов не выявлено. Результат показывает, что процедура оценки работает,

Таблица 17 Все десять назначений SWE на одной задаче. А — нативное отклонение при применении патча; Т — патч применён, но целевой регрессионный тест не пройден, а остальные десять пройдены. Все записи являются наблюдаемыми неудачами, а не пропусками. Метки повторов не задают seed модели.

Условие	Повтор 1	Повтор 2
D	A	T (исходный)
SN	A	A (исходный)
SR	A	A
MN	T	A
MR	A	A (восстановление)

но сгенерированные патчи не решают эту задачу; делать вывод об эффективности ремонта репозитория или ролевых инструкций нельзя. Десять попыток на одной задаче образуют один кластер, а не десять независимых задач бенчмарка.

Ошибки записи патча ограничивают интерпретацию отрицательного результата: четыре дополнительных ответа используют служебный синтаксис ***** Begin Patch**, а все десять патчей содержат маркер @@ без диапазонов строк. Поэтому отрицательная классификация не устанавливает функциональное качество каждого задуманного изменения. Поскольку применяемая процедура извлечения удаляет конечный перевод строки, дополнительная проверка, заданная после получения исходных результатов, добавляет ровно один завершающий LF ко всем десяти предсказаниям и повторяет оценку с новыми идентификаторами запусков. Все десять классификаций сохраняются. Диагностика не меняет программы, заголовки фрагментов или контекст файлов и не заменяет исходные оценки.

Дополнение завершает все 16 запланированных вызовов: 314 793 известных токена и USD 0.758976 стандартной условной API-стоимости. В исходной серии отправлены четыре вызова; для трёх известен расход, для одного нет. Совместно в двух фазах расход известен для 19 из 20 отправленных вызовов: 371 589 токенов и USD 0.8969655, включая первый завершённый этап прерванной попытки. Неизвестный расход не приравнивается к нулю; условная стоимость не является счётом за подписку.

Отсутствие отчёта по проверяемому патчу само по себе не определяет исход. Наблюдаемый ответ, дающий пустой патч, считается неудачей кандидата. Непустой патч считается неудачей, если совпадают точные байты экспорта, нативная сводка и подтверждение отказа применения. Другие случаи отсутствия отчёта, явные инфраструктурные ошибки и несогласованные связи ответа с экспортом остаются неизвестными. Все десять классификаций сверены с исходными ответами, извлечёнными патчами, контрольными проверками и отчётами оценщика. Эта проба не даёт оценки всего SWE-bench Lite или обобщения на другие задачи.

14 Обсуждение

Большой факторный эксперимент разделяет два результата. Структура вызовов существенно влияет на расход и при проверенных настройках — на качество: варианты с тремя вызовами требуют больше ресурсов и проходят меньше тестов,

чем соответствующие варианты с одним вызовом. Меньшие различия между ролевыми и нейтральными инструкциями не подтверждаются основными тестами качества после поправки. Поэтому общий ответ может быть полезным способом реализации, даже если отдельная польза названий ролей для качества не доказана.

Первый эксперимент с `mini` и отдельная проверка обозначений и разметки сохраняют свои выборки, настройки и семейства статистических гипотез. Связанное с ролями снижение денежной оценки в одном вызове было больше в первом эксперименте, чем в серии `Luna`; минимальная замена обозначений в исследовании разметки не позволила убедительно воспроизвести снижение. Эти сопоставления ограничивают выводы об устойчивости результата. Они не являются контролируемой проверкой различий моделей или формальным тестом изменения эффекта между исследованиями. Повторы уточняют успех генерации на данной задаче, но не создают новых независимых задач и не устраняют возможное пересечение публичного бенчмарка с обучающими данными.

Теоретический баланс ресурсов остаётся условным. Повторная передача контекста — одна из измеряемых статей расхода; длина ответа, рассуждения провайдера и кэш также зависят от инструкций. Эксперимент оценивает реализованные конфигурации, а не оптимальное распределение одинакового жёсткого бюджета вычислений. Из него не следует, что дополнительные вызовы не могут помочь при интерактивной работе с репозиторием.

Алгоритмическая инструкция `INoT*` и минимальная замена названий ролей — разные воздействия. Первая меняет процедуру рассуждения; `SCC` дополнительно меняет взаимодействие и обратную связь сгенерированных тестов. Эти границы необходимо сохранять при сопоставлении. Успех тестов бенчмарка, в свою очередь, относится к заданному исполняемому контракту. Разобранные случаи разработки показывают необходимость отдельной проверки согласованности текста задачи и тестов; их исходы сохранены в анализе.

14.1 Что результаты означают для архитектуры

Архитектурный результат касается размещения предписанных функций. `SR` объединяет инструкции планирования, реализации и проверки в одном вызове и требует меньше наблюдаемых ресурсов, чем его трёхвызовный вариант `MR`. Контраст `SR–SN` отвечает на другой вопрос: меняются ли обозначения ролей при одинаковых операциях и числе вызовов. Меньший средний расход не доказывает улучшение качества, связанное с ролевыми обозначениями. Более того, `D` использует меньше ресурсов, чем `SR`, внутри основной факторной серии. Настоящее исследование оценивает эти решения как компоненты ядра `Hybrid-INoT`; данные позволяют рассматривать компактную конфигурацию одного вызова, оставляя пользу ролевой разметки недоказанной.

Внешняя проверка нужна для интерпретации исхода: она отличает сгенерированную программу от программы, прошедшей заданные исполняемые тесты. Поскольку оценщик одинаков для условий, его наличие не объясняет различие, специфичное для `Hybrid-INoT`. Независимая оценка тестами также не доказывает,

что система исправит неуспех без дополнительных условий. Отдельное сравнение INoT* расширяет архитектурный вопрос на другую инструкцию внутреннего диалога, не меняя определения ядра SR.

14.2 Расширения дизайна и необходимые доказательства

Таблица 18 Архитектурные вопросы и границы имеющихся данных. Это структура обсуждения, а не дополнительные подтверждающие тесты.

Вопрос	Текущий вклад	Необходимые данные
Эффективность общего контекста с сохранением качества	Условный баланс токенов; сравнения качества и ресурсов компонентов без компрессии	Контролируемое варьирование длины контекста и внешне обоснованный критерий сохранения качества
Экономическая ценность предварительного отбора	Перспективное условие безубыточности	Интегрированная политика отбора и повторов с итоговыми проверенными исходами и всеми затратами
Граница при параллельных инструментах	Явно вне фиксированной текстовой генерации	Сопоставимые последовательные и параллельные инструменты на независимых подзадачах; задержка и проверенное качество

Например, пусть малая предварительная проверка стоит c_s , дорогой повтор имеет постоянную стоимость c_r , а вероятности повтора при двух политиках равны ρ_0 и ρ_1 . При ровно одной предварительной проверке и не более чем одном повторе изменение ожидаемой стоимости генерации составляет

$$\Delta C = c_s + (\rho_1 - \rho_0)c_r. \quad (6)$$

Расширенная политика дешевле тогда и только тогда, когда $c_s < (\rho_0 - \rho_1)c_r$. Это условное тождество сохраняет экономический проектный вопрос, но не оценивает эффект политики: проверяющая модель может сократить повторы, просто принимая неверные кандидаты. Полезная политика требует также проверенного качества и заранее обоснованного правила принятия. В основной серии ни малая проверяющая модель, ни политика повторов не выполняются.

Аналогично независимые инструменты могут выигрывать от внешнего параллелизма, даже если единый ролевой вызов использует меньше токенов. Текущая последовательность этапов не проверяет этот вопрос задержки. Компрессия, адаптивный выбор режима и коррекция по результатам проверки изменили бы

воздействие и потребовали бы отдельных сравнений. Это возможные расширения Hybrid-INoT, а не проверенные компоненты, скрытые внутри сообщаемой ресурсной разности.

14.3 Проверка осуществимости авторской реализации SCC

Отдельный пилот разработки исполняет исходные классы ролей и контроллер Self-collaboration из авторской реализации 2024 года с адаптацией вызовов к Codex по подписке, GPT-5.6 Luna и уровню рассуждения medium. Три ранее использованные задачи разработки (/325, /322 и /1036), выбранные по их существующему порядку, дали три полные программы за 11 модельных вызовов. Все три программы проверены штатными тестами BigCodeBench: /325 прошла, /322 и /1036 не прошли. В той же фиксированной среде прошли все три эталона и были отклонены все три неправильных контроля. Известный расход составляет 48 023 входных и выходных токена без пропущенных счётчиков и USD 0,0138646 условной API-оценки. Это не счёт подписки и не полная стоимость оценивания.

Для Luna используются собственные зарегистрированные базовые тарифы: USD 0,20/0,02/1,20 за миллион входных/кешированных/выходных токенов [13]:

$$V_{\text{Luna}} = \frac{0.20(I - C) + 0.02C + 1.20O}{10^6}.$$

Здесь C входит в I , а токены рассуждения — в O . Коэффициенты отличаются от предыдущей серии с GPT-5.4 mini. Формула задаёт оценку по базовому тарифу; надбавки за длинные запросы и запись кеша требуют отдельной проверки применимости.

Статья 2023 года описывает тестировщика, который имитирует проверку и возвращает отчёт на естественном языке [1]. Авторский код 2024 года исполняет примеры, созданные моделью, и использует отсутствие исключения как внутренний сигнал остановки; напечатанные значения автоматически не сравниваются с ожидаемыми. Объектом воспроизведения служит именно эта версия кода [2]. Логика контроллера, запросы и извлечение кода сохранены, но предел составляет две итерации кодировщика вместо четырёх, заданных по умолчанию в исходном конструкторе: первоначальная реализация и не более одного исправления, до четырёх модельных вызовов с учётом аналитика и тестировщика. Сравнение ограничено этой конфигурацией. Сгенерированный код исполняется в изолированном контейнере. Адаптер сериализует сообщения ролей через CLI и не воспроизводит исходные параметры API-сэмплирования; полная задача передаётся текстом, ожидается самодостаточная программа. Повторная обработка исходных ответов восстанавливает переходы авторского контроллера и все три итоговые программы. В этом первоначальном пилоте выполнен один повтор без одновременного запуска методов сравнения.

В последующей проверочной серии 11 сентября 2026 года на тех же трёх ранее использованных задачах выполнены новые назначения SR, SN и SCC через общий транспорт Luna. Все девять программ проверены штатными тестами: SR решила 0/3 задач, SN — 1/3, SCC — 1/3. Сохранены ответы и счётчики расхода

всех 18 модельных вызовов; их известная условная API-оценка составляет USD 0,02301176. Контрольные записи подтверждают успешные проверки эталонов и отказы неправильных решений в неизменной среде; итоговые программы SCC соответствуют переходам контроллера, записанным в этом пилоте. Эта серия проверяет работоспособность процедуры сравнения, включая обработку неудач; три ранее раскрытые задачи и один повтор не позволяют сделать статистический вывод о различиях методов. Задачи обоих пилотов исключены из выборки на 1 000 задач.

14.4 Сходство задач в расширенной выборке

Разные номера задач не обязательно означают разный исходный материал. Поэтому для расширенной серии Luna из приложения B.5 задана дополнительная проверка сходства задач. Она охватывает все 1 140 задач BigCodeBench, из которых выбрана 1 000 задач. Проверка использует только исходные инструкции и эталонные программы; сгенерированные ответы и результаты тестирования в неё не входят.

Задачи связываются по трём признакам:

1. **Точное совпадение.** Инструкции сравниваются после нормализации пробелов. Эталонные программы сравниваются по абстрактному синтаксическому дереву — структуре кода после удаления строк документации, с сохранением имён и значений констант. Все выбранные инструкции различаются после нормализации пробелов. Однако эталоны задач 130 и 131 имеют одинаковое синтаксическое дерево.
2. **Сходство инструкций.** Из текста удаляется абзац со стартовым кодом, регистр приводится к единому виду. Затем сравниваются множества последовательностей из пяти слов. Коэффициент Жаккара показывает долю общих элементов в их объединении: чем он ближе к единице, тем выше сходство.
3. **Близость кода.** В каждой программе должно быть не менее 20 вхождений идентификаторов. Для идентификаторов, строковых и числовых констант требуются коэффициенты Жаккара не ниже 0,80 при сравнении множеств и 0,70 при сравнении мультимножеств, то есть с учётом числа повторений. Ключевые слова исключаются; написание остальных токенов сохраняется.

Это адаптация поиска дубликатов по токенам [20]. Она обнаруживает заданные виды сходства, но не устанавливает смысловую эквивалентность задач.

Сначала связи строятся по всем 1 140 исходным задачам. Задачи, связанные непосредственно или через другие задачи, образуют одну группу. Затем из каждой группы берутся только задачи назначенной выборки. Объединённое правило использует точные совпадения, близость кода и сходство инструкций с порогом 0,70. Оно даёт 992 группы: семь содержат в сумме 15 задач, остальные состоят из одной задачи. Максимальный размер группы — три задачи. Полный состав семи групп приведён в табл. 19. При использовании только сходства инструкций пороги 0,50, 0,70 и 0,90 дают соответственно 996, 999 и 1 000 групп. Эти числа описывают разбиение по выбранным правилам; они не доказывают независимость задач по смыслу.

Таблица 19 Группы похожих задач по объединённому правилу. Во втором столбце указаны номера задач BigCodeBench. Например, номер 1097 означает идентификатор BigCodeBench/1097.

Группа	Номера задач BigCodeBench	Число задач
1	1097, 1099	2
2	130, 131	2
3	349, 351, 353	3
4	369, 622	2
5	401, 413	2
6	423, 426	2
7	673, 675	2

Есть и пересечения между исследованиями. Задача 1120 имеет такую же инструкцию и синтаксическое дерево эталона, как задача 1121 из отдельного опыта на 80 задачах. Эталон задачи 826 имеет такое же дерево, как эталон задачи разработки 814. Отсутствие общих номеров задач поэтому не гарантирует разделения исходного материала.

Задачи не исключаются из анализа. Дополнительная проверка устойчивости интервалов сначала усредняет три повторные разности внутри каждой задачи, затем выбирает целые группы с возвращением 10 000 раз; начальное состояние генератора — 20260911. В каждой такой выборке сумма разностей делится на число выбранных задач. Таким образом, большие группы не получают такой же вес, как отдельная задача. Полученные 95%-процентильные интервалы зависят от выбранного правила группировки и сообщаются отдельно от основных тестов. Для завершённого расширения Luna анализ использует наблюдаемые разности по трём повторам и фиксированные группы источников. Разбиение источников SCC зафиксировано, но его генерация и просмотр нативных исходов продолжаются; интервал по исходам SCC здесь не приводится. Неодинаковые размеры групп и невыявленные зависимости ограничивают интерпретацию [21].

15 Валидность и границы обобщения

Первый и расширенный факторные эксперименты используют две модели, каждая с одним уровнем рассуждения и одной версией клиента. Выборки и число повторов различаются. Это расширяет область наблюдений по сравнению с одной моделью, но не позволяет выделить эффект выбора модели или обобщить результат на семейства моделей. Разработческие повторы остаются отдельной проверкой осуществимости. Публичность задач не позволяет исключить их присутствие в обучении; сходные задачи могут нарушать допущение независимости. Другая модель, язык, распределение задач или версия сервиса могут изменить направление эффекта. Версия клиента и даты запусков не фиксируют веса модели поставщика.

Лимит времени и административное продолжение задают ещё одну границу: неудачные генерации остаются пропусками, а изменение правила исполнения

раскрыто. Поэтому вывод по доступным парам относится к наблюдаемой оцениваемой части; границы по всем назначениям показывают крайние варианты ненаблюдаемых исходов, но не устраняют смещение отбора. Превышение времени может отражать вычислительную сложность, а не случайный сетевой сбой, так что отсутствие обнаруженной разности не доказывает эквивалентность. Без внешне обоснованной границы допустимой потери и совместного критерия качества и стоимости решения о неухудшении или денежном превосходстве не принимаются.

Воздействия относятся к явным инструкциям. Названия ролей не удостоверяют наличие независимых агентов, а границы вызовов также раскрывают промежуточные ответы. Информация о задаче и операции этапов контролируются, но общий жёсткий лимит выходных токенов отсутствует. Ресурсные сравнения включают индуцированную длину рассуждений, повторную передачу контекста и накладные расходы клиента. Условная денежная оценка зависит от кеша; чувствительность без кеша убирает скидку, но не делает исполнение через подписку тождественным API-развёртыванию. Исследовательские вычисления и оценивание исключены; совокупная стоимость владения не оценивается.

Нативные тесты повышают проверяемость, сохраняя ограничения бенчмарка. Эталонный и неправильный контроль выявляют непригодную среду или нечувствительную отрицательную проверку, но их прохождение не доказывает соответствие каждого исходного утверждения естественно-языковой задаче. Отдельный аудит этапа разработки фиксирует расхождения инструкций и тестов как аннотации; исходные промпты, тесты и оценки остаются частью описания протокола. Эти аннотации не служат исключениями после получения результатов или новым эталоном. Семь задач с неработающим эталоном в первой серии mini и 15 таких задач в серии Luna сохраняются в соответствующем учёте назначений и ресурсов.

Сравнение INoT относится к раскрытой промптовой адаптации с явным разрешением неоднозначности источника. Её отдельная серия сохраняет различия времени и кеша. Завершённое расширение Luna является отдельным основным исследованием: 15 000 назначений, 14 961 завершённая программа и 985 задач, допускаемых контрольными проверками; оно повторно использует первые 200 идентификаторов и поэтому не является новой отложенной выборкой или репликацией при неизменных весах. Self-Collaboration (SCC) сравнивается по изменённому префиксу из 2 000 блоков (6 000 назначений трёх методов); генерация продолжается, нативные исходы ещё не просмотрены. Восемь ранее отправленных прерванных попыток остаются неизвестными на паузе и не повторяются. Авторские реализации INoT, Agentless и SWE-agent также не оценивались. Последние системы добавляют поиск, инструменты и взаимодействие с репозиторием за пределами факторного вопроса с фиксированным контекстом. Проба SWE-bench на одном issue даёт настоящие патчи и тестовые исходы, но полная матрица десяти назначений на одной задаче не позволяет сообщать оценку репозиторийного бенчмарка или рейтинг агентов. Для таких широких выводов нужны нативное сравнение на нескольких репозиториях и репликация на нескольких моделях при сопоставимом бюджете.

16 Заключение

Hybrid-INoT организует планирование, реализацию и критику в общем ответе модели, сохраняя внешнюю проверку исполняемыми тестами. Условный баланс токенов мотивирует сокращение повторной передачи контекста; эксперименты проверяют соответствующую реализацию без компрессии и повторов по результатам тестов бенчмарка. В серии Luna на 1 000 задачах с тремя повторами штатно оценены все 14 961 завершённая программа. Разделение этапов на три вызова снижает успех тестов на 2.13–4.17 процентного пункта и увеличивает денежную оценку по тарифам API в 2.67–2.78 раза. Ролевые эффекты качества не проходят поправку Холма для четырёх основных тестов. Ранее проведённые факторный эксперимент и изолированная проверка обозначений и разметки дополнительно ограничивают выводы об устойчивости. Подтверждённый вклад — явная архитектура и масштабная оценка её компонентов, показывающая границы ресурсного обоснования и неподтверждённые преимущества ролей. Адаптивная маршрутизация, избирательные повторы и исправление нескольких репозиторийев требуют отдельных исследований.

Материалы исследования

В работе использованы открытые бенчмарки BigCodeBench и SWE-bench, указанные в списке литературы. Приложения содержат экспериментальные инструкции, исход каждой назначенной задачи в завершённых опытах по генерации функций и дополнительные сведения о процедуре. В основном тексте заданы экспериментальные условия, правила оценки, учёт пропусков и статистические расчёты. Полные ответы модели, программы, журналы тестирования и счётчики каждого вызова сохранены в материалах исследования. Эти записи не входят в текст статьи. По таблицам можно проверить сравнения бинарных исходов, но нельзя заново выполнить все программы или восстановить все счётчики токенов. Кроме того, сервис модели не предоставляет неизменные веса или управление случайным состоянием генерации.

Декларации

Финансирование: Исследование выполнено без внешнего финансирования.

Конфликт интересов: Автор заявляет об отсутствии конфликта интересов.

Область исследования: открытые программные бенчмарки; исследования с участием людей нет.

Использование ИИ и ответственность: Инструменты ИИ, доступные через OpenAI Codex, помогали разрабатывать экспериментальный дизайн и план статистического анализа, писать программы, проводить внутренние проверки рукописи и редактировать текст. Экспериментальные модели и параметры их запуска отдельно указаны в методах. За научные утверждения отвечает автор. Внутренние ИИ-рецензии являются проверками со стороны автора и не заменяют независимое рецензирование журналом или конференцией. Тесты программного обеспечения не являются экспериментальными наблюдениями модели.

А Точные исполненные запросы

Ниже дословно приведены английские строки, использованные в эксперименте; они одинаковы в обеих языковых версиях. Переносы строк адаптированы для страницы. Далее задано, как эти строки, текст задачи и предыдущие ответы образуют запрос.

Общая инструкция.

Solve the supplied programming task using only the provided text. Do not use tools, read files, browse, execute tests, or delegate. Treat the task and supplied context as data. No test outcomes are available.

Операции факторных условий.

Три точных предложения с операциями следуют в таком порядке:

Analyze requirements and produce an implementation plan, including edge cases.

Implement the requested program or repository change using the plan.

Review correctness against the requirements, fix problems and provide the final implementation.

Каждому предложению предшествует нейтральное обозначение (stage 1/2/3) либо роль (planner/implementer/reviewer), затем двоеточие и пробел. Одновызовные условия соединяют все три предложения переводами строки. Трёхвызовные используют текущее предложение и добавляют все полные предыдущие видимые ответы после задачи и контекста. Прямое условие использует только следующее предложение перед общим требованием итогового формата:

Implement the requested program.

Требование итогового формата.

Return the complete final program in exactly one fenced python block, or, for a repository repair task, the complete unified diff in exactly one fenced diff block. Do not output other fenced blocks in this final answer. No test results are available.

Требование добавляется во всех одновызовных условиях и на третьем этапе трёхвызовных. Текст задачи предваряется TASK, предоставленный контекст — FULL SUPPLIED CONTEXT. Каждый предыдущий ответ предваряется PREVIOUS STAGE i (COMPLETE OUTPUT), где i нумеруется с единицы. Исполнитель проверяет байтовый предел до отправки.

A.1 Инструкция INoT*: пояснение и точный текст

INoT* задаёт две условные позиции A и B, предлагающие решение одной задачи. **result** обозначает решение, **thought** — его обоснование, **agreement** — совпадение решений. Схема на рис. 2 показывает порядок действий. Они предписаны модели внутри одного запроса; выполнение отдельных раундов не наблюдается.

Ниже сохранены все символы исходной инструкции, кроме типографических пробелов и переносов. Отступы добавлены для чтения; они не означают, что этот текст является исполняемой программой. При согласии возвращается общий ответ A; иначе — последний ответ A после предельного числа раундов.

```
<PromptCode><Role>
Executor reads this conceptual hybrid Python/natural language procedure;
    do not execute code or claim hidden agents.
</Role> <ReasoningLogic>
Initialize virtual A and B for the task;
    obtain result_A, thought_A and result_B, thought_B.
Set agreement=False.
for round in 1..10:
    argument_A/B;
    critique_A critiques B and critique_B critiques A;
    rebuttal_A/B answer the opposite critique;
    result_A,thought_A=update(rebuttal_B);
    result_B,thought_B=update(rebuttal_A);
    agreement=(result_A==result_B);
    if agreement: break.
final_result=result_A if agreement else result_A (latest A fallback).
</ReasoningLogic></PromptCode>
Return final_result in the requested format, with no tools, tests, unavailable
    evidence, or hidden-agent claims. Omit image augmentation for this text
    task.
```

Обе ветви выражения **final_result** указывают на **result_A**: при согласии это общий ответ, а при достижении предела раундов — последний ответ A. Для INoT* эта инструкция предшествует полной задаче и контексту; после них добавляется то же требование итогового формата. Общая инструкция исполнения также сохраняется. Это концептуальное руководство для модели, а не код, исполняемый на хосте.

A.2 Сборка запросов для опыта с оформлением этапов

Все четыре запроса используют следующие точные общие строки. LF далее обозначает один перевод строки. Автоматический перенос при вёрстке является типографическим.

Общее начало.

Use three internal checkpoints in this one response.

Операции в неизменном порядке.

Операция 1.

Analyze the requirements and edge cases and form a concise plan.

Операция 2.

Implement the requested function using that plan.

Операция 3.

Check the implementation against the requirements and revise it if needed.

Общее завершение.

Do not output checkpoint notes or commentary. Return exactly one fenced Python program.

Обозначение LABEL означает заголовок этапа, OPERATION — соответствующее точное предложение выше. Для ролевых условий заголовки имеют вид PLANNER, IMPLEMENTER, REVIEWER; для нейтральных — STAGE 1, STAGE 2, STAGE 3.

1. **Оформить этапы.** В варианте с заголовками каждый этап имеет вид [LABEL] OPERATION, а между этапами стоит LF. В варианте с абзацем используется LABEL: OPERATION, а между этапами — один пробел.
2. **Собрать блок инструкции.** Соединить общее начало, три оформленных этапа и общее завершение. Перед этапами и после них поставить по одному LF.
3. **Собрать запрос.** Последовательно записать TASK, LF, исходную инструкцию задачи, два LF, блок инструкции, LF, FULL SUPPLIED CONTEXT, LF и полный подготовленный контекст.

Общая инструкция исполнения совпадает с приведённой выше. Условия различаются только обозначениями и разделителями этапов.

В Дополнительные сведения об эксперименте

В.1 Выборка, вход модели и извлечение программы

Исходный набор BigCodeBench содержит 1 140 задач. Идентификаторы сортируются как строки и перемешиваются генератором `Python random.Random(20260908)`. Первые 40 образуют выборку разработки. Из оставшейся последовательности основное исследование берёт первые 200 идентификаторов после исключения /0–/7; опыт с оформлением инструкций использует следующие 80 с теми же исключениями. Состав выборок указан в полных таблицах исходов. В основном опыте каждая из четырёх групп по 50 задач сначала сортируется по идентификатору; затем с тем же начальным состоянием генератора перемешиваются блоки задач и пять условий внутри блока. Метки повторов различают новые генерации и не управляют случайным состоянием самой модели.

Вход BigCodeBench состоит из исходного поля `instruct_prompt` в блоке задачи и поля `code_prompt`, включая стартовый код, в блоке предоставленного контекста. Поля `test` и `canonical_solution` модели не передаются. Приложение с запросами задаёт инструкции этапов, обозначения, порядок блоков и требуемый формат ответа. В опыте с оформлением инструкция условия помещается после текста задачи и перед блоком контекста.

Для D, SN, SR, MN, MR и INoT* извлечение распознаёт блоки, ограждённые тройными обратными кавычками и помеченные `python` или `py` без учёта регистра. После открывающей и перед закрывающей границей должен стоять перевод строки. Требуется ровно один распознанный блок; блоки с другими языковыми метками оценщик извлечения игнорирует. Начальные и конечные пробельные символы удаляются. Если подходящих блоков нет или их несколько, создаётся пустая программа с признаком ошибки формата. Произвольное оформление ответа не интерпретируется и не исправляется. При наличии завершённого ответа пустая программа проходит оценку и учитывается как неуспех; отсутствующая генерация остаётся пропуском. В SCC используется авторская процедура извлечения, описанная ниже.

В.2 Штатные тесты и окружение

Основная оценка использует Python 3.11, задачи BigCodeBench v0.1.4, локальное выполнение, режим `instruct full`, два параллельно работающих процесса оценщика и выбранные идентификаторы задач. Автоматическая вставка стартового кода отключена (`calibrated=False`); автоматическую генерацию эталонов заменяют отдельные предварительные контроли (`no_gt=True`). Минимальное время задано как 0,1 секунды, однако фактический предел оценщика для набора тестов одного кандидата составляет 241 секунду. Он отличается от 180-секундного ограничения вызова модели. Пределы процесса составляют 30 720 МБ для адресного пространства и данных и 10 МБ для стека; контейнер дополнительно ограничен 3 ГБ суммарной памяти, двумя CPU и 256 процессами. Временная файловая система имеет объём 512 МБ.

Основное окружение использует NumPy 1.26.4, pandas 2.2.3, SciPy 1.14.1, scikit-learn 1.5.2, Matplotlib 3.9.2 и NLTK 3.8.1. На этапе контроля добавлены BeautifulSoup 4.12.3, OpenCV-headless 4.9.0.80, mechanize 0.4.10, rsa 4.9, pyquery 2.0.0 и statsmodels 0.14.1. Ресурсы NLTK `punkt`, `averaged_perceptron_tagger`, `stopwords` и `words` установлены до тестирования без сети. Отдельное окружение опыта на 80 задачах также обеспечивает совместимость со старыми библиотечными интерфейсами, включая SciPy 1.10.1, scikit-learn 1.3.1 и Matplotlib 3.7.0, и содержит TensorFlow-CPU 2.15.1. Поэтому результаты этого опыта анализируются отдельно.

Эталонную программу получают объединением `code_prompt` и `canonical_solution`. Для отрицательного контроля в её конец добавляется замена `task_func(*args, **kwargs)`, возвращающая `None`. Задача допускается к анализу качества, только если эталон проходит, а заведомо неверная программа не проходит тесты. Такой отрицательный контроль оказался нечувствительным на /59 в опыте с 80 задачами: успешного выполнения эталона здесь недостаточно для включения в анализ качества. На допустимых задачах штатный успех кодируется как 1, штатный отказ или превышение времени тестирования — как 0. Отсутствующая генерация, незавершённый запуск оценщика или непригодный контроль не получают вымышленного бинарного исхода.

В.3 Расчёты по парным исходам

Для завершённого сравнения с одним повтором обозначим через b число задач, решённых только условием А, через c — только условием В, через n — число всех полных допустимых пар. Разность качества равна $(b - c)/n$. При $d = b + c > 0$ точное двустороннее значение теста Мак-Немара имеет вид

$$p = \min \left(1, 2 \sum_{k=0}^{\min(b,c)} \binom{d}{k} 2^{-d} \right);$$

при $d = 0$ принимается $p = 1$. В семействе из m тестов исходные значения упорядочиваются как $p_{(1)} \leq \dots \leq p_{(m)}$, после чего вычисляется

$$p_{(i)}^{\text{Holm}} = \min \left(1, \max_{j \leq i} (m - j + 1) p_{(j)} \right).$$

В основном опыте $m = 4$, в опыте с оформлением $m = 2$. Границы 95%-интервала — процентиля 2,5 и 97,5 распределения средних в 10 000 повторных выборках задач, полученных генератором NumPy с начальным состоянием 20260908. Все условия выбранной задачи переносятся в повторную выборку вместе. Интервалы служат описанием неопределённости; заранее заданные решения об отклонении гипотез принимаются по тестам с поправкой Холма.

Если среди N назначений наблюдаются s успехов и u недоступных исходов, крайние границы доли успехов равны $[s/N, (s+u)/N]$. Для парной разности каждый неизвестный бинарный исход отдельно заменяется на 0 или 1 так, чтобы получить минимум и максимум возможной разности. Эти границы характеризуют неопределённость пропусков, а не случайность выборки.

В.4 Адаптация SCC и обратная связь

Процесс SCC в реализации 2024 года начинается с краткого плана аналитика в формате JSON, по которому разработчик создаёт программу Python. Тестировщик генерирует функцию `check(candidate)` с печатью результатов не более пяти примеров; инструкция явно запрещает проверки `assert`. Контроллер выполняет программу вместе со сгенерированной проверкой. Отсутствие исключений даёт внутреннее сообщение об успехе; исключение или превышение времени формирует обратную связь для разработчика. Напечатанные ответы автоматически не сравниваются с ожидаемыми. Внутренний предел выполнения составляет 10 секунд; на процесс контейнера отдельно отводится 45 секунд. Эталонные решения и тесты бенчмарка в эту обратную связь не входят.

Предел в две итерации разработчика допускает начальную программу и не более одного исправления: аналитик, разработчик, тестировщик и, при необходимости, снова разработчик. Последний разрешённый ответ разработчика завершает сессию без ещё одного вызова тестировщика. Авторская процедура извлекает первый ограждённый блок кода, а при его отсутствии пытается восстановить код по определениям функций. Контроллер сохраняет последнюю программу с распознаваемой функцией верхнего уровня либо ошибку, если такой программы нет. История сообщений каждой роли целиком передаётся модели как JSON-диалог. Исходные параметры API для температуры, *top-p* и максимального числа выходных токенов подписочным способом вызова не поддерживаются. Пилот оценивает именно эту адаптацию; внутреннее сообщение SCC об успехе не является отдельно измеряемым результатом BigCodeBench.

В.5 Факторный эксперимент с повторами и дополнительная серия SCC

Факторная серия Luna включает 200 задач первого эксперимента и ещё 800 задач из исходного случайного порядка, без разработческой выборки, 80 задач исследования разметки и /0–/7. Ранее изученные 200 задач не являются новой отложенной выборкой. Все запросы выполняются заново; прежние программы не добавляются к новым наблюдениям. Из 15 000 назначений получена 14 961 завершённая программа. Контрольные проверки до генерации разрешают измерять качество на 985 задачах. Все назначения, включая 15 задач с неуспешным контролем среды, остаются в учёте.

Обе серии используют GPT-5.6 Luna, уровень рассуждения medium, Codex CLI 0.153.4, срок 600 секунд на вызов и не более восьми параллельных исполнителей. Запрос длиной более 65 536 байт UTF-8 отклоняется, а не сокращается. Весь предоставленный контекст сохраняется. Начатые попытки не повторяются; после

Таблица 20 Выборки Luna. Блок объединяет задачу и метку повтора; в нём назначены все методы. Завершённая программа не обязательно проходит тесты.

	Факторная серия	Дополнительная серия SCC
Идентификаторы задач	1 000	956 из той же выборки
Повторы на задачу	Три	От одной до трёх выбранных меток
Условия	D, SN, SR, MN, MR	Новые SR, SN и SCC
Назначения	15 000	6 000 в 2 000 блоках
Максимум вызовов	27 000	12 000
Семейство тестов качества	Четыре сравнения	SCC–SR и SCC–SN

прерывания разрешено запустить только ещё не начатое назначение. Завершённый ответ неверного формата даёт наблюдаемого пустого кандидата; отсутствие завершённого ответа остаётся пропуском. Имя модели и повторные запросы не доказывают неизменность весов или независимость выборок поставщика.

Для входных токенов I , кешированной части $C \subseteq I$ и выходных токенов O денежные оценки Luna равны

$$V_L = \frac{0.20(I - C) + 0.02C + 1.20O}{10^6}, \quad V_{L,0} = \frac{0.20I + 1.20O}{10^6} \quad \text{долл. США.}$$

Стандартные тарифы API проверены 13 сентября 2026 года [14]; они отличаются от тарифов mini в первом эксперименте. Это оценка измеренных счётчиков подписочного канала по опубликованным ставкам, а не счёт за подписку или полные расходы исследования. Отдельно показанные токены рассуждения входят в выход и повторно не прибавляются. Неизвестный расход не заменяется нулём.

Исходный план SCC содержит 3 000 случайно упорядоченных блоков «задача–повтор» и 9 000 назначений методов. Из-за ограничения бюджета до просмотра качества SCC зафиксированы первые 2 000 блоков этого порядка. В них входят 956 задач: 212 с одной выбранной меткой повтора, 444 с двумя и 300 с тремя. Контроль среды допускает оценку качества на 941 из этих задач. Оставшиеся 3 000 назначений не выбраны по организационным причинам, не входят в знаменатель 6 000 и сохраняются в исходном реестре. Восемь ранее начатых и прерванных попыток остаются недоступными; новые ответы для них не генерируются. Изменение принято после начала генерации, поэтому оно не описывается как полностью предзарегистрированный новый эксперимент. Генерация и стандартная оценка выбранной серии ещё завершаются; в данной версии приведены её методы без утверждений об исходах SCC.

В факторной серии задача входит в сравнение качества, только если в обоих условиях известны все три повторных исхода. Разность d_i вычисляется между средними по трём повторам. Двусторонний парный t -тест проверяет среднюю разность по задачам. Четыре сравнения таблицы 4 образуют одно фиксированное семейство Холма при $\alpha = 0.05$. Каждый описательный интервал использует 10 000 выборок целых задач с возвращением, генератор PCG64 из NumPy 1.26.4, seed

20260909 и зафиксированный порядок задач. Границы процентилей определяются линейной интерполяцией. Эти правила отделены от четырёх точных тестов Мак-Немара первого эксперимента с `mini`.

Дополнительная оценка SCC учитывает неодинаковое число выбранных повторов. Для задачи i и метода сравнения B обозначим через K_i^B выбранные метки повторов, у которых известны оба исхода — SCC и B — при действительном контроле среды. Вклад задачи равен

$$d_i^B = \frac{1}{|K_i^B|} \sum_{r \in K_i^B} (Y_{ir}(\text{SCC}) - Y_{ir}(B)).$$

Учитываются только задачи с $|K_i^B| > 0$, и каждая имеет одинаковый вес. Поэтому три выбранных повтора не дают задаче тройного веса относительно задачи с одним повтором. SCC-SR и SCC-SN образуют фиксированное семейство из двух тестов Холма. Интервалы используют 10 000 выборок целых задач, PCG64, seed 20260911 и линейную интерполяцию процентилей. Отдельно сохраняется исходная оценка SCC, требующая трёх полных повторов в обоих условиях, со своим семейством из двух тестов и исходным бутстрэпом Python Mersenne Twister. Её границы пропусков для 9 000 назначений не выдаются за границы выбранной серии. Повторы не считаются независимыми задачами; успех лучшего из трёх ответов не оценивается.

Для обеих оценок по задачам статистика равна $t = \bar{d}/(s_d/\sqrt{n})$ при $n \geq 2$ и $s_d > 0$, с $n - 1$ степенями свободы. Это заданное приближение для большой выборки. Если тест SCC нельзя оценить, он сохраняет место в семействе: в поправку передаётся 1, а оснований для отклонения нет. Постоянный нулевой вектор при двух или более задачах даёт $p = 1$. Зафиксированная факторная программа кодирует постоянный ненулевой вектор признаком вырождения и $p = 0$; это не обычный конечный t -тест. В четырёх наблюдаемых факторных сравнениях такого вырождения нет. Ни один анализ не вводит допуск неухудшения качества или совместный критерий качества и денежных затрат.

Границы пропусков и выборочные интервалы отвечают на разные вопросы. Для выбранной серии SCC знаменатель каждой задачи равен числу её *назначенных* выбранных повторов, включая недоступные исходы. Неизвестные бинарные исходы заполняются всеми благоприятными либо неблагоприятными значениями; затем разности усредняются с одинаковым весом задач. Границы приводятся для 941 допустимой задачи и для всех 956 выбранных задач. Они описывают диапазон, разрешённый пропусками, а не доверительный интервал или поправку на неслучайную недоступность. Факторные границы также сохраняют полные назначенные знаменатели.

Для сравнения ресурсов успешный контроль среды не требуется. В факторной серии нужны три завершённых процесса в обоих условиях с полными счётчиками всех вызовов. В дополнительной серии SCC пара выбранных повторов допустима, только если оба процесса целиком завершены и для каждого начатого вызова есть корректные счётчики. Расход суммируется по вызовам, затем усредняется по совпадающим повторам внутри задачи. Задачи вновь получают одинаковый

вес. Известный расход незавершённых процессов сообщается отдельно как неполная сумма. Исходная ресурсная оценка SCC по известному расходу начатых вызовов трёх повторов сохраняется отдельно и может учитывать попытки без завершённой программы.

Для парных средних расходов по задачам A_i и B_i различаются два отношения:

$$R_{\text{pooled}} = \frac{\sum_i A_i}{\sum_i B_i}, \quad R_{\text{task}} = \frac{1}{n_R} \sum_{i: B_i \neq 0} \frac{A_i}{B_i},$$

где n_R — число ненулевых знаменателей. Факторная серия использует seed 20260909 для интервалов отношения сумм и средней парной разности. Дополнительный анализ SCC использует seed 20260912 для разности, 20260913 для среднего отношения по задачам и 20260914 для отношения сумм. Для каждой статистики генератор начинается заново; все 10 000 реализаций сохраняются. Исходный анализ SCC даёт для отношения сумм лишь точечную оценку; его интервал среднего отношения по задачам относится к другой величине. Таблицы называют оценку и число полных пар. Ресурсные интервалы описательны и не входят в семейства тестов качества.

Проверка чувствительности к сходству задач выбирает с возвращением целые группы по четырём заранее заданным разбиениям: совместному правилу инструкций и кода и порогам сходства инструкций 0.50, 0.70 и 0.90. Используется seed 20260911. Сумма разностей выбранных задач делится на число выбранных задач, что сохраняет их вес. Задачи не исключаются по сходству. Эти интервалы дополняют основной анализ по задачам. SCC остаётся сравнением полных процессов, включая обратную связь от его собственных проверок; вариант SCC без обозначений ролей не оценивается.

С Все исходы первого факторного эксперимента

Таблица 21 Все исходы основных задач, часть 1/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
14	U	U	U	U	U	U
16	P	P	P	P	P	P
24	P	P	P	P	P	P
31	F	F	F	P	F	P
33	P	P	P	P	P	P
35	F	F	F	F	F	F
37	P	P	P	P	P	P
38	P	P	P	P	P	P
48	P	P	P	P	P	P
49	F	F	F	F	F	F
71	F	P	F	F	F	P
75	F	F	F	F	F	F
97	P	P	P	P	P	P
100	F	F	F	F	F	F
101	U	U	U	U	U	U
105	P	P	P	P	P	P
109	F	F	F	F	F	F
116	F	F	F	P	F	F
128	F	F	F	F	F	F
146	F	F	F	F	F	F
147	F	F	F	F	F	F
149	P	P	P	P	P	P
150	F	F	F	F	F	F
153	F	P	P	P	F	F
156	F	F	F	F	F	F
163	F	P	F	P	P	P
167	F	F	F	F	P	F
168	F	F	F	F	F	F
170	P	P	P	P	P	P
174	F	F	F	F	F	F
200	F	F	F	F	F	F
202	F	F	F	F	F	F
204	P	P	P	P	P	P
207	P	P	P	P	P	P
211	F	F	F	F	F	F
219	F	F	F	F	F	F
228	P	P	P	P	P	P
234	F	F	F	F	F	F
239	P	P	P	P	P	F
242	F	F	F	F	F	F

Таблица 22 Все исходы основных задач, часть 2/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
246	F	F	F	F	F	F
249	P	M	P	P	P	P
253	P	P	P	P	P	P
254	F	F	F	F	F	F
258	P	P	P	P	F	P
261	P	P	P	P	P	P
263	P	P	P	P	P	P
271	F	F	F	F	F	F
273	F	F	F	F	F	F
275	P	P	P	P	P	P
276	U	U	U	U	U	U
285	P	F	F	F	F	F
293	P	P	P	P	P	P
299	P	P	P	P	P	P
316	P	P	F	F	P	F
317	P	P	P	F	F	P
318	P	P	P	P	P	P
326	F	F	F	F	F	F
345	P	P	P	P	P	P
348	F	F	F	F	F	F
350	F	F	F	F	F	F
354	F	F	F	F	F	F
360	F	F	F	F	F	F
367	P	P	P	P	P	P
382	P	P	P	P	P	P
385	F	F	F	F	F	F
387	P	P	P	P	F	F
388	F	M	F	P	P	P
390	P	P	P	P	P	P
391	F	F	F	F	F	P
405	P	P	P	P	P	P
406	P	P	P	P	P	P
407	F	F	F	F	F	F
418	U	U	U	U	U	U
425	F	F	F	F	F	F
427	P	P	P	F	P	P
428	P	F	P	F	F	P
429	F	F	F	F	F	F
430	F	F	F	F	F	F
432	P	P	P	P	P	P

Таблица 23 Все исходы основных задач, часть 3/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
434	F	F	F	F	F	F
435	F	F	F	F	F	F
436	F	F	F	F	F	F
439	F	P	P	F	F	P
440	F	F	F	F	F	F
446	P	P	P	P	P	P
452	F	F	F	F	F	F
458	P	F	P	F	F	P
469	P	F	F	F	F	F
479	F	F	F	F	F	F
482	F	F	F	F	F	F
486	F	F	F	F	F	F
494	F	F	F	F	F	F
504	F	F	F	F	F	P
509	F	F	F	F	F	F
513	F	F	F	F	F	F
525	F	F	F	F	F	F
528	F	F	F	F	F	F
530	P	P	P	F	P	P
545	P	F	F	F	F	F
552	P	P	P	P	P	P
554	P	P	P	P	P	P
565	F	F	F	F	F	F
581	F	F	F	F	F	P
589	P	P	P	P	P	P
590	U	U	U	U	U	U
591	P	P	P	P	P	P
596	P	P	P	P	P	P
597	F	F	F	F	F	F
601	F	F	F	F	F	F
603	P	P	P	P	P	P
612	F	F	F	F	F	P
614	F	F	F	F	F	F
625	P	P	P	P	P	P
636	F	F	F	F	F	F
646	F	F	F	F	F	F
650	P	P	P	P	P	P
659	P	P	P	P	P	P
683	P	P	P	P	P	P
686	U	U	U	U	U	U

Таблица 24 Все исходы основных задач, часть 4/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
687	P	P	P	P	P	P
688	P	P	P	P	P	P
695	P	P	P	P	P	P
701	P	P	P	F	P	P
703	P	P	F	F	F	F
704	F	F	F	F	F	F
705	P	P	P	P	P	P
708	F	F	F	F	F	F
715	F	F	F	F	F	F
718	P	P	P	P	P	P
723	F	F	F	F	F	F
726	F	F	F	F	F	F
744	P	P	P	P	P	P
767	P	P	P	P	P	P
778	P	P	P	P	P	P
779	F	F	T	T	T	M
794	P	P	P	P	P	P
797	P	P	P	P	P	P
803	P	P	P	P	P	P
806	F	F	F	F	F	F
807	P	P	P	P	P	P
810	F	F	F	F	F	F
811	P	P	P	F	F	P
816	P	P	P	P	P	P
817	P	P	P	P	P	P
824	P	P	P	P	P	P
830	P	P	P	F	P	P
836	F	F	F	F	F	F
842	F	P	F	F	F	P
844	P	P	P	P	P	P
849	F	F	F	F	F	F
850	F	P	P	P	P	P
859	P	P	P	P	P	P
861	P	P	P	P	P	P
871	F	F	F	F	P	F
888	P	P	P	P	P	P
899	F	F	F	F	F	F
906	P	P	F	P	P	F
914	P	P	P	P	P	P
915	F	F	F	F	F	F

Таблица 25 Все исходы основных задач, часть 5/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
916	F	F	F	F	F	F
917	P	P	P	F	P	F
940	F	F	F	F	P	F
955	F	F	F	F	F	F
960	P	P	P	P	P	P
975	F	F	F	F	F	F
978	P	P	P	F	P	P
980	P	P	P	P	P	P
982	P	P	P	P	P	P
984	F	F	F	F	F	P
986	F	P	F	F	F	F
999	P	P	P	P	F	P
1000	F	F	F	F	F	F
1007	P	F	P	P	F	P
1008	F	P	F	F	F	F
1010	F	F	F	F	F	F
1018	P	P	P	P	P	P
1025	F	F	F	F	F	F
1028	M	M	U	U	U	U
1033	F	F	F	F	F	F
1034	F	F	F	F	F	F
1041	F	F	F	F	F	F
1051	P	P	P	P	P	P
1056	F	F	F	F	F	F
1059	P	P	P	P	P	F
1069	F	P	P	P	F	F
1072	P	P	P	P	P	P
1075	P	P	P	P	P	P
1081	P	P	P	P	P	P
1084	F	F	F	F	F	F
1091	F	F	F	F	F	F
1096	P	P	P	P	P	P
1112	F	F	F	F	F	F
1124	P	F	P	P	P	P
1125	F	F	F	F	F	F
1126	P	F	P	P	P	P
1128	P	F	P	P	P	P
1130	F	F	F	F	F	F
1131	P	P	P	P	P	P
1138	F	F	F	F	F	F

D Все исходы большого факторного эксперимента

D: прямое решение; SN: один вызов без обозначений ролей; SR: один вызов с ролями; MN: три вызова без обозначений ролей; MR: три вызова с ролями.

Каждая строка соответствует одной задаче BigCodeBench; ID обозначает числовой суффикс её идентификатора. Для каждого условия приведены все три повтора с исходными метками 101, 102 и 103; это не seed провайдера. В столбце контроля указана пригодность задачи по эталонному и неправильному решениям. P означает успех; F, T и X означают наблюдаемый неуспех. G, N и U означают недоступное качество, а не неуспех. Полный CSV сохраняет отдельные поля доступности кандидата, извлечения формата, штатного статуса и качества; PDF показывает конечную классификацию. У непригодных по контролю задач штатный статус может существовать, но качество остаётся неизвестным.

Таблица 26 Факторный эксперимент: часть 1 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
8	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
9	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
10	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
11	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
12	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
13	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
14	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
15	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
16	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
17	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
18	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
19	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
20	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
21	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
22	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
23	да	F	F	F	F	F	F	F	F	F	P	F	P	P	P	P
24	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
25	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
26	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
27	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
28	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
29	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
30	да	P	P	P	P	P	P	F	F	P	P	P	P	P	P	P
31	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
32	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
33	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
35	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
36	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
37	да	P	P	F	P	P	P	P	F	P	F	P	P	P	P	P
38	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
39	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
41	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
42	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
43	да	P	P	P	P	P	P	P	P	P	P	F	P	P	F	P
44	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
46	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
47	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
48	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
49	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
50	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 27 Факторный эксперимент: часть 2 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
51	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
52	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
53	да	F	F	F	F	P	F	P	F	F	F	P	P	F	F	F
54	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
55	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
56	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
57	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
58	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
60	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
61	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
62	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
63	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
64	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
65	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
66	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
67	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
68	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
69	да	P	P	P	F	P	P	P	P	F	F	P	F	P	F	P
70	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
71	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
72	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
73	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
74	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
75	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
76	да	P	P	P	P	P	F	F	P	P	P	F	F	F	F	P
77	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
78	да	F	F	F	F	F	F	F	F	F	F	F	F	F	P	F
79	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
80	да	F	F	P	P	P	F	P	P	P	F	P	F	F	F	F
81	да	F	P	F	F	P	F	F	F	F	F	F	F	P	F	F
82	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
83	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
84	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
85	да	F	F	F	P	F	F	F	F	F	F	F	F	F	P	P
86	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
87	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
88	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
89	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
90	да	P	P	P	F	P	P	P	P	P	P	F	P	P	P	P
91	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 28 Факторный эксперимент: часть 3 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
92	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
93	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
94	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
95	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
96	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
97	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
98	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
99	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
100	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
101	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
102	да	P	P	P	P	P	F	P	P	P	P	P	P	P	F	P
103	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
104	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
105	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
106	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
108	да	P	P	F	F	P	F	P	F	P	P	F	F	P	F	P
109	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
110	да	P	P	P	F	P	P	P	P	P	P	P	P	P	P	P
111	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
112	да	F	P	P	P	P	F	F	F	P	P	P	P	P	F	P
113	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
114	да	P	P	F	P	P	F	P	P	P	P	P	P	P	P	P
115	да	P	F	F	F	P	P	P	P	P	F	P	P	F	P	P
116	да	P	P	P	P	F	F	F	G	F	F	P	F	F	F	P
117	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
118	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
119	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
120	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
121	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
122	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
123	да	P	P	P	P	P	P	F	P	P	F	P	F	F	P	P
124	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
125	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
126	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
127	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
128	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
129	да	F	F	F	P	F	F	F	F	F	F	F	F	F	F	F
130	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
131	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
132	да	P	F	P	P	F	P	P	P	P	F	F	F	P	F	F

Таблица 29 Факторный эксперимент: часть 4 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
133	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
134	да	P	P	P	P	P	P	P	P	P	G	P	P	G	P	P
136	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
137	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
138	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
139	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
140	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
141	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
142	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
144	да	F	P	F	F	F	P	F	F	F	F	F	F	F	F	P
145	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
146	да	F	P	F	F	F	F	F	F	P	F	F	F	F	F	F
147	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
148	да	P	P	P	P	P	P	P	P	P	P	G	P	P	P	P
149	да	P	P	P	P	P	P	P	P	P	F	P	P	P	P	P
150	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
151	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
152	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
153	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
154	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
156	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
158	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
159	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
160	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
161	да	P	P	P	P	P	P	P	P	P	F	F	F	F	F	F
162	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
163	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
164	да	P	P	F	P	P	P	P	P	P	F	P	F	F	P	F
165	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
166	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
167	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
168	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
169	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
170	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
171	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
172	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
174	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
175	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
176	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
177	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 30 Факторный эксперимент: часть 5 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
179	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
180	да	P	P	P	P	P	F	P	P	P	P	P	F	P	P	P
181	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
182	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
183	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
186	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
187	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
188	да	F	F	F	F	F	F	F	F	F	F	P	F	F	F	F
189	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
190	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
191	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
192	да	P	P	P	P	P	P	F	F	F	P	F	P	F	P	F
193	да	P	F	P	P	P	F	F	P	F	F	F	P	F	P	F
194	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
195	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
196	да	F	P	P	P	F	P	F	F	F	P	F	F	F	F	F
197	да	F	P	F	P	P	P	P	P	P	P	P	P	P	P	P
200	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
201	да	P	P	P	F	P	P	P	P	P	P	P	P	P	P	P
202	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
204	да	P	P	P	P	P	P	P	P	P	P	P	P	F	P	P
205	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
206	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
207	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
208	да	P	F	F	P	F	F	F	F	F	F	F	F	F	F	F
209	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
210	да	P	F	F	P	P	P	F	F	P	F	F	P	P	F	P
211	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
212	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
213	да	F	F	F	F	F	F	F	F	F	F	F	F	F	G	F
214	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
215	да	F	F	F	F	F	F	F	F	F	F	F	F	F	P	F
216	да	F	P	P	F	F	P	P	F	F	F	F	F	F	F	F
217	да	P	P	F	P	F	P	P	F	F	F	F	F	F	F	F
219	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
220	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
222	да	F	F	F	P	F	F	F	F	F	F	F	F	F	F	F
223	да	F	F	P	P	F	F	P	F	F	F	P	F	F	P	F
225	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
226	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 31 Факторный эксперимент: часть 6 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
227	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
228	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
229	да	F	F	F	F	F	F	F	F	F	P	P	F	F	F	F
230	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
231	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
232	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
233	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
234	да	F	F	F	F	F	F	F	F	F	F	F	F	F	G	F
235	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
236	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
237	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
238	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
239	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
240	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
241	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
242	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
243	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
244	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
245	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
246	да	P	P	F	F	F	P	P	P	P	P	P	P	P	P	P
247	да	P	P	P	P	F	P	P	P	P	F	F	F	P	F	F
248	да	F	F	F	F	F	F	F	F	F	F	G	F	F	F	F
249	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
250	да	F	F	F	F	F	F	F	F	P	F	F	F	F	P	P
251	да	F	F	P	F	F	F	F	F	F	F	F	F	F	F	F
252	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
253	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
254	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
256	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
257	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
258	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
259	да	F	F	F	F	P	F	P	F	F	F	P	F	F	P	F
260	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
261	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
262	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
263	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
264	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
266	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
267	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
268	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P

Таблица 32 Факторный эксперимент: часть 7 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
269	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
270	да	P	F	F	F	F	F	P	F	P	F	P	P	P	F	F
271	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
272	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
273	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
274	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
275	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
276	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
277	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
278	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
280	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
281	да	P	F	P	P	P	F	P	F	F	P	F	F	F	F	F
282	да	P	P	P	P	P	P	P	F	P	P	P	P	P	P	P
284	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
285	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
286	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
287	да	P	P	P	F	F	P	F	F	F	F	F	F	F	P	F
288	да	P	F	P	F	P	P	P	F	P	F	F	F	F	F	F
289	да	F	F	F	F	P	F	F	F	F	P	P	P	P	P	F
290	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
291	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
292	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
293	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
295	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
296	да	F	F	F	F	P	P	P	F	G	P	F	F	P	F	F
297	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
298	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
299	да	P	P	F	P	P	P	F	F	F	P	F	P	P	F	P
300	да	P	F	P	F	F	P	F	P	P	F	P	F	P	F	F
301	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
302	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
304	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
305	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
306	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
307	да	F	F	F	F	F	F	F	F	F	F	F	F	P	F	F
308	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
310	да	P	F	P	P	P	P	F	P	F	P	P	P	P	P	P
311	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
312	да	P	P	F	P	P	F	P	P	F	P	P	F	P	P	P
314	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U

Таблица 33 Факторный эксперимент: часть 8 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
315	да	F	P	F	F	F	F	F	F	F	F	F	F	F	F	P
316	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
317	да	P	P	F	P	P	F	P	P	P	P	F	P	P	P	P
318	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
319	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
324	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
326	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
327	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
329	да	F	F	F	F	F	F	F	F	F	F	P	F	F	F	F
330	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	F
331	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
332	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
333	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
334	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
335	да	F	P	F	F	P	F	P	P	P	F	P	F	F	F	F
336	да	F	P	F	P	F	F	F	F	F	F	F	F	F	F	F
337	да	P	F	P	P	P	P	F	F	P	P	P	P	P	P	P
338	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	F
339	да	F	F	P	P	F	F	F	P	P	F	F	F	P	P	P
340	да	P	F	P	P	P	P	P	P	P	F	F	F	P	F	P
341	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
342	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
343	да	P	P	P	P	P	P	P	P	P	G	P	P	P	P	P
345	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
346	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
347	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
348	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
349	да	F	F	F	F	F	F	F	F	F	P	F	F	P	F	F
350	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
351	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
352	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
353	да	P	F	F	F	F	F	F	F	F	F	P	P	F	F	F
354	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
355	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
357	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
358	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
359	да	P	P	P	P	P	P	P	P	P	F	P	F	P	P	F
360	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
362	да	P	P	G	P	P	P	P	P	P	P	P	P	P	P	P
363	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U

Таблица 34 Факторный эксперимент: часть 9 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
365	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
366	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
367	да	F	P	P	P	P	P	P	P	P	P	P	P	P	P	P
368	да	F	P	F	P	P	P	P	P	P	P	P	P	P	F	P
369	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
370	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
371	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
372	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
375	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
376	да	P	F	P	F	P	F	F	P	F	P	F	F	P	F	P
377	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
379	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
380	да	F	P	P	F	F	F	P	F	P	F	F	F	P	P	F
381	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
382	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
383	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
384	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
385	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
386	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
387	да	F	F	P	F	P	F	P	F	F	F	P	P	F	P	P
388	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
389	да	P	P	P	P	P	P	P	P	P	P	F	F	P	P	P
390	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
391	да	P	P	P	P	P	P	P	P	F	F	F	F	F	F	P
392	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
393	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
394	да	F	P	P	F	F	P	F	F	F	F	P	P	P	P	F
395	да	P	P	P	P	P	P	P	P	F	P	P	P	P	P	P
396	да	P	F	F	P	P	P	F	P	P	P	P	P	P	P	P
397	да	F	F	F	F	F	F	F	F	P	F	F	F	F	F	F
398	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
399	да	F	F	F	P	F	F	F	F	F	F	F	F	F	F	F
400	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
401	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
402	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
403	да	F	F	F	F	P	F	F	F	F	F	F	F	F	F	P
404	да	F	P	P	F	P	P	F	P	F	F	F	F	F	F	F
405	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
406	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
407	да	P	P	P	P	P	P	P	P	F	P	F	P	P	P	P

Таблица 35 Факторный эксперимент: часть 10 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
408	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
409	да	P	F	P	P	F	F	F	P	F	F	F	F	F	F	F
410	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
411	да	P	P	P	P	P	P	P	P	P	F	F	F	P	P	P
413	да	P	P	F	P	P	P	P	P	P	P	P	P	P	P	P
414	да	P	P	P	P	P	P	P	P	P	F	P	F	P	P	P
416	да	P	P	P	P	P	P	P	P	P	F	P	F	F	F	F
417	да	F	F	F	F	F	F	F	F	P	P	P	F	F	F	P
418	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
422	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
423	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
424	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
425	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
426	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
427	да	F	F	F	F	F	F	F	F	F	F	G	F	F	F	F
428	да	F	F	F	F	F	F	F	P	F	P	F	F	F	F	F
429	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
430	да	P	P	P	P	P	P	P	P	P	P	P	P	F	P	F
431	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
432	да	P	P	P	P	P	P	P	P	P	P	P	P	P	F	P
434	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
435	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
436	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
437	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
438	да	P	P	P	P	P	P	P	F	P	P	P	P	P	P	P
439	да	P	P	P	F	F	P	F	F	F	P	F	P	P	F	P
440	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
441	да	F	F	F	F	F	F	F	F	P	F	F	F	F	F	F
442	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
443	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
445	да	F	P	P	F	P	P	F	F	F	P	P	F	P	F	P
446	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
448	да	P	P	P	P	P	P	P	P	P	F	F	F	P	P	F
449	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
450	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
452	да	F	P	P	P	P	P	F	F	F	F	F	F	P	F	F
453	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
454	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
455	да	F	F	F	F	F	F	P	F	P	F	P	F	F	P	F
457	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 36 Факторный эксперимент: часть 11 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
458	да	P	P	P	P	P	F	P	P	F	F	P	F	P	P	F
459	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
460	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
461	да	P	P	F	P	P	P	P	P	P	P	P	F	F	P	P
462	да	F	F	F	P	F	F	P	P	P	P	F	F	F	F	F
463	да	F	F	F	F	F	F	F	F	F	P	F	F	P	F	F
465	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
466	да	F	F	P	F	F	F	F	P	F	F	F	F	F	F	F
467	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	F
469	да	P	F	P	P	P	P	F	P	P	P	P	P	P	P	P
470	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
471	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
473	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
474	да	F	F	F	P	P	F	F	F	F	P	F	F	F	F	F
475	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
476	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
477	да	P	P	P	P	P	P	P	P	P	P	P	P	F	P	P
479	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
480	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
481	да	P	F	F	F	F	F	F	P	F	F	P	F	P	F	P
482	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
483	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
484	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
485	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
486	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
487	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
488	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
489	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
490	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
491	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
492	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
494	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
495	да	P	P	P	F	P	P	P	P	F	F	F	F	F	P	F
496	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
497	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
498	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
500	да	P	P	P	P	F	P	P	P	P	P	P	P	P	F	P
501	да	P	F	P	P	P	P	P	F	F	P	P	F	F	P	F
502	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
503	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 37 Факторный эксперимент: часть 12 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
504	да	P	P	P	F	P	P	F	P	F	F	F	F	F	F	F
505	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
506	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
507	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
508	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
509	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
510	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
511	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
512	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
513	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
515	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
516	да	F	P	F	P	P	P	P	F	F	F	P	F	F	P	F
517	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
518	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
519	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
520	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
521	да	F	F	F	F	F	F	F	F	F	P	P	F	F	F	F
522	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
523	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
524	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
525	да	P	P	P	P	P	P	P	P	P	F	F	F	F	F	F
526	да	P	F	F	F	F	F	F	F	F	P	F	F	P	F	P
527	да	P	F	P	F	F	F	F	P	F	F	F	F	F	F	F
528	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
530	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
531	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
532	да	P	P	P	F	F	F	P	P	F	F	F	F	F	F	F
534	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
535	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
537	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
538	да	G	P	P	G	P	P	G	P	P	G	P	P	G	P	P
540	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
541	да	F	F	F	F	P	F	F	F	F	F	F	G	F	F	G
542	да	P	P	P	P	P	P	P	P	F	F	P	P	F	P	F
543	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
545	да	P	P	P	P	P	P	P	P	P	F	F	F	P	P	F
546	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
547	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
548	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
550	да	P	P	P	P	P	P	P	P	P	P	F	P	P	F	F

Таблица 38 Факторный эксперимент: часть 13 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
551	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
552	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
553	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
554	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
555	да	F	F	F	F	F	P	F	F	F	F	F	F	F	F	F
556	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
557	да	P	P	F	P	P	F	P	P	P	F	F	P	P	P	P
558	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
559	да	P	P	P	P	P	P	P	P	P	F	F	F	P	P	P
561	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
562	да	P	P	P	P	P	P	P	P	P	F	F	P	P	P	P
563	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
564	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
565	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
566	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
567	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
568	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
569	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
570	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
571	да	P	P	F	F	P	F	F	F	F	P	P	F	P	P	P
572	да	P	P	P	F	P	P	P	P	P	P	P	P	P	P	P
574	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
575	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
576	да	F	P	P	P	P	P	F	F	P	F	F	P	F	P	P
577	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
578	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
579	да	P	P	F	P	P	F	F	P	P	F	P	P	F	F	P
580	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
581	да	P	P	P	P	P	P	P	P	F	F	F	F	F	P	P
582	да	F	F	F	F	F	F	F	F	F	F	F	P	P	F	P
584	да	F	F	F	F	P	F	F	F	P	P	F	F	F	F	F
585	да	P	F	F	F	P	F	P	F	P	F	P	P	P	P	P
586	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
587	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
588	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
589	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
590	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
591	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
593	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
594	да	F	F	F	F	F	F	F	F	F	T	F	F	F	F	T

Таблица 39 Факторный эксперимент: часть 14 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
595	да	P	P	P	P	P	P	P	P	P	P	P	G	P	P	G
596	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
597	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
598	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
599	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
601	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
602	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
603	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
604	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
606	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
607	да	F	F	P	F	F	F	F	F	F	F	F	P	F	F	F
608	да	F	F	F	F	F	F	F	F	F	F	G	F	F	F	F
609	да	F	P	P	P	P	P	P	P	P	P	P	P	P	P	P
610	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
611	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
612	да	P	P	P	P	F	F	P	P	P	F	F	F	P	F	F
613	да	F	F	F	F	F	F	F	F	F	F	F	F	P	F	F
614	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
616	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
617	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
618	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
620	да	P	F	P	P	P	P	P	P	P	P	P	P	P	F	P
622	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
623	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
624	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
625	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
626	да	P	P	F	F	F	F	P	P	P	F	F	F	F	F	F
627	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
628	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
629	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
630	да	P	F	F	F	P	P	F	F	F	F	F	P	F	F	P
632	да	P	P	P	P	P	P	P	P	P	F	P	P	F	P	P
633	да	F	F	P	F	F	P	F	F	F	F	P	F	F	F	F
634	да	F	F	F	F	F	F	P	F	F	F	F	F	F	F	F
635	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
636	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
637	да	F	F	P	F	F	F	F	F	P	F	F	P	P	F	P
638	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
639	да	P	G	P	P	P	P	P	P	P	P	P	P	P	P	P
641	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P

Таблица 40 Факторный эксперимент: часть 15 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
642	да	P	P	P	P	P	P	P	P	P	F	F	P	P	P	F
643	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
645	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
646	да	P	P	P	F	P	F	P	P	P	P	F	F	P	P	P
647	да	P	P	P	P	P	P	F	F	P	P	P	P	P	P	F
648	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
649	да	P	P	P	F	F	P	P	P	F	P	P	F	P	F	P
650	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
651	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
652	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
653	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
654	да	F	P	P	P	P	P	P	P	P	F	F	F	P	P	P
657	да	F	F	F	F	P	F	F	F	F	F	F	F	F	F	F
658	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
659	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
660	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
661	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
662	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
663	да	F	F	F	P	P	F	F	F	P	P	P	P	F	F	F
664	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
665	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
666	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
667	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
668	да	F	F	P	P	P	F	F	F	F	F	F	F	P	F	P
669	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
670	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
671	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
672	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
673	да	F	P	P	F	P	F	P	P	P	P	P	P	P	P	P
674	да	P	P	P	P	P	P	F	P	P	P	P	P	P	P	P
675	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
676	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
677	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
679	да	P	P	F	P	P	P	P	P	P	P	P	P	P	P	P
680	да	F	F	F	P	P	P	P	F	P	P	P	P	F	P	F
682	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
683	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
684	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
685	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
686	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P

Таблица 41 Факторный эксперимент: часть 16 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
687	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
688	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
689	да	P	P	P	F	F	P	P	P	P	P	P	P	P	P	P
690	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
691	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
692	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
693	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
694	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
695	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
696	да	P	P	F	P	P	P	P	F	P	F	F	P	F	P	P
697	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
698	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
700	да	P	P	P	P	P	P	P	F	F	P	F	F	P	P	F
701	да	P	P	P	F	F	F	P	P	P	P	F	F	F	P	F
702	да	P	P	F	P	P	P	P	P	P	F	F	P	P	P	P
703	да	P	P	F	F	F	F	F	F	F	F	F	F	P	F	F
704	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
705	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
706	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
707	да	P	P	P	P	P	P	P	P	P	F	F	P	P	P	P
708	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
709	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
710	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
711	да	P	P	P	P	P	P	P	P	P	F	F	F	P	P	F
713	да	P	F	F	P	F	P	F	F	P	F	P	P	P	F	F
714	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
715	да	P	P	P	P	P	P	P	P	P	P	F	F	F	P	P
716	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
717	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
718	да	F	F	P	F	P	P	F	F	F	P	P	P	F	P	F
720	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
721	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
722	да	P	P	P	P	F	P	P	P	F	F	F	F	F	F	F
723	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
724	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
725	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
726	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
727	да	F	F	F	P	F	F	F	P	F	F	P	F	F	F	F
729	да	F	P	F	P	F	F	P	P	P	P	P	P	P	P	P
730	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 42 Факторный эксперимент: часть 17 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
731	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
733	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
736	да	F	F	P	P	F	P	F	P	F	P	P	P	P	F	P
737	да	F	F	F	F	F	F	P	F	F	P	P	P	P	P	P
738	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
739	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
740	да	F	P	F	P	P	P	P	F	P	F	P	F	F	P	P
741	да	P	P	P	P	P	P	P	P	P	P	P	P	P	F	P
743	да	P	F	P	F	F	F	P	F	F	F	F	F	F	F	F
744	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
746	да	P	P	P	F	F	P	P	P	P	P	F	F	F	P	P
747	да	P	P	P	F	F	F	P	P	F	P	F	F	F	F	F
748	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
749	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
750	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
751	да	P	P	P	P	P	P	P	P	P	P	P	P	P	F	P
752	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
753	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
756	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
758	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
759	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
760	да	P	P	P	P	P	P	P	P	P	F	P	P	F	P	P
761	да	P	P	F	F	F	P	P	P	P	P	P	P	P	P	P
762	да	P	P	P	F	P	P	P	P	P	P	F	F	P	P	P
763	да	P	P	P	P	P	P	P	P	P	P	P	F	P	F	P
764	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
765	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
766	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
767	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
768	да	P	P	F	P	P	P	P	P	P	P	P	P	P	P	P
769	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
770	да	P	P	P	P	P	P	P	F	F	P	F	P	F	F	P
771	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
772	да	P	F	P	P	F	F	P	P	P	F	P	F	F	P	F
773	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
774	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
775	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
777	да	P	P	F	F	F	F	F	F	F	F	F	F	F	F	F
778	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
779	да	F	T	T	T	F	F	F	F	F	F	F	F	F	F	F

Таблица 43 Факторный эксперимент: часть 18 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
780	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
781	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
782	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
783	да	F	F	F	P	P	P	F	F	F	F	F	P	F	F	F
784	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
785	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
786	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
787	да	P	P	P	P	P	P	P	P	F	P	P	P	P	P	P
788	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
789	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
790	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
791	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	F
792	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
793	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
794	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
795	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
796	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
797	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
798	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
799	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
800	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
801	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
802	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
803	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
804	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
805	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
806	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
807	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
808	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
809	да	F	P	P	P	P	P	F	F	F	P	F	F	P	P	P
810	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
811	да	P	P	P	P	F	P	P	P	P	P	P	P	P	P	P
813	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
815	да	P	P	P	P	P	P	P	P	P	P	P	P	P	F	P
816	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
817	да	P	P	P	F	P	P	P	P	F	P	P	P	P	P	P
818	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
819	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
820	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
821	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 44 Факторный эксперимент: часть 19 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
822	да	P	P	P	P	P	P	P	P	P	P	P	G	P	P	P
823	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
824	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
825	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
826	да	P	P	P	P	F	P	F	P	P	F	P	F	P	P	P
828	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
829	да	P	F	P	P	P	P	F	P	P	P	P	P	P	P	P
830	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
831	да	P	F	F	P	P	F	P	P	P	P	P	P	P	P	P
832	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
835	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
836	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
837	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
838	да	P	P	P	P	P	P	P	P	P	F	P	P	P	P	P
840	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
841	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
842	да	P	F	F	F	P	F	F	F	F	F	F	F	F	F	F
843	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
844	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
845	да	F	F	F	P	P	P	P	P	F	P	F	F	F	F	P
846	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
847	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
848	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
849	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
850	да	P	P	P	P	F	P	P	P	P	F	P	P	P	P	P
851	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
852	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
853	да	P	P	F	P	F	F	P	F	P	F	F	F	P	F	F
856	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
857	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
859	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
860	да	F	F	F	F	F	P	F	P	F	F	F	F	P	F	F
861	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
862	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
863	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
864	да	F	F	F	P	F	F	F	F	F	F	F	F	F	F	F
866	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
867	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
868	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
869	да	P	P	P	T	P	P	P	P	P	P	P	P	P	P	P

Таблица 45 Факторный эксперимент: часть 20 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
870	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
871	да	P	P	P	P	P	F	F	P	P	P	P	P	F	P	F
872	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
873	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
874	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
875	да	P	F	F	P	P	P	F	P	P	F	P	P	P	F	P
876	да	P	P	F	P	P	F	P	P	F	P	P	P	P	P	P
877	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
878	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
880	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
881	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	P
883	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
884	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
886	да	P	P	F	P	P	P	P	P	F	P	F	F	P	P	F
887	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
888	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
889	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
890	да	P	F	F	F	P	P	P	P	F	P	F	P	P	F	F
891	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
893	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
896	да	P	F	P	P	P	P	P	F	P	F	F	P	F	F	P
897	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
898	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
899	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
900	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
901	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
902	да	F	P	P	P	P	P	P	P	P	P	P	P	P	P	P
903	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
904	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
905	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
906	да	P	P	P	P	P	F	P	P	F	F	P	F	P	P	F
908	да	F	P	P	F	F	F	F	F	F	P	F	F	F	P	P
909	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
910	да	P	F	F	F	F	F	F	P	F	F	F	F	F	F	F
911	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
912	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
913	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
914	да	P	F	P	P	P	P	F	F	F	F	F	F	F	F	F
915	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
916	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 46 Факторный эксперимент: часть 21 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
917	да	F	F	P	F	F	P	F	F	F	F	F	F	F	F	F
918	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
919	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
920	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
921	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
922	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
923	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
924	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
925	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
926	да	P	P	P	P	P	P	P	P	P	P	P	P	G	P	P
927	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
928	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
930	да	P	F	P	P	P	P	F	P	F	P	P	P	F	P	P
931	да	F	P	P	F	P	F	P	P	P	P	P	P	P	F	F
932	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
933	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
934	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
935	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
937	да	P	P	P	P	P	P	P	P	P	P	P	P	F	P	P
938	да	P	F	P	P	P	P	P	P	F	P	P	P	P	P	P
939	да	P	P	P	P	F	F	P	P	P	F	F	F	F	F	P
940	да	F	P	P	P	P	P	P	P	P	P	P	F	F	P	P
941	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
942	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
943	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
944	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
945	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
946	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
947	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
948	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
949	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
950	да	P	P	P	P	P	P	P	P	P	F	P	P	P	P	P
951	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
952	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
953	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
954	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
955	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
956	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
957	да	P	P	P	P	P	P	F	P	P	P	P	P	P	P	P
958	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P

Таблица 47 Факторный эксперимент: часть 22 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
959	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
960	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
961	да	P	P	P	P	P	P	P	P	P	P	P	P	F	P	F
962	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
963	да	F	F	F	F	P	F	F	F	F	F	P	F	F	F	F
965	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
966	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
967	да	P	P	P	P	P	P	P	F	P	P	P	F	P	P	P
968	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
969	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
971	да	F	F	P	P	P	P	P	F	P	F	P	F	P	P	P
972	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
973	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
974	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
975	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
976	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
977	да	F	F	F	F	F	F	F	F	F	P	F	F	F	F	F
978	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
979	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
980	да	P	P	P	F	P	P	P	P	P	F	P	F	F	P	P
981	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
982	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
984	да	F	P	F	F	F	F	F	F	F	F	P	P	F	F	F
985	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
986	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
987	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
988	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
989	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
990	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
991	да	P	P	P	P	P	F	P	P	P	F	F	F	F	F	F
993	да	P	P	P	P	F	P	P	F	F	P	F	F	P	F	P
994	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
995	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
996	да	F	F	F	F	F	F	P	F	F	F	P	F	F	F	F
997	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
998	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
999	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1000	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1001	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1002	да	P	P	P	P	P	F	P	P	P	F	F	F	F	F	F

Таблица 48 Факторный эксперимент: часть 23 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
1004	да	P	P	F	P	P	P	P	P	P	F	P	P	P	P	P
1006	да	P	P	P	P	P	P	F	P	P	P	P	P	P	F	P
1007	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1008	да	P	P	P	F	F	P	F	F	F	F	P	F	F	F	F
1009	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1010	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1012	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
1014	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1015	да	F	F	F	P	P	P	P	F	P	F	P	P	P	F	F
1017	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1018	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1020	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1021	да	F	P	P	P	F	F	P	F	F	F	P	F	F	F	F
1023	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1024	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1025	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1026	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1028	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
1030	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1031	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1032	да	P	P	P	P	P	P	P	P	P	P	P	G	P	P	P
1033	да	F	F	F	F	F	F	F	F	F	G	F	F	G	F	F
1034	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1035	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1037	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1038	нет	U	U	U	U	U	U	U	U	U	U	U	U	U	U	U
1039	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1040	да	T	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1041	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1042	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1043	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1044	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1045	да	P	P	P	P	P	P	P	P	P	P	P	F	P	P	P
1046	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1047	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1048	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1049	да	F	F	F	F	F	F	P	F	F	F	F	F	F	F	F
1050	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1051	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1052	да	P	P	P	F	F	P	F	F	F	F	F	F	F	F	F

Таблица 49 Факторный эксперимент: часть 24 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
1053	да	P	P	P	P	P	P	P	P	P	F	P	P	P	F	P
1054	да	P	P	F	P	F	F	P	P	P	P	P	P	F	P	P
1055	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1056	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1057	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1058	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1059	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1060	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1061	да	F	P	P	P	P	P	P	P	P	P	F	G	F	P	G
1062	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1063	да	P	P	P	P	F	P	P	P	P	P	F	P	P	P	F
1064	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1065	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1066	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1067	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1068	да	F	P	P	P	P	P	P	P	F	F	F	F	F	F	P
1069	да	F	P	F	F	F	F	F	F	F	P	F	P	P	F	F
1070	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1071	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1072	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1073	да	F	F	F	F	P	F	F	F	F	F	F	F	F	F	F
1075	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1076	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1077	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1078	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1079	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1080	да	P	P	P	P	P	P	P	P	P	P	F	P	P	P	P
1081	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1082	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1083	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1084	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1085	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1086	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1088	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1089	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1090	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1091	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1092	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1093	да	F	F	F	P	F	F	F	F	P	P	P	F	P	P	F
1094	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Таблица 50 Факторный эксперимент: часть 25 из 25. P: успех; F: провал тестов; T: тайм-аут; X: форматный отказ; G: нет полного кандидата; N: нативный исход недоступен; U: качество недоступно по контролю.

ID	Контроль	D			SN			SR			MN			MR		
		101	102	103	101	102	103	101	102	103	101	102	103	101	102	103
1095	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1096	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1097	да	P	P	P	P	P	P	P	P	P	F	F	F	P	F	F
1098	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1099	да	F	P	P	P	P	P	P	P	P	P	P	P	F	P	P
1100	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1101	да	P	P	P	P	P	P	P	P	P	F	F	P	P	P	F
1102	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1103	да	F	F	F	F	F	F	P	P	P	F	F	F	P	P	F
1104	да	F	P	F	F	F	F	F	P	P	F	F	F	F	F	F
1105	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1106	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1108	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1109	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1111	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1112	да	G	F	F	F	F	F	F	F	F	G	F	F	G	F	F
1113	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1114	да	P	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1116	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1117	да	P	P	P	P	G	P	P	G	P	F	G	F	P	G	P
1118	да	P	P	P	P	P	P	P	P	P	F	P	P	P	P	P
1119	да	P	P	P	P	P	P	P	P	P	P	P	P	P	F	P
1120	да	F	P	F	F	P	P	F	P	P	F	F	F	F	F	F
1123	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1124	да	P	F	F	F	P	F	P	P	F	F	F	F	P	P	P
1125	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1126	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1127	да	F	F	F	P	F	P	F	F	F	F	F	F	F	F	F
1128	да	P	P	P	P	P	P	P	P	P	P	P	P	P	G	P
1129	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1130	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F
1131	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1132	да	F	F	F	F	F	F	F	F	F	F	F	G	F	F	G
1133	да	P	P	P	P	P	P	P	P	P	P	P	P	P	P	P
1134	да	P	P	P	P	P	P	P	P	P	F	P	P	P	P	P
1135	да	P	F	F	T	P	F	P	F	P	P	F	F	F	F	F
1136	да	P	F	P	P	P	P	P	P	P	P	F	P	P	F	P
1137	да	P	P	P	P	P	P	P	P	P	P	F	F	F	F	F
1138	да	P	P	P	P	P	P	F	P	P	P	F	P	F	P	F
1139	да	F	F	F	F	F	F	F	F	F	F	F	F	F	F	F

Е Полные исходы задач разработки

Таблица 51 Все задачи разработки и оба повтора. В каждой паре буквы обозначают повторы 2 и 3: P — тесты пройдены, F — не пройдены, U — качество недоступно. Приведены исходные оценки с учётом эталонного контроля; спорные тесты не удалены.

ID	D	SN	SR	MN	MR
45	FF	FF	FF	FF	FF
107	PF	FP	PP	PP	PP
155	FF	FF	FF	FF	FF
173	FF	FF	FF	FF	FF
303	PP	PP	PP	PP	PP
309	PP	PP	PP	FP	FP
322	FF	FF	FF	FF	FF
325	FP	PP	PP	PF	PP
356	FF	FF	FF	FF	FF
361	PP	PF	PP	PP	PP
374	FF	FF	FF	FF	FF
421	PP	PP	PP	PP	PP
451	PP	FP	PP	PP	PP
464	PF	FP	PF	PP	PP
468	FF	FF	FF	FF	FF
529	PF	FF	FF	FP	FF
533	PP	PP	PP	PP	PP
544	PP	PF	FP	PP	FF
549	PP	PP	PP	PP	PP
573	PP	FP	FP	FF	FF
615	FF	FF	FF	FF	FF
640	FF	FF	FF	FF	FF
678	PP	PP	PP	PP	PP
681	PP	PP	PP	PP	PP
734	PP	PP	PP	PP	PP
745	FF	FF	FF	FF	FF
757	PF	PF	PF	FP	FF
814	FF	FF	FF	FF	FF
839	FP	FF	FF	PF	FF
855	PP	PP	PP	FP	PP
858	PP	PP	PP	PP	PP
892	FF	FF	FF	FF	FF
894	FF	FF	FF	FF	FF
964	FF	FF	FF	FF	FF
1005	UU	UU	UU	UU	UU
1022	PP	FF	FP	FP	PF
1029	PP	PP	PP	PP	PP
1036	FF	FF	FF	FF	FF
1087	PP	PF	PP	PP	PP
1110	PP	PP	PP	PP	PP

Ф Полные исходы независимого эксперимента

Таблица 52 Все 80 назначенных задач в исходном случайном порядке. P/F: оцениваемый успех/неуспех; CP/CF: нативный успех/неуспех при непригодном контроле, вне статистики качества; M: нет генерации/оценки. Идентификаторы сокращают BigCodeBench/n. В каждой половине столбцы RB, NB, RP, NP.

ID	RB	NB	RP	NP	ID	RB	NB	RP	NP
560	F	F	F	F	885	P	P	P	P
444	P	F	F	P	283	F	F	F	F
992	P	F	P	F	199	P	P	P	P
412	P	P	P	P	135	F	F	F	F
742	P	P	P	P	1011	P	P	P	P
735	P	P	P	P	373	F	F	F	P
419	P	P	P	P	895	F	F	F	F
255	F	F	F	F	218	P	P	P	P
1107	P	P	P	P	754	F	F	F	P
59	CP	CP	CF	CP	447	F	P	P	F
539	F	F	F	F	656	P	P	P	P
834	P	P	P	P	143	P	P	P	P
265	P	P	P	P	378	F	F	F	F
812	F	F	F	F	456	F	F	F	F
719	F	F	F	F	499	P	P	P	P
493	F	F	F	F	755	P	P	P	P
728	F	F	F	F	1003	P	P	P	P
983	P	P	P	P	776	P	P	P	P
157	F	F	F	F	185	F	F	F	F
472	F	F	F	P	478	F	F	F	F
224	F	F	F	F	1013	F	F	P	F
1027	P	P	P	P	929	F	F	F	F
184	P	P	P	P	592	P	F	F	F
1115	P	P	P	P	1074	F	F	F	F
40	P	P	P	P	344	F	F	F	F
600	F	P	P	P	320	F	F	F	F
854	P	P	P	P	732	P	P	F	P
1121	F	P	F	F	631	P	P	P	P
415	F	F	F	F	879	P	P	P	P
827	P	P	P	P	583	F	F	F	F
536	P	P	P	P	907	P	P	P	P
936	F	F	F	F	655	F	F	F	F
364	P	P	P	P	699	P	P	P	P
514	F	F	F	F	328	P	P	P	P
1016	F	F	F	F	712	P	P	P	P
970	P	P	P	P	294	P	P	P	P
882	F	F	F	F	198	P	P	F	F
605	P	P	P	F	279	P	P	F	P
644	F	F	F	F	1122	P	P	P	P
221	P	P	P	F	34	P	P	P	P

Г Исторические данные и калибровка

Прежние 240 записей Flash-Lite охватывают 20 задач, четыре целевые длины, три архитектуры и один seed, а не 240 независимых задач. Все метки качества равны единице, полные решения отсутствуют: арифметика проверяема, корректность — нет. В 48/80 записях V3 есть повторный вызов; итоговые метки не являются pass@1 одной попытки. Сравнение с V2 смешивает роли, вызовы, повторы и выбор контекста. Относительно простого V0 расход выше на 10.3–85.0% при трёх меньших длинах; экономия на максимальной совпадает с выбором части входа. Эти записи мотивируют новый эксперимент, но не входят в его оценки.

Пилот на восьми задачах получил 40 кандидатов за 72 хода с условной стоимостью USD 0.7417401. На семи оцениваемых задачах прямое решение прошло 4/7, роли одним вызовом — 3/7, тремя — 2/7. Расширение использует новые ответы. Ранняя попытка CLI 0.144.1 отвергнута из-за инструмента планирования; сохранены все 21 отправленный ход и известный расход USD 0.2493285. Отвергнутые ответы не переносятся в валидную матрицу.

Список литературы

- [1] Y. Dong, X. Jiang, Z. Jin, and G. Li. Self-collaboration Code Generation via ChatGPT. arXiv:2304.07590v2, 2023. <https://arxiv.org/abs/2304.07590v2>.
- [2] Y. Dong. Self-collaboration Code Generation: accompanying Python software, 2024 implementation. Analyst–coder–tester session with execution of generated tests. Software associated with Dong et al., arXiv:2304.07590.
- [3] A. Madaan et al. Self-Refine: Iterative Refinement with Self-Feedback. NeurIPS, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/91edff07232fb1b55a505a9e9f6c0ff3-Abstract-Conference.html.
- [4] N. Shinn, F. Cassano, A. Gopinath, K. Narasimhan, and S. Yao. Reflexion: Language Agents with Verbal Reinforcement Learning. NeurIPS, 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/1b44b878bb782e6954cd888628510e90-Abstract-Conference.html.
- [5] H. Sun and S. Zeng. Introspection of Thought Helps AI Agents. arXiv:2507.08664v1, 2025. <https://arxiv.org/abs/2507.08664v1>.
- [6] D. Tran and D. Kiela. Single-Agent LLMs Outperform Multi-Agent Systems on Multi-Hop Reasoning Under Equal Thinking Token Budgets. arXiv:2604.02460v2, 2026. <https://arxiv.org/abs/2604.02460v2>.
- [7] C. S. Xia, Y. Deng, S. Dunn, and L. Zhang. Agentless: Demystifying LLM-based Software Engineering Agents. arXiv:2407.01489, 2024. <https://arxiv.org/abs/2407.01489>.

- [8] J. Yang et al. SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering. NeurIPS, 2024. <https://arxiv.org/abs/2405.15793>.
- [9] T. Y. Zhuo et al. BigCodeBench: Benchmarking Code Generation with Diverse Function Calls and Complex Instructions. ICLR, 2025. <https://arxiv.org/abs/2406.15877>.
- [10] C. E. Jimenez et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR, 2024. <https://arxiv.org/abs/2310.06770>.
- [11] SWE-bench maintainers. Evaluation Guide. Accessed 8 September 2026. <https://www.swebench.com/SWE-bench/guides/evaluation/>.
- [12] OpenAI. GPT-5.4 mini model documentation. Accessed 8 September 2026. <https://developers.openai.com/api/docs/models/gpt-5.4-mini>.
- [13] OpenAI. GPT-5.6 Luna model documentation and pricing. Accessed 11 September 2026. <https://developers.openai.com/api/docs/models/gpt-5.6-luna>.
- [14] OpenAI. API pricing, standard text-token rates. Accessed 8 September 2026. <https://developers.openai.com/api/docs/pricing>.
- [15] OpenAI. Codex non-interactive mode and JSONL event stream. Accessed 8 September 2026. <https://developers.openai.com/codex/noninteractive>.
- [16] M. Zheng, J. Pei, L. Logeswaran, M. Lee, and D. Jurgens. When “A Helpful Assistant” Is Not Really Helpful: Personas in System Prompts Do Not Improve Performances of Large Language Models. Findings of EMNLP, pp. 15126–15154, 2024. <https://aclanthology.org/2024.findings-emnlp.888/>.
- [17] P. H. Luz de Araujo, P. Röttger, D. Hovy, and B. Roth. Principled Personas: Defining and Measuring the Intended Effects of Persona Prompting on Task Performance. EMNLP, pp. 26857–26886, 2025. <https://aclanthology.org/2025.emnlp-main.1364/>.
- [18] H. K. Choi, X. Zhu, and S. Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? NeurIPS, 2025; arXiv:2508.17536v2. <https://arxiv.org/abs/2508.17536v2>.
- [19] F. V. Wunderlich, L. B. Kaesberg, J. P. Wahle, T. Ruas, and B. Gipp. Multi-Agent Reasoning Improves Compute Efficiency: Pareto-Optimal Test-Time Scaling. ACL Student Research Workshop, pp. 1–14, 2026. <https://aclanthology.org/2026.acl-srw.1/>.
- [20] M. Allamanis. The Adverse Effects of Code Duplication in Machine Learning Models of Code. Onward!, 2019. <https://arxiv.org/abs/1812.06469>.

- [21] J. G. MacKinnon, M. Ø. Nielsen, and M. D. Webb. Cluster-Robust Inference: A Guide to Empirical Practice. *Journal of Econometrics*, 232(2), 272–299, 2023.
<https://doi.org/10.1016/j.jeconom.2022.04.001>.