

Ролевые обозначения и границы вызовов при генерации кода: факторный эксперимент без компрессии на 200 задачах

Даниил Привезенцев^{1*}

^{1*}Национальный исследовательский университет «Высшая школа экономики», Москва, Россия.

Corresponding author(s). E-mail(s): daprivezentsev@edu.hse.ru;

Аннотация

Ролевые конвейеры часто одновременно меняют инструкции и структуру вызовов модели, скрывая источник экономии. В эксперименте скрещены нейтральные и ролевые обозначения этапов с одним и тремя вызовами при одинаковых операциях и полном предоставленном контексте; добавлено прямое решение. Случайная резервная выборка из 200 задач BigCodeBench задаёт 1 000 программ на GPT-5.4 mini со средним уровнем рассуждения. После раскрытого продолжения только неотправленных назначений получены и проверены исходными нативными тестами 996 программ; эталонные контроли проходят на 193 задачах. Качество составляет 44.56–48.70%, устраняя прежний потолок. Разность качества ролей и нейтральных этапов равна -1.05 процентного пункта в одном вызове (описательный 95%-интервал [-4.71,+2.62]) и +1.04 [-3.11,+5.70] в трёх. Ни один из четырёх заранее заданных тестов не отклоняет нулевую гипотезу после поправки Холма. На полных ресурсных парах роли в одном вызове требуют на 8.76% меньше токенов и имеют на 18.45% меньшую оценку по API-тарифам; три вызова стоят в 2.09–2.50 раза дороже одного. Известный расход основной серии — 8 585 185 токенов и USD 14.20482 по опубликованным ставкам; для трёх прерванных вызовов счётчики отсутствуют. Отдельно сохранены этап разработки (400 программ) и независимая адаптация INoT (199 программ). Полные выведенные ответы и нативные отчёты позволяют перепроверить результаты. Установлено ресурсное различие конкретного протокола, но не доказаны неухудшение качества и общее преимущество внутренних агентов.

Keywords: Code generation, role prompting, factorial design, token accounting, BigCodeBench, reproducibility

1 Введение

Планирование, реализацию и проверку можно задать этапами одного ответа или распределить между последовательными вызовами модели. Название этих этапов агентами вводит второе изменение — ролевую формулировку. Сравнение, которое дополнительно сжимает вход, не позволяет определить причину экономии ресурсов или различия качества. В частности, более дешёвый сжатый ответ не устанавливает пользу внутреннего разделения ролей. Эта проблема идентификации мотивирует контролируемую проверку обозначений и границ вызовов на исполнимых задачах программирования.

Исследуемое воздействие определено точно. Нейтральные номера этапов либо названия `planner`, `implementer` и `reviewer` сопровождают одинаковые предложения с описанием операций. Независимо от обозначений операции запрашиваются в одном новом вызове модели либо в трёх новых вызовах с передачей всей видимой истории. Каждое условие получает одну и ту же полную задачу и весь предоставленный контекст. Инструкция прямой реализации за один вызов служит простейшим сравнением. Поэтому контрасты обозначений изолируют формулировку при фиксированной топологии, а контрасты числа вызовов включают поток промежуточной информации и повторный инференс. Эти интерпретации не требуют утверждать, что названия ролей создают независимых скрытых агентов.

Исследование разделяет этап разработки на 40 задачах и резервную выборку из 200 задач, использует исходные исполнимые тесты `BigCodeBench` и отдельно оценивает зафиксированную адаптацию `INoT PromptCode` на тех же резервных задачах. Демонстрация на одном `issue` `SWE-bench` задаёт ограниченную границу переноса на ремонт репозитория. Качество на этих задачах может изменяться; каждое назначение остаётся в учёте даже при неудачной генерации или отказе эталона. Опубликованные тарифы `GPT-5.4 mini` позволяют явно оценить ресурсы по фактическим счётчикам подписочного канала и отдельно показать чувствительность к скидке за кеш.

Вклад состоит в протоколе 2×2 без компрессии с прямым решателем, парном анализе задач с четырьмя заранее заданными контрастами качества и явным учётом пропусков, а также полном архиве доступных ответов, программ, штатных отчётов и токенов, проверяемом без новых вызовов модели. Эмпирическое утверждение ограничено фиксированными промптами, запрошенным псевдонимом модели и выборкой задач. Исследовательский вопрос — улучшают ли ролевые обозначения и границы вызовов измеренное сочетание качества и ресурсов в этих условиях.

2 Связанные исследования

`INoT` описывает компактные инструкции `PromptCode` для внутреннего диалога и рассуждения [1]. Это мотивирует оценку раскрытой адаптации алгоритма, тогда как отдельное минимальное воздействие обозначений проверяет, меняют ли результат сами названия ролей. Сравнения отвечают на разные вопросы: инструкция `INoT` изменяет процедуру рассуждения, а факторный контраст обозначений сохраняет предложения с описанием операций. Исходное сравнение `Hybrid-INoT`

дополнительно изменяло компрессию и повторные попытки; его исторические записи сохраняются как контекст, а не объединяются с новым экспериментом.

Исследование одно- и многоагентных систем при сопоставимом бюджете токенов рассуждения подчёркивает различие дополнительных вызовов и дополнительных вычислений [2]. Здесь фактическая длина завершения не ограничена одинаковым жёстким бюджетом. Вместо этого компоненты числа токенов и денежная оценка приводятся как измеренные исходы вместе с качеством. Такой дизайн характеризует соотношения реализованных протоколов и не устанавливает оптимальное распределение фиксированного бюджета инференса.

Agentless использует структурированный процесс локализации, исправления и проверки [3]; SWE-agent связывает модель с интерфейсом репозитория [4]. Обе системы добавляют поиск, инструменты и взаимодействие с окружением сверх генерации функций при фиксированном контексте. Их опубликованные оценки нельзя вставлять в парную матрицу с другими задачами и настройками. BigCodeBench [5] предоставляет разнообразные задачи с библиотечными зависимостями и исполнимыми тестами, а SWE-bench [6, 7] проверяет изменения репозитория тестами конкретных issue. Штатная оценка усиливает валидность исходов, однако успешный эталонный контроль не разрешает каждое расхождение естественно-языковой инструкции и теста.

Исследования persona prompting мотивируют более узкое утверждение, чем универсальная польза ролей для рассуждения. Zheng и соавторы не обнаруживают устойчивого улучшения от системных персон в исследованных фактологических задачах [13]. Luz de Araujo и соавторы разделяют качество, устойчивость к несущественным атрибутам персоны и соответствие заданной специализации; результаты зависят от модели и задачи [14]. Эти работы не проверяют наши запросы на генерацию кода. Они обосновывают изменение обозначений при сохранении требуемых операций и ограничение вывода конкретными использованными обозначениями.

Данные о нескольких агентах также зависят от выбранного сравнения. Choi и соавторы связывают значительную часть выигрыша в своих NLP-экспериментах с независимым голосованием, отделяя обмен сообщениями от агрегации [15]. В то же время Wunderlich и соавторы находят конфигурации, в которых debate или mixture-of-agents улучшают соотношение вычислений и точности относительно self-consistency на MMLU-Pro и BBH [16]. Это основание для условной оценки, а не универсального вывода за или против нескольких агентов. Наша нейтральная последовательная цепочка не является голосованием, смесью независимых моделей или ансамблем с выровненным бюджетом. Вклад работы — факторная проверка одной модели на исполняемом коде с полным учётом трасс и расходов; общее превосходство над перечисленными альтернативами не входит в оцениваемый эффект.

3 Дизайн исследования и оцениваемые эффекты

3.1 Факторный эксперимент без компрессии

В основном эксперименте независимо варьируются число вызовов модели (один или три) и обозначения этапов (нейтральные или ролевые). Таблица 1 определяет четыре факторных условия и прямой решатель. Во всех структурированных условиях предписаны одинаковые операции: анализ требований и граничных случаев, реализация по плану, затем проверка и исправление относительно требований. Ролевое воздействие заменяет обозначения «stage 1», «stage 2», «stage 3» на «planner», «implementer», «reviewer»; предложения с описанием операций остаются неизменными. При одном вызове все три инструкции предшествуют задаче. При трёх вызовах каждый получает инструкцию своего этапа, полный текст задачи, весь предоставленный контекст и все полные предыдущие видимые ответы. Итоговый формат одинаков: ровно один блок с полной программой Python. Прямой решатель получает только инструкцию реализации и требование к итоговому формату.

Таблица 1 Реализованные условия. Фактор числа вызовов включает передачу промежуточных ответов между новыми вызовами.

Код	Вызовы	Обозначения	Операции
D	1	Нет	Прямая реализация
SN	1	Нейтральные	План, реализация, проверка
SR	1	Ролевые	План, реализация, проверка
MN	3	Нейтральные	План, реализация, проверка
MR	3	Ролевые	План, реализация, проверка

Компрессия отсутствует во всех условиях. Такая постановка заменяет прежнее сравнение трёх вызовов без сжатия с одним сжатым вызовом, но не оценивает эффект прежнего компрессора. Контраст обозначений является воздействием на промпт, а не свидетельством независимых внутренних агентов. Контраст числа вызовов включает поток промежуточной информации и повторный инференс, а не только механическое изменение счётчика вызовов. Непроверенные маршрутизатор и дополнительная модель проверки исключены из заявленного метода.

Пусть $Y_t(a)$ показывает, прошла ли единственная итоговая программа для задачи t в условии a исходные тесты бенчмарка в проверенном окружении. Четыре заранее заданных парных эффекта качества имеют вид

$$\Delta_{R,1} = \mathbb{E}_t[Y_t(\text{SR}) - Y_t(\text{SN})], \quad \Delta_{R,3} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{MN})], \quad (1)$$

$$\Delta_{C,N} = \mathbb{E}_t[Y_t(\text{MN}) - Y_t(\text{SN})], \quad \Delta_{C,R} = \mathbb{E}_t[Y_t(\text{MR}) - Y_t(\text{SR})]. \quad (2)$$

Каждая нулевая гипотеза задаёт нулевую разность качества. Описательное взаимодействие равно $\Delta_{R,3} - \Delta_{R,1}$. Ожидания относятся к выборке задач при реализованном протоколе и стохастической генерации, а не к свойству, независимому от поставщика модели. Оценки по доступным данным требуют полных пар; при пропусках без дополнительных предположений они характеризуют именно наблюдаемую подвыборку.

3.2 Распределение задач и отдельный этап разработки

Источник задач — BigCodeBench v0.1.4 [5]. Основная выборка содержит 200 новых идентификаторов из ранее зафиксированной случайной перестановки резервного пула с заданным начальным состоянием генератора. Взяты первые 200 допустимых идентификаторов в этом случайном порядке после исключения восьми примеров карточки датасета (/0–/7), случайно просмотренных при проверке лицензии. Это не первые строки датасета и не отбор по сложности. Идентификаторы, точные входы модели и данные оценщика хешируются до контролей; неудачный контроль не приводит к замене задачи. Сорок задач разработки не пересекаются с этими 200. Этап разработки включает два обозначенных повтора и 400 программ, основная выборка — один новый повтор и 1 000 назначений. Последние дают не более 200 независимых единиц выборки, а не 1 000 независимых задач. Родственные задачи могут дополнительно уменьшать эффективную независимость. Публичность бенчмарка оставляет открытым вопрос о наличии задач в обучающих данных.

Каждой основной задаче назначены все пять условий. Четыре непересекающиеся группы по остатку индекса от деления на четыре содержат по 50 задач. В каждой группе зафиксированный псевдослучайный порядок определяет блоки задач и порядок условий; группу обрабатывают два работника, одновременно действует не более восьми экспериментальных процессов CLI. Полная матрица и хеши исходного кода закоммичены до отправки запросов. Модель не получает тесты бенчмарка, эталонные решения или результаты тестирования во время генерации. Метки повторов обозначают новые наблюдения по протоколу, а не случайные состояния модели у поставщика.

3.3 Генерация и полные доступные трассы

Используются запрошенный псевдоним модели `gpt-5.4-mini`, уровень рассуждения `medium` и официальный Codex CLI 0.153.4 с аутентификацией подписки ChatGPT [10, 12]. Опубликованный тариф позволяет проверить денежную оценку ресурсов; выбранная конфигурация является экономичным доступным вариантом для кода, но глобальный минимум цены не доказан. CLI изолирован от пользовательской конфигурации и инструкций репозитория. Инструменты, браузер, делегирование и выполнение тестов отключены. Каждый вызов создаёт новую временную сессию в пустом рабочем каталоге. Допустимая схема событий требует ровно одного полного ответа и корректной записи использования; неожиданный инструмент, повтор или событие сжатия нарушают заданное текстовое условие.

Для каждого отправленного вызова сохраняются точный промпт, аргументы, поток событий, стандартный поток ошибок и конечное состояние. Для завершённых записей дополнительно сохраняются итоговый текст, компоненты числа токенов и хеши исходных файлов. Входы последующих вызовов реконструируются и побайтно сверяются с полными предыдущими доступными ответами. Доступность скрытых рассуждений поставщика не предполагается. Псевдоним модели не фиксирует неизменные веса; проверенное управление температурой и случайным состоянием модели отсутствует. На вызов установлен предел 180 секунд. Вход свыше 65 536 байт UTF-8 отклоняется, а не сокращается. Единственного жёсткого ограничения выходных токенов нет; длина ответа и потребление ресурсов являются результатами воздействия.

Исходное правило останавливает группу после первой неудачной попытки. Поэтому сетевые обрывы и превышения времени оставляют другие назначения неотправленными. Отдельная закоммитенная поправка, записанная до оценки или просмотра качества основной выборки, разрешает продолжить только такие неотправленные назначения. Любое назначение хотя бы с одним начатым этапом навсегда исключается из продолжения. Точный список оставшихся назначений и завершённый архив первой серии фиксируются до отправки; сохраняются промпты, настройки, ограничения времени и исходный порядок внутри группы. Явный сетевой обрыв или превышение времени завершает попытку без повтора; ошибки квоты, аутентификации и нераспознанные ошибки останавливают дальнейшую отправку. Первые попытки, продолжения и пропуски остаются различимыми. Таким образом, анализ использует заранее заданные контрасты при изменённом протоколе исполнения; это не неизменённый пререгистрированный запуск.

3.4 Штатная оценка и контроль оцениваемости

Неизменённый CLI BigCodeBench на коммите 09dd993f46c3 выполняет исходные тесты задач в режиме `instruct full`. Каждый запуск оценщика использует контейнер без сети, от непривилегированного пользователя, с основной файловой системой только для чтения, пределом памяти 3 ГБ, двумя CPU и двумя работниками оценщика. Подготовленные данные, точное дерево исходников, идентификатор образа, версии пакетов, автономные ресурсы, команды и штатные отчёты архивируются. Строгое извлечение выбирает единственный итоговый блок Python; нарушение формата даёт пустую наблюдаемую программу и отдельный признак ошибки формата, без выбора альтернативного ответа или исправления.

До генерации модели исходные эталонные и заведомо неверные программы проверены на всех 200 задачах. Изменения зависимостей ограничены этапом контролей, сохраняют предыдущие неудачные запуски и вызывают повторные контроли всей матрицы. Итоговое окружение пропускает 193 эталона и отклоняет все 200 неверных программ. Поэтому семь задач недоступны для оценки качества во всех условиях; их назначения и ресурсы генерации сохраняются в учёте. Итоговый образ дополняет окружение разработки фиксированными зависимостями и автономными ресурсами NLTK. Штатная диагностика эталонов содержит

ошибки DNS (/101, /590), отсутствие TensorFlow (/418), неподдерживаемый аргумент кодировщика (/686), проверки моментов вырожденной выборки (/276) и проверки архива/журнала (/14, /1028). Последующая проверка без изменения объема подтверждает отсутствие внешних команд, используемых последними двумя задачами; связь этих отказов с отсутствием команд является диагностическим выводом по исходникам. Позднейшая диагностика не меняет зафиксированный контроль оцениваемости. Контроли устанавливают оцениваемость и различение заведомо неверного решения, но не полную семантическую согласованность инструкции и теста.

Оценщику передаются только реально полученные программы. Каждый результат связывается с точной архивной программой, исходным идентификатором задачи и проверенным окружением; незавершённые запуски оценщика и противоречивые отчёты не могут давать наблюдения качества. Исходный штатный статус хранится рядом с отдельным аналитическим статусом с учётом контроля оцениваемости. Для отсутствующей генерации не создаётся фиктивный отказ тестов. Одинаковый контроль применяется ко всем условиям и поисковой репликации INoT.

3.5 Статистический анализ, пропуски и оценка ресурсов

Для каждого из четырёх запланированных контрастов качества приводятся число полных пар, оба числа несогласованных исходов, средняя парная разность, точный двусторонний биномиальный тест Мак-Немара и скорректированное по Холму p для семейства четырёх тестов при $\alpha = 0.05$. Процентильные интервалы используют 10 000 бутстрэп-выборок задач с начальным состоянием анализа 20260908; эти описательные интервалы не являются одновременными интервалами. Взаимодействие, ресурсные контрасты и сравнения с прямым решателем остаются описательными. Взаимодействие использует задачи с полными наблюдениями во всех четырёх факторных условиях; оно может не совпадать с вычитанием двух отдельно оценённых ролевых контрастов, если их доступные подвыборки различаются. Повторы разработки усредняются внутри задачи в отдельном описательном анализе и не объединяются с основными тестами.

При 200 независимых оцениваемых задачах наихудшая нормальная 95%-полуширина для одной доли приблизительно равна 6.9 процентного пункта. Это обоснование точности, а не расчёт 80%-мощности для парного эффекта; неопределённость парной разности зависит от несогласованных исходов. Исследование не устанавливает неухудшение в пределах двух пунктов. Качество условия оценивается по доступным наблюдениям и сопровождается границами пропусков по всем назначениям: недоступные исходы считаются сначала всеми неудачами, затем всеми успехами. Эти границы не являются доверительными интервалами или поправкой при случайных пропусках.

Завершённый вызов CLI возвращает счётчики входа I , кешированного входа C и выхода O . Кешированный вход входит в общий вход; отдельно доступное число токенов рассуждения входит в выход. Повторного суммирования нет. Опубликованные стандартные тарифы API составляют соответственно USD 0.75, 0.075 и

4.50 за миллион токенов [11]. Рассчитываются

$$V = \frac{0.75(I - C) + 0.075C + 4.50O}{10^6}, \quad V_0 = \frac{0.75I + 4.50O}{10^6} \quad \text{USD.} \quad (3)$$

V — контрфактическая оценка измеренных токенов подписки по прейскуранту API, а не платёж или счёт; V_0 — анализ чувствительности без скидки за кеш. Обе оценки исключают работу исследовательских ассистентов, разработку кода, сборку окружения и вычисления оценщика. Средние ресурсы программы суммируют её завершённые вызовы. Отдельный реестр включает доступные счётчики прерванных программ и явно считает вызовы без итогового учёта; неизвестное использование не заменяется нулём. Отношения ресурсов используют одну и ту же подвыборку полных пар в числителе и знаменателе. Время отправки и состояние кеша могут влиять на денежную оценку, особенно между отдельно запущенными сериями.

4 Поисковая репликация алгоритма INoT

Четыре сконструированных факторных условия не подменяют опубликованный метод. Поэтому отдельно зафиксирована промптовая репликация INoT [1], обозначенная INoT*. Она использует те же 200 задач, полный предоставленный контекст, GPT-5.4 mini medium, итоговый формат и контроль оцениваемости. На задачу приходится один новый вызов, работают два работника с тем же пределом 180 секунд. Независимо сформулированная инструкция PromptCode описывает двух виртуальных участников, исходные ответы, взаимные аргументы, критику, возражения, обновления и проверку согласия с пределом десять раундов. Это концептуальная инструкция для модели, а не код, исполняемый на компьютере, или проверенная последовательность скрытых взаимодействий агентов.

Правило остановки следует текстовому описанию исходной статьи: согласие либо предел раундов. Соответствующий исходный листинг содержит неоднозначное условие цикла и не задаёт итоговый ответ при отсутствии согласия. В этой репликации явно возвращается последний ответ виртуального участника А. Дополнение изображениями исключено для текстовых задач. Точная независимо сформулированная инструкция архивируется. Проверенная исполняемая авторская реализация для данной постановки не найдена; подтверждение адаптации авторами не заявляется.

Независимое административное продолжение использует то же правило «только ещё не отправленные»: начальная попытка с превышением времени не повторяется, а оставшиеся 137 нетронутых назначений фиксируются и отправляются по одному разу. Все трассы первой серии и продолжения хранятся раздельно. Сравнения INoT* с D и SR являются поисковыми и не входят в четыре основных теста. Парность контролирует состав задач, но отдельная серия сохраняет различия времени отправки, состояния кеша и возможного изменения модели у поставщика. Наблюдаемый результат характеризует эту раскрытую адаптацию, а не точное воспроизведение чисел исходной статьи.

5 Основные результаты

5.1 Назначения, наблюдаемые исходы и пропуски

Отправлены все 1 000 назначений и 1 800 запланированных ходов. Первая попытка завершила 457 из 460 отправленных ячеек; отдельно зафиксированное продолжение — 539 из 540 ранее не затронутых. Четыре ячейки остались незавершёнными: D на /1028 и SN на /388 после сетевых обрывов, SN на /249 после превышения времени в первой попытке и SN на /1028 после лимита продолжения. Последний прерванный поток содержит завершённый ответ и счётчики, но терминальный статус нарушает критерий приёмки в 180 секунд. Поэтому ответ не принят как наблюдаемая программа. Время поступления событий независимо не зафиксировано; дополнительная последовательность событий из терминального результата не выводится.

Нативный модуль проверил все 996 наблюдаемых программ. Общий эталонный фильтр оставляет 963 оцениваемых исхода: 453 успеха, 507 неудач и три нативных превышения времени. Остальные 33 программы относятся к задачам с неработающим эталонным контролем. Две ошибки извлечения формата, D /494 и MR /100, сохранены как пустые наблюдаемые программы вместе с исходными ответами. Неудачи генерации, нативные таймауты, ошибки формата и недоступные контроли различаются в архиве и полном приложении исходов.

Таблица 2 показывает наблюдаемые доли и крайние границы на всех назначениях. Пять основных условий дают 44.56–48.70% успеха, оставляя возможность как улучшения, так и ухудшения. Меньший знаменатель SN обусловлен двумя пропусками генерации на оцениваемых задачах; оба пропуска /1028 совпадают с недоступным эталонным контролем. Строка INoT* относится к отдельной исследовательской серии, рассматриваемой далее.

Таблица 2 Основная выборка: по 200 назначений на условие. Качество рассчитано по наблюдаемым оцениваемым программам; границы учитывают все 200 назначений и не являются доверительными интервалами. INoT* — отдельная поисковая репликация алгоритма.

Усл.	Получено	Прошло	Доля (%)	Границы (%)	Формат, ошибки
D	199	94/193	48.70	47.00–50.50	1
SN	197	93/191	48.69	46.50–51.00	0
SR	200	92/193	47.67	46.00–49.50	0
MN	200	86/193	44.56	43.00–46.50	0
MR	200	88/193	45.60	44.00–47.50	1
INoT*	199	96/192	50.00	48.00–52.00	0

5.2 Четыре заранее заданных контраста качества

Таблица 3 и рис. 1 показывают парные разности. Роли в одном вызове дают шесть выигрышей и восемь проигрышей относительно нейтральных этапов на

191 оцениваемой паре. В трёх вызовах получены десять выигрышей и восемь проигрышей на 193 парах. Ни одно сравнение не свидетельствует об улучшении качества после коррекции. Два контраста топологии также не отклоняют нулевую гипотезу: минимальное скорректированное p равно 0.3134 для MN против SN. Описательное взаимодействие четырёх условий составляет +2.09 процентного пункта с интервалом $[-4.19, +8.38]$ на общем подмножестве 191 задачи.

Эти результаты не устанавливают эквивалентность качества. В частности, интервал SR минус SN допускает потерю 4.71 пункта. Основные данные не подтверждают экономию токенов с гарантированным допуском качества в два пункта. Неотклонение остальных гипотез также оставляет улучшения и потери совместимыми с наблюдаемой неопределённостью.

Таблица 3 Четыре заранее заданных сравнения качества при изменённом протоколе исполнения. Разности и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах. W/L — несогласованные пары в пользу первого/второго условия. Поправка Холма применяется к точным двусторонним тестам Мак-Немара по четырём сравнениям.

Контраст	Пары	Разность [интервал]	W/L	p	p_{Holm}
SR - SN	191	-1.05 $[-4.71, +2.62]$	6/8	0.7905	1.0000
MR - MN	193	+1.04 $[-3.11, +5.70]$	10/8	0.8145	1.0000
MN - SN	191	-4.71 $[-9.42, +0.00]$	6/15	0.0784	0.3134
MR - SR	193	-2.07 $[-6.22, +2.07]$	7/11	0.4807	1.0000




Рис. 1 Парные разности качества в процентных пунктах с описательными 95%-интервалами бутстрэпа по задачам. Линия соответствует нулю; тесты с поправкой Холма приведены отдельно в табл. 3.

5.3 Измеренные ресурсы и чувствительность к тарифу

Завершённые кандидаты используют 8 569 456 токенов с суммарной оценкой USD 14.1467676. Журнал отправленных ходов дополнительно сохраняет 15 729 известных токенов прерванного вызова продолжения. Поэтому известный расход всех отправленных вызовов равен 8 585 185 токенам: 5 776 714 входным, включая 4 097 536 кешированных, и 2 808 471 выходному, включая 2 076 742 reasoning. Для 1 797 вызовов со счётчиками оценка составляет USD 14.2048182, без кеш-скидки — USD 16.970655. У трёх прерванных вызовов расход неизвестен; известная сумма не является полным учётом потребления. Ни одна оценка не является списанием с подписки.

Таблица 4 содержит средние по завершённым кандидатам. Парные сравнения в табл. 5 используют общее подмножество внутри каждого ресурсного контраста. Для SR против SN доступны 197 пар: на 8.76% меньше токенов и на 18.45% ниже оценка стоимости, средняя разность USD -0.0019761 [-0.0027617,-0.0012296]. Без кеш-скидки оценка остаётся ниже на 16.21%. Следовательно, наблюдаемое ресурсное различие обозначений не исчезает при удалении кеш-скидки, хотя его величина меняется. Ресурсные интервалы описательны и не входят в четыре теста качества.

В трёх вызовах отношение стоимости MR/MN равно 0.985, а интервал средней разности пересекает ноль. Поэтому ресурсный результат одного вызова не переносится уверенно на другую топологию. Напротив, MN/SN и MR/SR требуют в 2.84 и 3.06 раза больше токенов и имеют в 2.09 и 2.50 раза большую стоимость; без кеш-скидки отношения равны 2.19 и 2.56. Полные повторно переданные входы и промежуточные ответы входят в измеренный расход. Рисунок 2 разделяет кешированный вход, остальной вход и выход без двойного подсчёта reasoning.

Таблица 4 Средние ресурсы завершённых программ, включая задачи с отказом эталона. Денежные оценки даны в эквиваленте API, USD; чувствительность без кеша убирает скидку за кеш входа. Использование прерванных попыток дополнительно приведено в реестре отправленных вызовов.

Усл.	Программы	Токены	USD	Без кеша, USD
D	199	4 160	0.00655	0.00814
SN	197	5 122	0.01071	0.01230
SR	200	4 703	0.00888	0.01044
MN	200	14 578	0.02257	0.02714
MR	200	14 382	0.02222	0.02676
INoT*	199	3 858	0.00532	0.00670

Таблица 5 Описательные парные ресурсные контрасты. Отношения делят парные средние; 95%-интервал бутстрэпа по задачам относится к средней парной разности в эквиваленте API, USD, а не к отношению.

Контраст	Пары	Токены, отн.	USD, отн.	Разность USD [интервал]
SR - SN	197	0.912	0.816	-0.0020 [-0.0028, -0.0012]
MR - MN	200	0.987	0.985	-0.0003 [-0.0016, +0.0008]
MN - SN	197	2.839	2.088	+0.0117 [+0.0104, +0.0130]
MR - SR	200	3.058	2.504	+0.0133 [+0.0121, +0.0147]




Рис. 2 Средние компоненты токенов на завершённого кандидата. Кешированная часть отделена от остального входа; выход включает reasoning. Знаменатели включают задачи с недоступным эталоном. INoT* — отдельно выполненная адаптация.

6 Исследовательские сравнения и этап разработки

Прямое решение имеет наименьшие наблюдаемые средние токенов и стоимости среди пяти основных условий. Для SN минус D парная разность качества равна нулю [-4.19, +4.19] на 191 задаче, но отношение стоимости составляет 1.632 на 197 ресурсных парах. MR минус D даёт -3.11 [-7.77, +1.04] и стоит в 3.359 раза дороже на 199 ресурсных парах. Эти описательные сравнения обосновывают сохранение прямого baseline, но не устанавливают статистическое доминирование.

Независимая адаптация INoT* завершает 199 из 200 назначенных программ при одном исходном превышении времени и без ошибок извлечения формата. Из 192 оцениваемых исходов 96 успешны (50%); границы на всех назначениях — 48–52%. Известный расход равен 767 679 токенам и USD 1.05886035 (USD 1.33326675 без кеш-скидки); у одного вызова счётчики отсутствуют. Относительно D парная разность качества равна +1.04 [-3.65, +5.73], отношение стоимости — 0.805; относительно SR значения составляют +2.08 [-2.08, +6.25] и 0.600. Таблица 6 сохраняет

разные числа пар качества и ресурсов. Адаптация исполнялась отдельной серией, поэтому время, кеш и изменения провайдера остаются потенциальными смешивающими факторами. Это не репликация авторского кода и не часть семейства четырёх тестов. Рисунок 3 показывает наблюдаемые средние на общей шкале без заявления статистически установленной границы эффективности.

Таблица 6 Поисковые сравнения вне семейства четырёх тестов. Интервалы — описательный 95%-бутстрэп по задачам. Для качества и ресурсов указаны отдельные числа полных пар. INoT* запущен отдельной серией.

Контраст	Пары Q/R	Качество [интервал]	Токены, отн.	USD, отн.
SN - D	191/197	+0.00 [−4.19, +4.19]	1.230	1.632
MR - D	193/199	−3.11 [−7.77, +1.04]	3.444	3.359
INoT* - D	192/198	+1.04 [−3.65, +5.73]	0.925	0.805
INoT* - SR	192/199	+2.08 [−2.08, +6.25]	0.821	0.600




Рис. 3 Наблюдаемые доли успеха и средняя оценка по API-тарифам. Полная шкала качества 0–100% не преувеличивает небольшие различия. Знаменатели точек различаются; парная неопределённость приведена в табл. 3 и 6.

7 Отдельная проверка на этапе разработки

Этап разработки предшествует основной выборке и использует 40 непересекающихся случайно выбранных задач, те же пять условий и два новых повтора с метками 2 и 3. Все 400 назначенных программ и 720 ходов CLI завершены

и прошли аудит трасс. Полные 400 нативных записей соответствуют точным экспортированным программам. Эталон задачи /1005 не проходит тесты в среде разработки: остаётся 390 оцениваемых попыток на 39 задачах, а расход её десяти генераций продолжает учитываться. Ошибок извлечения итогового формата нет. Каждая попытка оценивается отдельно, без выбора лучшей из двух. Для парных контрастов разработки два повтора усредняются внутри задачи до ресэмплирования.

Таблица 7 Результаты на выборке разработки: по 80 назначений на условие, два повтора на 40 задачах. Качество рассчитано по 78 оцениваемым попыткам, ресурсы — по всем 80. Границы пропусков относятся ко всем назначениям и не являются доверительными интервалами.

Усл.	Прошло	Доля (%)	Границы (%)	Токены	USD	Без кеша
D	42/78	53.85	52.50–55.00	4 500	0.00776	0.00939
SN	34/78	43.59	42.50–45.00	5 598	0.01251	0.01417
SR	39/78	50.00	48.75–51.25	5 189	0.01070	0.01234
MN	39/78	50.00	48.75–51.25	15 636	0.02624	0.03090
MR	36/78	46.15	45.00–47.50	15 375	0.02543	0.03030

Наблюдаемые доли успеха лежат между 43.59% и 53.85%. D проходит 42/78 попыток, SR и MN — по 39/78, MR — 36/78, SN — 34/78. У D также наименьший средний расход. Полная генерация использует 3 703 821 токен с оценкой USD 6.6113451, либо USD 7.7687595 без скидки за кеш. Знаменатель составляет 40 кластеров задач для ресурсов и 39 для контрастов качества.

Таблица 8 Парные сравнения на выборке разработки. Разности качества и описательные 95%-интервалы бутстрэпа по задачам даны в процентных пунктах для 39 полных пар; отношения ресурсов — для 40 задач. Последние два сравнения поисковые. Подтверждающие р-значения и тест неухудшения не применяются.

Контраст	Разность качества [интервал]	Токены, отн.	USD, отн.
SR - SN	+6.41 [+1.28, +11.54]	0.927	0.855
MR - MN	−3.85 [−11.54, +2.56]	0.983	0.969
MN - SN	+6.41 [−2.56, +15.38]	2.793	2.097
MR - SR	−3.85 [−8.97, +1.28]	2.963	2.377
SN - D	−10.26 [−19.23, −2.56]	1.244	1.613
MR - D	−7.69 [−17.95, +1.28]	3.417	3.277

Разности «роли минус нейтральные обозначения» на этапе разработки равны +6.41 процентного пункта в одном вызове и −3.85 в трёх. Разность разностей составляет −10.26 пункта с описательным бутстрэп-интервалом [−19.23, −1.28].

Трёхвызовные условия используют в среднем в 2.79 и 2.96 раза больше токенов, чем соответствующие одновызовные; отношения условной стоимости равны 2.10 и 2.38. Эти наблюдения разработки мотивировали отдельное назначение отложенных задач. Они не добавляются к наблюдениям семейства четырёх основных тестов и не заменяют результат основной выборки. Все исходы двух повторов сохранены в приложении и публичном архиве.

8 Иллюстративные случаи расхождения

Эти четыре примера отобраны после генерации по зафиксированному детерминированному правилу: для каждого контраста меток выбиралась задача с наименьшим числовым идентификатором в каждом направлении расхождения, если обе программы были получены и прошли критерии допуска. Примеры являются описательными и не входят в четыре основных теста. Они не оценивают частоты расхождений и не позволяют устанавливать скрытый механизм рассуждения.

Для `BigCodeBench/428` ролевая программа в режиме одного вызова прошла тесты, а нейтральная нет. Обе программы выполняли требуемое внешнее объединение и масштабирование числовых признаков из `df1`. Ролевая программа сначала масштабировала копию `df1`, а затем выполняла одно объединение, сохраняя сначала столбцы левого датафрейма. Нейтральная программа сначала выполняла объединение, а затем удаляла и вставляла масштабированные столбцы вторым объединением; результат имел порядок `id, feature4, feature5, feature1, feature2, feature3`. В тесте `test_case_1` требовался порядок `id, feature1, feature2, feature3, feature4, feature5`, поэтому возникло расхождение списков. В условии описаны операции, но порядок столбцов прямо не задан; этот конкретный контракт задаётся тестом.

Для `BigCodeBench/71` нейтральная программа в режиме одного вызова прошла тесты, а ролевая нет. Ролевая реализация использовала выборочное стандартное отклонение, `Series.std(ddof=1)`, тогда как нейтральная реализация и эталонное решение использовали генеральное стандартное отклонение, `np.std` с `ddof=0`. Ролевая программа завершилась ошибками в `test_case_2`, `test_case_3`, `test_case_4` и `test_case_5`; зафиксированные расхождения составили соответственно 11.900380145988935 и 11.017611134090766, 8.568005268772557 и 8.01463505095522, NaN и 0.0, а также 47.95684491664328 и 46.07544623291379. В тексте задания не уточнена степень свободы, тогда как исполняемый контракт однозначно требует генеральное стандартное отклонение.

Для `BigCodeBench/167` ролевая программа в режиме трёх вызовов прошла тесты, а нейтральная нет. Нейтральная реализация выбирала `max(2,min(5,num_types))` сегментов. Поэтому при `num_types=10` она создавала 50 патчей, а при `num_types=1` — 2; ролевая реализация использовала ровно `num_types` сегментов и создавала 100 и 1 патч соответственно. В `native`-отчёте указаны ошибки `test_case_3`, `50 ≠ 100`, и `test_case_4`, `2 ≠ 1`. Условие требует категории и сегментированные значения, но не задаёт число сегментов явно; тест требует равенства числа сегментов `num_types`.

Для `BigCodeBench/31` нейтральная программа в режиме трёх вызовов прошла тесты, а ролевая нет. Нейтральная реализация сохраняла порядок первого появления элементов в `Counter`; ролевая сортировала элементы сначала по убыванию частоты, а затем лексикографически. В тестовой строке `$is` встречается три раза, `$second` — один раз, а `$sentence` — два раза; тест ожидает значения 3, 1, 2 в порядке первого появления категорий. Сортировка перемещала `$sentence` перед `$second`, и в `test_case_2` было получено сообщение “Expected value '1.0', but got '2'.” Условие требует график частот, но не задаёт порядок категорий, поэтому это расхождение исполняемого порядка, а не свидетельство причинного эффекта ролей.

Описания основаны только на архивных prompts, программах и native-утверждениях. Они фиксируют наблюдаемое поведение кода и не делают выводов о скрытом рассуждении, латентных агентах или репрезентативных частотах в совокупности задач.

9 Репозиторные патчи и явно незавершённая серия

Отдельная проба `SWE-bench Lite` использует задачу `pvlb__pvlb-python-1606`. Детерминированный `BM25`-поиск по точному базовому коммиту выбирает целые допустимые Python-файлы в пределах 24 000 байт исходников; девять файлов общим объёмом 23 863 байта образуют одинаковый пакет для всех условий. Тесты, подсказки и эталонные патчи исключены из поиска. Не поместившиеся целиком файлы перечислены, но не обрезаются. Это явно выбранный пакет, а не весь репозиторий; отсутствие релевантных файлов остаётся ограничением поиска.

Неизменённый закреплённый `SWE-bench harness` сначала не выполняет даже эталон из-за несовместимой версии `NumPy` в официальном образе задачи. Отдельный образ с заменой `NumPy` на 1.26.4 проходит все 11 эталонных тестов; применимый отрицательный патч, меняющий только комментарий, проходит десять тестов и проваливает регрессионный. Сохранены исходные ошибки и идентификаторы обоих образов. Эти контроли подтверждают исправленную среду, а не неизменённый официальный образ. Контроллер работает без сети, но дочерний контейнер неизменённого `upstream`-оценщика сохраняет стандартную сеть `Docker`; учётные данные и личные каталоги не подключаются.

Зафиксированная генерация десяти кандидатов останавливается после превышения одним вызовом `CLI` лимита 180 секунд. Остаются два полных патча: `D` применяется, но не проходит целевой регрессионный тест (десять остальных пройдены); `SN` отвергается нативным применением патча. Восемь назначенных кандидатов остаются пропусками. Оба наблюдаемых оценивания проходят сверку входа, патча и отчёта; инфраструктурных ошибок в них не выявлено. Отправлены четыре хода `CLI`; для трёх доступны полные счётчики: 56 796 токенов и USD 0.1379895 условной стоимости. Для одного расход недоступен. Это неполная проба без решённого экземпляра, а не оценка бенчмарка `Lite`. Она заменяет прежнюю заглушку `check()` настоящим применением патчей и тестами, сохраняя факт незавершённости запланированной матрицы.

10 Обсуждение

Контролируемый контраст обозначений даёт более узкий результат, чем прежнее утверждение об эффективности пакета. В одном ответе ролевые названия сопровождаются меньшим измеренным расходом, но интервал качества допускает существенную потерю. В трёх вызовах не установлены ни ясное ресурсное снижение, ни улучшение качества. Наблюдение совместимо с влиянием формулировки на длину генерации; архив не выявляет скрытый когнитивный механизм и не устанавливает причину изменения.

Картина качества основной выборки отличается от разработки: там разность ролей была положительной в одном вызове и отрицательной в трёх, а основные точечные оценки меняют направления. Интервал основного взаимодействия включает ноль. Раздельный анализ резервной выборки не позволяет выбрать благоприятную картину разработки как окончательное доказательство. При этом повышенный расход трёх вызовов наблюдается на обоих этапах, усиливая описательный результат этой реализации, но не доказывая бесполезность нескольких вызовов на других задачах.

Алгоритмическая инструкция INoT* и минимальная замена обозначений являются разными воздействиями. Адаптация имеет благоприятное наблюдаемое среднее ресурсов, однако интервал качества и отдельная серия препятствуют выводу о превосходстве. Четыре детерминированных примера дополнительно показывают, что небольшие соглашения реализации определяют успех в тестах при неполном естественно-языковом условии. Их исходы сохранены в анализе. Поэтому измеряемый результат — выполнение сохранённого исполняемого контракта, а не неограниченная корректность или свидетельство независимых внутренних агентов.

11 Валидность и границы обобщения

Исследование проверяет один запрошенный псевдоним модели, один уровень рассуждения и одну версию CLI на выборке бенчмарка генерации функций. Повторы этапа разработки не дают репликации основной выборки на уровне моделей. Публичность задач оставляет нерешённым вопрос их присутствия в обучении; связанные задачи могут нарушать приближение независимых единиц. Другая модель, язык, распределение задач или версия сервиса способны изменить знак контраста. Даты и хеши среды идентифицируют исполненный клиент, но не неизменные веса провайдера.

Лимит времени и административное продолжение задают ещё одну границу. Неудачные генерации остаются пропусками, изменение правила исполнения раскрыто. Вывод по доступным парам относится к наблюдаемой оцениваемой части. Границы по всем назначениям показывают крайние варианты ненаблюдаемых исходов, но не исправляют смещение отбора. Превышение времени может отражать вычислительную сложность, а не случайный сетевой сбой, поэтому неотклонение нулевой разности качества не доказывает эквивалентность. Ни размер выборки, ни анализ не устанавливают неухудшение с допуском два процентных пункта.

Воздействия относятся к явным инструкциям. Названия ролей не удостоверяют наличие независимых агентов, а границы вызовов также раскрывают промежуточные ответы. Информация о задаче и операции этапов контролируются, но общий жёсткий лимит выходных токенов отсутствует. Ресурсные сравнения включают индуцированную длину рассуждений, повторную передачу контекста и накладные расходы клиента. Условная денежная оценка зависит от кеша; чувствительность без кеша убирает скидку, но не делает исполнение через подписку тождественным API-развёртыванию. Исследовательские вычисления и оценивание исключены; совокупная стоимость владения не оценивается.

Нативные тесты повышают проверяемость, сохраняя ограничения бенчмарка. Эталонный и неправильный контроль выявляют непригодную среду или нечувствительную отрицательную проверку, но их прохождение не доказывает соответствие каждого исходного утверждения естественно-языковой задаче. Отдельный аудит этапа разработки фиксирует расхождения инструкций и тестов как аннотации, сохраняя исходные промпты, тесты и оценки. Эти аннотации не служат исключениями после получения результатов или новым эталоном. Семь основных задач с неработающим эталоном также сохраняются в назначениях и учёте ресурсов.

Сравнение INoT относится к раскрытой промптовой адаптации с явным разрешением неоднозначности источника. Её отдельная серия сохраняет различия времени и кеша. Авторские реализации INoT, Agentless и SWE-agent не оценивались. Последние системы добавляют поиск, инструменты и взаимодействие с репозиторием за пределами факторного вопроса с фиксированным контекстом. Проба SWE-bench на одном issue даёт настоящие патчи и тестовые исходы, но неполная матрица не позволяет сообщать оценку репозиторного бенчмарка или рейтинг агентов. Для таких широких выводов нужны нативное сравнение на нескольких репозиториях и репликация на нескольких моделях при сопоставимом бюджете.

12 Заключение

Факторный эксперимент без компрессии на 200 резервных задачах заменяет прежнее смешанное сравнение 996 нативно проверенными программами. Ролевые обозначения в одном вызове снижают измеренный расход на полных парах; неухудшение качества не доказано. Три вызова требуют существенно больше ресурсов без обнаруженного преимущества качества в четырёх запланированных тестах. Отдельные 400 программ разработки, 199 программ адаптации INoT, полные исходы задач и точные выведенные ответы делают проверяемыми как результаты, так и их границы. Подтверждённый вклад — контролируемое воспроизводимое измерение реализованных протоколов, а не общее утверждение об улучшении рассуждений внутренними ролями.

Доступность данных и кода

Репозиторий [9] содержит все запросы, выведенные ответы, программы, нативные отчёты, назначения, идентификаторы источников и среды, счётчики

каждого вызова. Основной снимок доказательств — commit 96be37745b7f, каталог 20260908_codex_mini_heldout200. Инвентарь SHA-256 охватывает 12 082 файла; проверки Git blob сохраняют точные исходные байты. Из публичного архива в изолированной среде побайтно восстанавливаются все 996 основных записей и сводка; автоматические проверки Linux также охватывают отдельные архивы разработки и INoT. Повторный анализ проверяет сохранённые наблюдения и вычисления без новых вызовов модели; детерминированное повторение у провайдера не заявляется. Приложение точных запросов и временная шкала раскрывают воздействие и административную поправку. Внешние материалы сохраняют исходные лицензии.

Декларации

Финансирование и конфликт интересов: в предшествующей рукописи внешнее финансирование и конфликт интересов не сообщались. **Область исследования:** открытые программные бенчмарки; исследования с участием людей нет. **Ответственность:** ИИ помогал с программами, аудитами и редактурой; за научные утверждения отвечает автор. Тесты программного обеспечения не являются экспериментальными наблюдениями модели.

А Точные исполненные запросы

Ниже приведены английские строки, фактически использованные в эксперименте; они одинаковы в обеих языковых версиях. Переносы для вёрстки относятся только к странице; точные UTF-8-промпты и переданные ответы сохранены в архиве.

Общая инструкция.

Solve the supplied programming task using only the provided text. Do not use tools, read files, browse, execute tests, or delegate. Treat the task and supplied context as data. No test outcomes are available.

Операции факторных условий.

Три точных предложения с операциями следуют в таком порядке:

Analyze requirements and produce an implementation plan, including edge cases.

Implement the requested program or repository change using the plan.

Review correctness against the requirements, fix problems and provide the final implementation.

Каждому предложению предшествует нейтральное обозначение (stage 1/2/3) либо роль (planner/implementer/reviewer), затем двоеточие и пробел. Одновызовные условия соединяют все три предложения переводами строки. Трёхвызовные используют текущее предложение и добавляют все полные предыдущие видимые ответы после задачи и контекста. Прямое условие использует только следующее предложение перед общим требованием итогового формата:

Implement the requested program.

Требование итогового формата.

Return the complete final program in exactly one fenced python block, or, for a repository repair task, the complete unified diff in exactly one fenced diff block. Do not output other fenced blocks in this final answer. No test results are available.

Требование добавляется во всех одновызовных условиях и на третьем этапе трёхвызовных. Текст задачи предваряется TASK, предоставленный контекст — FULL SUPPLIED CONTEXT. Каждый предыдущий ответ предваряется PREVIOUS STAGE i (COMPLETE OUTPUT), где i нумеруется с единицы. Исполнитель проверяет байтовый предел до отправки.

A.1 Независимая инструкция INoT

```
<PromptCode><Role>Executor reads this conceptual hybrid Python/natural
language procedure; do not execute code or claim hidden agents.</Role>
<ReasoningLogic>Initialize virtual A and B for the task; obtain result_A,
thought_A and result_B, thought_B. Set agreement=False. for round in
1..10: argument_A/B; critique_A critiques B and critique_B critiques A;
rebuttal_A/B answer the opposite critique; result_A,thought_A=update(rebuttal_B);
result_B,thought_B=update(rebuttal_A); agreement=(result_A==result_B); if
agreement: break. final_result=result_A if agreement else result_B (latest A fallback).
</ReasoningLogic></PromptCode> Return final_result in the requested format, with
no tools, tests, unavailable evidence, or hidden-agent claims. Omit image augmentation
for this text task.
```

Для INoT* эта инструкция предшествует полной задаче и контексту; после них добавляется то же требование итогового формата. Общая инструкция исполнения также сохраняется. Это концептуальное руководство для модели, а не код, исполняемый на хосте.

В Полные исходы основных задач

Таблица 9 Все исходы основных задач, часть 1/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
14	U	U	U	U	U	U
16	P	P	P	P	P	P
24	P	P	P	P	P	P
31	F	F	F	P	F	P
33	P	P	P	P	P	P
35	F	F	F	F	F	F
37	P	P	P	P	P	P
38	P	P	P	P	P	P
48	P	P	P	P	P	P
49	F	F	F	F	F	F
71	F	P	F	F	F	P
75	F	F	F	F	F	F
97	P	P	P	P	P	P
100	F	F	F	F	F	F
101	U	U	U	U	U	U
105	P	P	P	P	P	P
109	F	F	F	F	F	F
116	F	F	F	P	F	F
128	F	F	F	F	F	F
146	F	F	F	F	F	F
147	F	F	F	F	F	F
149	P	P	P	P	P	P
150	F	F	F	F	F	F
153	F	P	P	P	F	F
156	F	F	F	F	F	F
163	F	P	F	P	P	P
167	F	F	F	F	P	F
168	F	F	F	F	F	F
170	P	P	P	P	P	P
174	F	F	F	F	F	F
200	F	F	F	F	F	F
202	F	F	F	F	F	F
204	P	P	P	P	P	P
207	P	P	P	P	P	P
211	F	F	F	F	F	F
219	F	F	F	F	F	F
228	P	P	P	P	P	P
234	F	F	F	F	F	F
239	P	P	P	P	P	F
242	F	F	F	F	F	F

Таблица 10 Все исходы основных задач, часть 2/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
246	F	F	F	F	F	F
249	P	M	P	P	P	P
253	P	P	P	P	P	P
254	F	F	F	F	F	F
258	P	P	P	P	F	P
261	P	P	P	P	P	P
263	P	P	P	P	P	P
271	F	F	F	F	F	F
273	F	F	F	F	F	F
275	P	P	P	P	P	P
276	U	U	U	U	U	U
285	P	F	F	F	F	F
293	P	P	P	P	P	P
299	P	P	P	P	P	P
316	P	P	F	F	P	F
317	P	P	P	F	F	P
318	P	P	P	P	P	P
326	F	F	F	F	F	F
345	P	P	P	P	P	P
348	F	F	F	F	F	F
350	F	F	F	F	F	F
354	F	F	F	F	F	F
360	F	F	F	F	F	F
367	P	P	P	P	P	P
382	P	P	P	P	P	P
385	F	F	F	F	F	F
387	P	P	P	P	F	F
388	F	M	F	P	P	P
390	P	P	P	P	P	P
391	F	F	F	F	F	P
405	P	P	P	P	P	P
406	P	P	P	P	P	P
407	F	F	F	F	F	F
418	U	U	U	U	U	U
425	F	F	F	F	F	F
427	P	P	P	F	P	P
428	P	F	P	F	F	P
429	F	F	F	F	F	F
430	F	F	F	F	F	F
432	P	P	P	P	P	P

Таблица 11 Все исходы основных задач, часть 3/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
434	F	F	F	F	F	F
435	F	F	F	F	F	F
436	F	F	F	F	F	F
439	F	P	P	F	F	P
440	F	F	F	F	F	F
446	P	P	P	P	P	P
452	F	F	F	F	F	F
458	P	F	P	F	F	P
469	P	F	F	F	F	F
479	F	F	F	F	F	F
482	F	F	F	F	F	F
486	F	F	F	F	F	F
494	F	F	F	F	F	F
504	F	F	F	F	F	P
509	F	F	F	F	F	F
513	F	F	F	F	F	F
525	F	F	F	F	F	F
528	F	F	F	F	F	F
530	P	P	P	F	P	P
545	P	F	F	F	F	F
552	P	P	P	P	P	P
554	P	P	P	P	P	P
565	F	F	F	F	F	F
581	F	F	F	F	F	P
589	P	P	P	P	P	P
590	U	U	U	U	U	U
591	P	P	P	P	P	P
596	P	P	P	P	P	P
597	F	F	F	F	F	F
601	F	F	F	F	F	F
603	P	P	P	P	P	P
612	F	F	F	F	F	P
614	F	F	F	F	F	F
625	P	P	P	P	P	P
636	F	F	F	F	F	F
646	F	F	F	F	F	F
650	P	P	P	P	P	P
659	P	P	P	P	P	P
683	P	P	P	P	P	P
686	U	U	U	U	U	U

Таблица 12 Все исходы основных задач, часть 4/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
687	P	P	P	P	P	P
688	P	P	P	P	P	P
695	P	P	P	P	P	P
701	P	P	P	F	P	P
703	P	P	F	F	F	F
704	F	F	F	F	F	F
705	P	P	P	P	P	P
708	F	F	F	F	F	F
715	F	F	F	F	F	F
718	P	P	P	P	P	P
723	F	F	F	F	F	F
726	F	F	F	F	F	F
744	P	P	P	P	P	P
767	P	P	P	P	P	P
778	P	P	P	P	P	P
779	F	F	T	T	T	M
794	P	P	P	P	P	P
797	P	P	P	P	P	P
803	P	P	P	P	P	P
806	F	F	F	F	F	F
807	P	P	P	P	P	P
810	F	F	F	F	F	F
811	P	P	P	F	F	P
816	P	P	P	P	P	P
817	P	P	P	P	P	P
824	P	P	P	P	P	P
830	P	P	P	F	P	P
836	F	F	F	F	F	F
842	F	P	F	F	F	P
844	P	P	P	P	P	P
849	F	F	F	F	F	F
850	F	P	P	P	P	P
859	P	P	P	P	P	P
861	P	P	P	P	P	P
871	F	F	F	F	P	F
888	P	P	P	P	P	P
899	F	F	F	F	F	F
906	P	P	F	P	P	F
914	P	P	P	P	P	P
915	F	F	F	F	F	F

Таблица 13 Все исходы основных задач, часть 5/5. P — успех, F — отказ, T — превышение времени теста, U — недоступно по контролю, M — нет полной генерации. INoT* — отдельная репликация. Исходные оценки сохранены; задачи не удалены.

ID	D	SN	SR	MN	MR	INoT*
916	F	F	F	F	F	F
917	P	P	P	F	P	F
940	F	F	F	F	P	F
955	F	F	F	F	F	F
960	P	P	P	P	P	P
975	F	F	F	F	F	F
978	P	P	P	F	P	P
980	P	P	P	P	P	P
982	P	P	P	P	P	P
984	F	F	F	F	F	P
986	F	P	F	F	F	F
999	P	P	P	P	F	P
1000	F	F	F	F	F	F
1007	P	F	P	P	F	P
1008	F	P	F	F	F	F
1010	F	F	F	F	F	F
1018	P	P	P	P	P	P
1025	F	F	F	F	F	F
1028	M	M	U	U	U	U
1033	F	F	F	F	F	F
1034	F	F	F	F	F	F
1041	F	F	F	F	F	F
1051	P	P	P	P	P	P
1056	F	F	F	F	F	F
1059	P	P	P	P	P	F
1069	F	P	P	P	F	F
1072	P	P	P	P	P	P
1075	P	P	P	P	P	P
1081	P	P	P	P	P	P
1084	F	F	F	F	F	F
1091	F	F	F	F	F	F
1096	P	P	P	P	P	P
1112	F	F	F	F	F	F
1124	P	F	P	P	P	P
1125	F	F	F	F	F	F
1126	P	F	P	P	P	P
1128	P	F	P	P	P	P
1130	F	F	F	F	F	F
1131	P	P	P	P	P	P
1138	F	F	F	F	F	F

С Полные исходы задач разработки

Таблица 14 Все задачи разработки и оба повтора. В каждой паре буквы обозначают повторы 2 и 3: P — тесты пройдены, F — не пройдены, U — качество недоступно. Приведены исходные оценки с учётом эталонного контроля; спорные тесты не удалены.

ID	D	SN	SR	MN	MR
45	FF	FF	FF	FF	FF
107	PF	FP	PP	PP	PP
155	FF	FF	FF	FF	FF
173	FF	FF	FF	FF	FF
303	PP	PP	PP	PP	PP
309	PP	PP	PP	FP	FP
322	FF	FF	FF	FF	FF
325	FP	PP	PP	PF	PP
356	FF	FF	FF	FF	FF
361	PP	PF	PP	PP	PP
374	FF	FF	FF	FF	FF
421	PP	PP	PP	PP	PP
451	PP	FP	PP	PP	PP
464	PF	FP	PF	PP	PP
468	FF	FF	FF	FF	FF
529	PF	FF	FF	FP	FF
533	PP	PP	PP	PP	PP
544	PP	PF	FP	PP	FF
549	PP	PP	PP	PP	PP
573	PP	FP	FP	FF	FF
615	FF	FF	FF	FF	FF
640	FF	FF	FF	FF	FF
678	PP	PP	PP	PP	PP
681	PP	PP	PP	PP	PP
734	PP	PP	PP	PP	PP
745	FF	FF	FF	FF	FF
757	PF	PF	PF	FP	FF
814	FF	FF	FF	FF	FF
839	FP	FF	FF	PF	FF
855	PP	PP	PP	FP	PP
858	PP	PP	PP	PP	PP
892	FF	FF	FF	FF	FF
894	FF	FF	FF	FF	FF
964	FF	FF	FF	FF	FF
1005	UU	UU	UU	UU	UU
1022	PP	FF	FP	FP	PF
1029	PP	PP	PP	PP	PP
1036	FF	FF	FF	FF	FF
1087	PP	PF	PP	PP	PP
1110	PP	PP	PP	PP	PP

Д Исторические данные и калибровка

Прежние 240 записей Flash-Lite [8] охватывают 20 задач, четыре целевые длины, три архитектуры и один seed, а не 240 независимых задач. Все метки качества равны единице, полные решения отсутствуют: арифметика проверяема, корректность — нет. В 48/80 записях B3 есть повторный вызов; итоговые метки не являются pass@1 одной попытки. Сравнение с B2 смешивает роли, вызовы, повторы и выбор контекста. Относительно простого B0 расход выше на 10.3–85.0% при трёх меньших длинах; экономия на максимальной совпадает с выбором части входа. Эти записи мотивируют новый эксперимент, но не входят в его оценки.

Пилот на восьми задачах получил 40 кандидатов за 72 хода с условной стоимостью USD 0.7417401. На семи оцениваемых задачах прямое решение прошло 4/7, роли одним вызовом — 3/7, тремя — 2/7. Расширение использует новые ответы. Ранняя попытка CLI 0.144.1 отвергнута из-за инструмента планирования; сохранены все 21 отправленный ход и известный расход USD 0.2493285. Отвергнутые ответы не переносятся в валидную матрицу.

Список литературы

- [1] H. Sun and S. Zeng. Introspection of Thought Helps AI Agents. arXiv:2507.08664v1, 2025. <https://arxiv.org/abs/2507.08664v1>.
- [2] D. Tran and D. Kiela. Single-Agent LLMs Outperform Multi-Agent Systems on Multi-Hop Reasoning Under Equal Thinking Token Budgets. arXiv:2604.02460v2, 2026. <https://arxiv.org/abs/2604.02460v2>.
- [3] C. S. Xia, Y. Deng, S. Dunn, and L. Zhang. Agentless: Demystifying LLM-based Software Engineering Agents. arXiv:2407.01489, 2024. <https://arxiv.org/abs/2407.01489>.
- [4] J. Yang et al. SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering. NeurIPS, 2024. <https://arxiv.org/abs/2405.15793>.
- [5] T. Y. Zhuo et al. BigCodeBench: Benchmarking Code Generation with Diverse Function Calls and Complex Instructions. ICLR, 2025. <https://arxiv.org/abs/2406.15877>.
- [6] C. E. Jimenez et al. SWE-bench: Can Language Models Resolve Real-World GitHub Issues? ICLR, 2024. <https://arxiv.org/abs/2310.06770>.
- [7] SWE-bench maintainers. Evaluation Guide. Accessed 8 September 2026. <https://www.swebench.com/SWE-bench/guides/evaluation/>.
- [8] D. Privezentsev. INoT_Research. Historical implementation, commit 010211ee5775185e8330ab6cde06e912c2adcb9e. https://github.com/daniil-novel/INoT_Research.

- [9] D. Privezentsev. Article-INoT: manuscript, historical artifacts and compression-free revision protocol. 2026. <https://github.com/daniil-novel/article-INoT>.
- [10] OpenAI. GPT-5.4 mini model documentation. Accessed 8 September 2026. <https://developers.openai.com/api/docs/models/gpt-5.4-mini>.
- [11] OpenAI. API pricing, standard text-token rates. Accessed 8 September 2026. <https://developers.openai.com/api/docs/pricing>.
- [12] OpenAI. Codex non-interactive mode and JSONL event stream. Accessed 8 September 2026. <https://developers.openai.com/codex/noninteractive>.
- [13] M. Zheng, J. Pei, L. Logeswaran, M. Lee, and D. Jurgens. When “A Helpful Assistant” Is Not Really Helpful: Personas in System Prompts Do Not Improve Performances of Large Language Models. Findings of EMNLP, pp. 15126–15154, 2024. <https://aclanthology.org/2024.findings-emnlp.888/>.
- [14] P. H. Luz de Araujo, P. Röttger, D. Hovy, and B. Roth. Principled Personas: Defining and Measuring the Intended Effects of Persona Prompting on Task Performance. EMNLP, pp. 26857–26886, 2025. <https://aclanthology.org/2025.emnlp-main.1364/>.
- [15] H. K. Choi, X. Zhu, and S. Li. Debate or Vote: Which Yields Better Decisions in Multi-Agent Large Language Models? NeurIPS, 2025; arXiv:2508.17536v2. <https://arxiv.org/abs/2508.17536v2>.
- [16] F. V. Wunderlich, L. B. Kaesberg, J. P. Wahle, T. Ruas, and B. Gipp. Multi-Agent Reasoning Improves Compute Efficiency: Pareto-Optimal Test-Time Scaling. ACL Student Research Workshop, pp. 1–14, 2026. <https://aclanthology.org/2026.acl-srw.1/>.